

NLP Asoslari va Matnni Qayta Ishlash

Tabiiy tilni qayta ishlash — 1-ma'ruza

A.A. Abdulali

11:00–12:20 · VMQ 425-son, mavzu №1

15-iyun 2026

Qayerdamiz?

1 Kirish: NLP Nima Uchun?

2 NLPga Kirish va Tarixi

3 Matnni Qayta Ishlash

4 Matn Vektorizatsiyasi

5 NLP Vazifalari va Ilovalari

6 Xulosa va Ko'prik

16 Kunda Siz Ishlaydigan NLP Tizimi Qurasiz

Kapstone loyihasi — har dars bir modul:

- **Bugun** (L1 + P1): matn tozalash, BoW, TF-IDF
`m01_text_preprocessor.py`
- **1-hafta**: klassik tasniflash, vektorlar, qidiruv
- **2-hafta**: Word2Vec, N-gram, RNN, LSTM
- **3-hafta**: Transformer, NER, Seq2Seq tarjima
- **4-hafta**: BERT fine-tuning, RAG, agent, deploy

Yakuniy mahsulot

O'zbek Hujjat Yordamchisi

Savol → qidiruv → kontekst → javob

Sharh → sentiment tahlil

Hujjat → xulosa chiqarish

Bugungi ulush

`preprocess(text)` funksiyasi — barcha keyingi 14 modul shu funksiyaga tayanadi.

Bugungi Dars Oxirida Siz Nima Qila Olasiz?

- ❶ **Keltirib chiqara olasiz:** NLP ning asosiy vazifalari va ilovalari taksonomiyasini (tasniflash, teglash, generatsiya, qidiruv).
- ❷ **Amalga oshira olasiz:** tokenizatsiya, normalizatsiya, stopword filtrlash, stemming — o'zbek apostrofining Unicode muammosini hisobga olib.
- ❸ **Hisoblay olasiz:** kichik 3-hujjatli korpus uchun BoW matritsasi va TF-IDF qiymatlarini qo'lda.
- ❹ **Kodda bog'lay olasiz:** `sklearn.TfidfVectorizer` ni qo'lda hisoblangan raqamlar bilan moslashtira olasiz.

Python asoslari (ro'yxat, tsikl, funksiya); maktab darajasida logarifm. Eslab qolmagan bo'lsangiz — ilova slayd **S1** ga qarang.

Dars Rejasi: To'rt Tsikl, 80 Daqiqa

Tsikl	Mavzu	Vaqt	Asosiy chiqish
1	NLPga kirish, tarixi, sentiment	15 daq	Sentiment tahlil tushunchasi
2	Matnni qayta ishlash (5 bosqich)	22 daq	Uzbek-aware pipeline + kod
3	BoW va TF-IDF vektorizatsiya	25 daq	Qo'lda hisoblangan TF-IDF
4	NLP vazifalari va ilovalar	12 daq	Vazifalar xaritasi
Xulosa, ko'prik P1 ga, savollar		6 daq	Ertaga nima qurasiz

Har tsikl qanday qurilgan

intuitsiya → rasmiy ta'rif → qo'lda misol → sizning vazifangiz (→ kod ko'prigi). Har qo'lda hisoblangan raqam ertangi P1 da assert sifatida tekshiriladi.

Muammo: “Yaxshi” Kalit So’zi Salbiy Sharhni Musbat Deb Belgilaydi

Maqsad: sharh musbat yoki salbiy?

Sodda yondashuv: agar “yaxshi” so’zi bo’lsa — musbat.

Natija xato!

*“Bu mahsulot yaxshi emas,
qaytarib bering!”*

naive: “yaxshi” topildi

⇒ **musbat**

???

Boshqa muammolar:

- So’z tartibi: “yaxshi emas” $\neq$ “emas yaxshi”
- Harf katta-kichik: YAXSHI $\neq$ yaxshi
- Apostrof: o’zbek $\neq$ uzbek

NLP yondashuvi:

- 1 **Preprocessing** (bugun): tozalash, vektorlash
- 2 **Vektorizatsiya** (bugun): BoW / TF-IDF
- 3 **Model o’qitish:** logistik regressiya (3-ma’ruza)
- 4 **Baholash:** F1, confusion matrix

Bugun o’rganasiz

1–2 qadamlar: preprocessing va vektorizatsiya. Tasniflash — L2 (2-ma’ruza).

Qayerdamiz?

- 1 Kirish: NLP Nima Uchun?
- 2 NLPga Kirish va Tarixi**
- 3 Matnni Qayta Ishlash
- 4 Matn Vektorizatsiyasi
- 5 NLP Vazifalari va Ilovalari
- 6 Xulosa va Ko'prik

NLP Hamma Joyda: Siz Ham Undan Foydalanasiz

Kundalik hayotda NLP:

- Spam filtri (Gmail, Outlook)
- Matn to'ldirish (Telegram, WhatsApp)
- Tarjima (Google Translate)
- Ovozli yordamchi (Siri, Alexa)
- Qidiruv tizimi (Google, Yandex)
- Huquqiy hujjat tahlili (lex.uz)

Kapstone darsi — o'zbek NLP:

- Uzum Market sharhlar → sentiment
- O'zbek yangiliklari → tasnif
- Hujjatlar bazasi → semantik qidiruv
- So'rov → RAG asosida javob

Har qanday matn vazifasi:

tozalash → **vektor** → **model**.

Bugun — birinchi ikki qadam.

NLP — Tabiiy Tilni Qayta Ishlash: Rasmiy Ta'rif

NLP (*Natural Language Processing*) — kompyuter fanlari va lingvistikaning kesishmasi; maqsad: **kompyuterlarni inson tili bilan ishlashga o'rgatish**.

bunda: *corpus* = matnlar to'plami; *token* = so'z yoki belgi birligi; *label* = tasniflash nishoni

Kiritma:

Xom matn (string)
Yangiliklar, sharhlar
Huquqiy hujjatlar
Suhbat tarixi


NLP vazifalari:

Tasniflash (classification)
Teglash (tagging / NER)
Generatsiya (generation)
Qidiruv (retrieval)

Chiqarma:

Sinf belgisi
Annotatsiyalangan
ketma-ketlik
Yangi matn

NLP Tarixi: Qoidalardan Neyron Tarmoqlargacha



Bu kursda:

- 1-hafta: Statistik + ML (BoW, TF-IDF, LR, NB)
- 2-hafta: Word2Vec, N-gram, RNN
- 3-hafta: LSTM, Seq2Seq, Transformer
- 4-hafta: BERT fine-tuning, RAG, agentlar

O'zbek NLP haqiqati

O'zbek uchun asosiy muammo: **labeled data kamligi**. Barcha usullar — qoidadan LLM gacha — shu muammoni turli yo'llar bilan hal qiladi.

Sentiment Tahlili: Sharh Musbatmi Yoki Salbiy?

Vazifa: Uzum Market sharhlarini musbat / salbiy deb tasniflash.

Kiritma (xom sharhlar):

“Bu dastur juda qulay va tezkor!”

“Yetkazib berish 3 kun kechikdi.”

“Narxi yaxshi, lekin sifati o'rtacha.”

Maqsad (label):

→ **musbat** +

→ **salbiy** −

→ **salbiy** − (“lekin” zid bildiradi)

Sodda pipeline:

- 1 So'zlarni sanash (BoW / TF-IDF) — *bugun, tsikl 3*
- 2 Chastotaga asoslangan model o'qitish (logistik regressiya) — *L2*
- 3 Yangi sharh uchun bashorat

P13 da (14-kun): BERT ni o'zbek sharhlar uchun fine-tune qilamiz!

Savol — 30 soniya

Quyidagi sharh musbatmi yoki salbiy?

“Mahsulot o‘z vaqtida keldi, ammo rang kutganimdek emas edi.”

Qaysi so‘z yoki ibora sizning qaroringizni belgiladi?

Sizning Vazifangiz: Sentiment Taxmin Qiling

Savol — 30 soniya

Quyidagi sharh musbatmi yoki salbiy?

“Mahsulot o‘z vaqtida keldi, ammo rang kutganimdek emas edi.”

Qaysi so‘z yoki ibora sizning qaroringizni belgiladi?

Javob

Salbiy — “ammo . . . emas edi” iborasi salbiy his-tuyg‘uni bildiradi.

“O‘z vaqtida keldi” — musbat signal, lekin “ammo” dan keyingisi ustun turadi.

Muammo: oddiy BoW bu “ammo”–“emas” kombinatsiyasini **ko‘rmaydi** — ikkala so‘z alohida-alohida hisoblanadi.

Yechim: n-gramlar (5-ma’ruza) yoki BERT (13-ma’ruza).

Qayerdamiz?

- 1 Kirish: NLP Nima Uchun?
- 2 NLPga Kirish va Tarixi
- 3 Matnni Qayta Ishlash**
- 4 Matn Vektorizatsiyasi
- 5 NLP Vazifalari va Ilovalari
- 6 Xulosa va Ko'prik

Xom Matn Shovqin To'la — Tozalash Shart

Xom kiritma:

```
"Toshkentda NLP O'RGANISH  
JUDA qiziq!!! :) #nlp"
```

Muammolar:

- $NLP \neq nlp$ (harf katta-kichik)
- `!!!`, `:)`, `#nlp` — shovqin
- `JUDA` — stopword, ma'no bermaydi
- `O'RGANISH`, `o'rganish`, `o'rgan` — bir o'zak, uch alohida token

Tozalangan chiqarma:

```
['toshkent', 'nlp', 'o'rgan',  
'qiziq']
```

Foyda:

- Lug'at hajmi kamayadi ($|V| \downarrow$)
- Hujjatlar taqqoslanadigan bo'ladi
- Bir o'zakli shakllar birga guruhlanadi

Preprocessing sifati barcha
keyingi modellar natijasini
bevosita belgilaydi!

Preprocessing Pipeline: Besh Bosqich

- ➊ **Tokenizatsiya** (*tokenization*) — matnni token ro'yxatiga aylantirish; o'zbek uchun Unicode-aware regex zarur
- ➋ **Kichik harfga o'tish** (*lowercasing*) — NLP, Nlp, nlp → nlp
- ➌ **Tinish belgilarini tozalash** — !, ?, :) → o'chirish
- ➍ **Stop-word filtrlash** (*stopword removal*) — “va”, “yoki”, “bu”, “ham” → o'chirish
- ➎ **Stemming / lemmatizatsiya** — “o'rganadi” → “o'rgan”

bunda: *token* = matn birligi; *stopword* = ma'nosiz tez-uchraydigan so'z; *stem* = so'z o'zagining taxminiy shakli

Stop-Words Filtrlash va Stemming: Muhim So'zlarni Qoldiring

Stop-words (o'zbek misoli):

*“va”, “yoki”, “bu”, “ham”,
“lekin”, “esa”, “juda”, “bilan”...*

Bu so'zlar barcha hujjatlarda tez uchraydi $\Rightarrow$ df
yuqori $\Rightarrow$ IDF past $\Rightarrow$ TF-IDF past.

Filtrlash foydasi: lug'at $|V|$ kamayadi, model tezroq
va aniqroq.

Stemming vs Lemmatizatsiya:

So'z	Stem	Lemma
o'rganadi	o'rgan	o'rganmoq
o'rganish	o'rgan	o'rganish
o'rgandim	o'rgan	o'rganmoq
o'rganaman	o'rgan	o'rganmoq

Stem: qo'shimcha qirqadi — tezroq

Lemma: lug'at shakli — aniqroq

O'zbek uchun: Snowball yoki regex.

Qo'lda Misol: Besh Bosqichdan O'tish

Kiritma: "O'zbekistonda NLP o'rganish juda qiziqarli!"

#	Bosqich	Natija
1	Tokenizatsiya	["O'zbekistonda", "NLP", "o'rganish", "juda", "qiziqarli", "!"]
2	Kichik harf	["o'zbekistonda", "nlp", "o'rganish", "juda", "qiziqarli", "!"]
3	Tinish tozalash	["o'zbekistonda", "nlp", "o'rganish", "juda", "qiziqarli"]
4	Stop-words	["o'zbekistonda", "nlp", "o'rganish", "qiziqarli"] (<i>"juda"</i> olib tashlandi)
5	Stemming	["o'zbekiston", "nlp", "o'rgan", "qiziq"]

Muhim kuzatuv

"o'rganish" → "o'rgan" (stemming). Ertaga P1 da barcha 5 bosqich
TextPreprocessor.preprocess() metodida amalga oshiriladi.

Sizning Vazifangiz: Matnni Qo'lda Tozalang

Savol — 2 daqiqa

Quyidagi matnni 5 bosqichdan o'tkazing:

"Toshkentda katta tadbir bo'ldi, hammaga yoqdi va esda qoldi!"

Stop-words: {va, yoki, bu, ham, esa, hammaga}

Sizning Vazifangiz: Matnni Qo'lda Tozalang

Savol — 2 daqiqa

Quyidagi matnni 5 bosqichdan o'tkazing:

"Toshkentda katta tadbir bo'ldi, hammaga yoqdi va esda qoldi!"

Stop-words: {va, yoki, bu, ham, esa, hammaga}

Javob

- 1) ["Toshkentda", "katta", "tadbir", "bo'ldi", "hammaga", "yoqdi", "va", "esda", "qoldi", "!"]
- 2) ["toshkentda", "katta", "tadbir", "bo'ldi", "hammaga", "yoqdi", "va", "esda", "qoldi", "!"]
- 3) ["toshkentda", "katta", "tadbir", "bo'ldi", "hammaga", "yoqdi", "va", "esda", "qoldi"]
- 4) ["toshkentda", "katta", "tadbir", "bo'ldi", "yoqdi", "esda", "qoldi"]
- 5) ["toshkent", "katta", "tadbir", "bo'l", "yoq", "esda", "qol"]

Kod ↔ Pipeline: Uzbek Regex Tokenizer

preprocessing_uz.py

```
import re

STOP_UZ = {
    'va', 'yoki', 'bu', 'ham',
    'lekin', 'esa', 'juda'
}

def preprocess(text):
    text = text.lower()           # 2. kichik
    harf                           harf
    tokens = re.findall(          # 1.
        "[a-z\u2019\u2019]+", text) # '=U+2019
    tokens = [t for t in tokens   # 4. stopword
               if t not in STOP_UZ]
    stems = [                     # 5. stemming
        re.sub(
            r'(lar|da|dan|ga|ni|lik|ish|di|man)$',
            ''
```

Qator → bosqich:

Qator	Pipeline bosqich
9	#2 kichik harf
10–11	#1 tokenizatsiya
12–13	#4 stopword filtri
14–19	#5 stemming

Eslatma

Tinish belgilarini tozalash
(#3) regex avtomatik:
[a-z...]+ faqat
harflarni ushlaydi.

Tuzog': Apostrof Birligi Tokenizer'ni Sindiradi

Haqiqiy xato — amaliyotda tez-tez uchraydi

Word, Google Docs ko'pincha U+2019 (') ni ishlatadi.

Agar `re.findall(r"[a-z']+")` da faqat ASCII ' (0x27) bo'lsa va hujjatda U+2019 (') bo'lsa:

`"o'rganish" → ["o", "rganish"]` **NOTO'G'RI**

Yechim: ikkala Unicode nuqtasini qo'llang

```
re.findall(r"[a-z\u2019']+", text.lower())
```

`\u2019` = U+2019 (') va ' (ASCII 0x27) ikkisini ushlaydi.

P1 darsida `uzbek_tokenize()` shu regex'ni ishlatadi — bu kurs davomida standart tokenizer sifatida qabul qilinadi.

Keyingi darsda (L4, 5-kun): Levenshtein masofasi bilan imlo tuzatishda ushbu apostrof farqi masofani noto'g'ri hisoblashiga olib keladi.

Qayerdamiz?

- 1 Kirish: NLP Nima Uchun?
- 2 NLPga Kirish va Tarixi
- 3 Matnni Qayta Ishlash
- 4 Matn Vektorizatsiyasi**
- 5 NLP Vazifalari va Ilovalari
- 6 Xulosa va Ko'prik

BoW: Har Bir Hujjat So'zlar To'plami Sifatida

3 ta hujjat:

D1: "nlp qiziq"

D2: "python foydali"

D3: "nlp foydali"

Lug'at:

$V = \{\text{nlp, qiziq, python, foydali}\}$

Har bir so'zni sanash:

	nlp	qiziq	python	foyda
D1	1	1	0	0
D2	0	0	1	1
D3	1	0	0	1

Har satr — hujjat vektori $\mathbf{d}_i \in \mathbb{R}^4$.

So'z **tartibi saqlanmaydi!**

Muammo: "nlp" D1 va D3 da bir xil.

→ Yechim: TF-IDF og'irlash.

Soʻz Qopi (Bag of Words) — Rasmiy Taʼrif

Lugʻat: $V = \{w_1, w_2, \dots, w_{|V|}\}$ — korpusdagi barcha noyob tokenlar toʻplami.

Hujjat vektori: $\mathbf{d}_i \in \mathbb{R}^{|V|}$, bunda $d_{i,j} = “w_j$ soʻzining D_i hujjatdagi paydo boʻlish soni”.

bunda: $V = \text{lugʻat}$; $|V| = \text{lugʻat hajmi}$; $\mathbf{d}_i = i\text{-hujjat vektori}$; $d_{i,j} = j\text{-soʻz chastotasi } D_i \text{ da}$ **Muhim xossalar:**

- $d_{i,j} \geq 0$ (chastota manfiy boʻlmaydi)
- $d_{i,j} = 0$ (w_j soʻzi D_i da yoʻq)
- Vektor **siyrak** (sparse): aksariyat yozuvlar = 0
- Soʻz tartibi, kontekst, maʼno — **yoʻqoladi**

TF: Hujjatdagi So'z Chastotasi (Term Frequency)

$$\text{TF}(t, d) = (t \text{ so'zining } d \text{ hujjatdagi paydo bo'lish soni})$$

bunda: t = so'z (term); d = hujjat (document); bu kursda **raw count** (normalizatsiyasiz) ishlatadi
Misollar (bizning korpus):

Hujjat	Matn	So'z	TF
D1	"nlp qiziq"	nlp	1
D1	"nlp qiziq"	qiziq	1
D2	"python foydali"	python	1
D3	"nlp foydali"	foydali	1

Boshqa ta'riflar ham bor (masalan, normalized: $\text{TF}/|d|$). Bu kurs raw count ishlatadi — qo'lda hisoblash osonroq.

IDF: Noyob So'zlar Mukofotlanadi (Inverse Document Frequency)

$$\text{IDF}(t) = \ln\left(\frac{N}{\text{df}(t)}\right)$$

bunda: N = korpusdagi jami hujjatlar soni; $\text{df}(t)$ = t uchraydigan hujjatlar soni; $\ln$ = natural logarifm
Nima uchun logarifm?

- Agar N/df juda katta bo'lsa (noyob so'z), $\ln$ shkalani boshqaruvchan qiladi.
- $\text{df}(t) = N$: $\text{IDF} = \ln(1) = 0$ (barcha hujjatlarda — muhim emas)
- $\text{df}(t) = 1$: $\text{IDF} = \ln(N)$ (faqat bitta hujjatda — juda muhim)

TF-IDF: $\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \text{IDF}(t)$

Qo'lda Hisob: 3 Hujjat, TF-IDF Matritsasi (P1 Assert Raqamlari)

Korpus: $N = 3$; $D1 = \text{"nlp qiziq"}$, $D2 = \text{"python foydali"}$, $D3 = \text{"nlp foydali"}$
 $V = \{\text{nlp, qiziq, python, foydali}\}$

BoW matritsasi:

	nlp	qiziq	py	foyd
D1	1	1	0	0
D2	0	0	1	1
D3	1	0	0	1

IDF hisoblash:

So'z	df	IDF
nlp	2	$\ln(3/2) \approx \mathbf{0.405}$
qiziq	1	$\ln(3/1) \approx \mathbf{1.099}$
python	1	$\ln(3/1) \approx 1.099$
foydali	2	$\ln(3/2) \approx 0.405$

TF-IDF = TF $\times$ IDF:

$$\text{TF-IDF}(\text{nlp}, D1) = 1 \times 0.405 = \mathbf{0.405}$$

$$\text{TF-IDF}(\text{qiziq}, D1) = 1 \times 1.099 = \mathbf{1.099}$$

Xulosa

"qiziq" D1 ni **yaxshiroq tavsiflaydi** — faqat D1 da uchraydi! (df=1, IDF yuqori)

"nlp" D1 ham D3 da bor — past og'irlik (0.405).

Ertangi P1 birinchi assert:

`abs(val_nlp - 0.405) < 1e-3`

`abs(val_qiziq - 1.099) < 1e-3`

Sizning Vazifangiz: TF-IDF(*python*, D2) Hisoblang

Savol — 2 daqiqa (xuddi shu korpus)

D1="nlp qiziq", D2="python foydali", D3="nlp foydali", $N = 3$

a) TF-IDF(*python*, D2) =?

b) TF-IDF(*foyda*li, D2) =?

Qaysi so'z D2 ni yaxshiroq ifodalaydi?

Sizning Vazifangiz: TF-IDF(*python*, D2) Hisoblang

Savol — 2 daqiqa (xuddi shu korpus)

D1="nlp qiziq", D2="python foydali", D3="nlp foydali", $N = 3$

a) TF-IDF(*python*, D2) = ?

b) TF-IDF(*foyda*li, D2) = ?

Qaysi so'z D2 ni yaxshiroq ifodalaydi?

Javob

a) $df(\text{python}) = 1 \Rightarrow IDF = \ln(3/1) \approx 1.099$

TF-IDF(*python*, D2) = $1 \times 1.099 = \mathbf{1.099}$

b) $df(\text{foyda}li) = 2$ (D2 va D3 da) $\Rightarrow IDF = \ln(3/2) \approx 0.405$

TF-IDF(*foyda*li, D2) = $1 \times 0.405 = \mathbf{0.405}$

Xulosa: "python" D2 ni yaxshiroq ifodalaydi — faqat D2 da uchraydi!

Kod ↔ Formula: TfidfVectorizer va Qo'lda Hisob

tfidf_demo.py

```
from sklearn.feature_extraction.text \
    import TfidfVectorizer

corpus = [
    "nlp qiziq",          # D1
    "python foydali",     # D2
    "nlp foydali"         # D3
]

# smooth_idf=False -> IDF = ln(N/df)
# norm=None -> L2 normalizatsiyasiz
vec = TfidfVectorizer(
    smooth_idf=False, norm=None)
X = vec.fit_transform(corpus).toarray()

idx = vec.vocabulary_
# X[0, idx['nlp']] -> 0.405
# X[0, idx['qiziq']] -> 1.099
```

Parametr → formula:

Parametr	Formula
smooth_idf=False	$\ln(N/df)$
smooth_idf=True	$\ln \frac{N+1}{df+1}$
norm=None	raw TF-IDF
norm='l2'	ℓ_2 -norma

Ehtiyot

sklearn default:

smooth_idf=True,
norm='l2'.

Qo'lda hisob bilan
moslashtirish uchun
parametrlarni
moslang!

Qayerdamiz?

- 1 Kirish: NLP Nima Uchun?
- 2 NLPga Kirish va Tarixi
- 3 Matnni Qayta Ishlash
- 4 Matn Vektorizatsiyasi
- 5 NLP Vazifalari va Ilovalari**
- 6 Xulosa va Ko'prik

NLP Nima Qila Oladi? Vazifalar Xaritasi

Matnni sinflarga ajratish

- Sentiment: musbat / salbiy
- Spam filtri: spam / ham
- Mavzu: sport, siyosat, ...

Yangi matn yaratish

- Tarjima: uz → en
- Xulosa: uzun → qisqa
- Dialog: savol → javob

Har token uchun sinf belgilash

- NER: inson, joy, tashkilot
- POS: ot, fe'l, sifat, ...

Mos hujjat topish

- Semantik qidiruv (FAISS)
- RAG: so'rov → kontekst → LLM javob

Asosiy NLP Vazifalari va O'zbek Ilovalari


Vazifa	Metod	O'zbek ilovasi (kapstone)
Sentiment tahlil	BoW+LR, BERT	Uzum Market sharhlar (P2, P13)
NER	Bi-LSTM	Lex.uz: shaxs, joy, tashkilot (P10)
Tarjima	Seq2Seq+Attention	Uz-En parallel corpus OPUS-100 (P11)
Xulosa	Transformer	Wikipedia o'zbek maqolalar (P12)
Qidiruv (RAG)	FAISS + LLM	O'zbek qonunchilik hujjatlari (P14)
Agent	LangChain ReAct	Hujjat yordamchisi — kapstone (P15)

Kapstone aloqasi

Har satr — kurs davomida qurasiz. Bugungi preprocessing (m01) barchasining birinchi qadami sifatida ishlaydi.

To'liq Pipeline: Sharhdan Sentiment Ballgacha

Vazifa: “Bu mahsulot qimmat, ammo sifati a'lo!” → musbat?



m01 (bugun):

["mahsulot", "qimmat", "sifat", "alo"]

TF-IDF:

[0.0, 0.5, 0.3, 0.9, ...]

m02 (3-kun): LR bashorat → {musbat: 0.74}

Kuzatuv

“alo” so'zining yuqori TF-IDF musbat tasniflashga yordam beradi. “qimmat” salbiy signal — model ularni og'irlaydi.

Sizning Vazifangiz: Ilovani NLP Vazifasiga Moslang

Savol — 2 daqiqa

Quyidagi ilovalar qaysi NLP vazifasiga tegishli?

- 1 Telegram botga “Bugun Toshkentda ob-havo qanday?” deb so’rash
- 2 Yangiliklar saytida “NLP” kalit so’zi bilan mos maqolalar topish
- 3 Jurnal maqolasidan 3-gaplik xulosa olish
- 4 O’zbek matnida “Abdulloh Karimov, Toshkent” ni aniqlash

Sizning Vazifangiz: Ilovani NLP Vazifasiga Moslang

Savol — 2 daqiqa

Quyidagi ilovalar qaysi NLP vazifasiga tegishli?

- 1 Telegram botga “Bugun Toshkentda ob-havo qanday?” deb so’rash
- 2 Yangiliklar saytida “NLP” kalit so’zi bilan mos maqolalar topish
- 3 Jurnal maqolasidan 3-gaplik xulosa olish
- 4 O’zbek matnida “Abdulloh Karimov, Toshkent” ni aniqlash

Javob

- 1 **Dialog / Generatsiya** — LLM agent (P15, 16-kun)
- 2 **Semantik qidiruv / Retrieval** — FAISS indeks (P14, 15-kun)
- 3 **Xulosa / Summarization** — Transformer (P12, 13-kun)
- 4 **NER (nomlangan obyektlar)** — Bi-LSTM (P10, 11-kun)

Qayerdamiz?

- 1 Kirish: NLP Nima Uchun?
- 2 NLPga Kirish va Tarixi
- 3 Matnni Qayta Ishlash
- 4 Matn Vektorizatsiyasi
- 5 NLP Vazifalari va Ilovalari
- 6 Xulosa va Ko'prik**

O'zbek Tili: Agglutinatsiya TF-IDF Ni Chalg'itadi

Agglutinativ morfologiya:

Shakl	Morfema tahlili	Stem
o'rganaman	o'rgan+a+man	o'rgan
o'rganish	o'rgan+ish	o'rgan
o'rgandim	o'rgan+di+m	o'rgan
o'rganadi	o'rgan+a+di	o'rgan

4 ta **alohida token** — 1 ta ma'no!

BoW matritsasida **4 ta alohida ustun**
(har birida $df \approx 1$, IDF yuqori).

Stemming *olmasa*:

- Lug'at hajmi sun'iy oshadi ($|V| \uparrow$)
- Vektor siyraklashadi (sparse $\uparrow$)
- O'rganish topiklari tarqab ketadi

Stemming *bilan*:

- Barcha 4 shakl → "o'rgan"
- 1 ta ustun, df to'g'ri

Dars xulosasi

O'zbek NLP da stemming — **majburiy**; ingliz tilida esa ko'pincha ixtiyoriy. m01 uchun asosiy sabablardan biri shu.

Qachon Nima Ishlatish? BoW va TF-IDF Taqqoslov Jadvali

Mezon	CountVec (BoW)	TfidfVec
Asosi	Raw chastota	$TF \times IDF$ og'irlash
Umumiy so'zlar	Yuqori $\Rightarrow$ ustunlik	Past IDF $\Rightarrow$ kamaytiriladi
Noyob so'zlar	Oddiy og'irlik	Yuqori IDF $\Rightarrow$ muhimroq
Sklearn sinfi	CountVectorizer	TfidfVectorizer
Tezlik	Tezroq	Ozgina sekinroq
Qo'llash	Baseline, Naive Bayes	Qidiruv, LR, SVM
O'zbek uchun	Stemming kerak	Stemming + IDF muhim

Amaliy qoida

Har doim TfidfVectorizer bilan boshlang; Naive Bayes uchun CountVectorizer ni sinab ko'ring. Ikkalasida ham preprocessor (m01) majburiy.

Salton (1975): 50 Yillik Poydevor

Salton, G., Wong, A., Yang, C.S. (1975). **A Vector Space Model for Automatic Indexing.** *Communications of the ACM*, 18(11), 613–620.

Maqola haqida:


- 1975 — Google'dan 23 yil oldin!
- Matnni vektor sifatida ko'rish g'oyasi shu erdan boshlanadi
- TF-IDF og'irlash shu maqoladan kelib chiqqan
- Bugungi BERT, GPT ham “embedding” g'oyasiga tayanadi
- Google Scholar: 10 000+ iqtibos

Keyingi sessiyaga muhokama savoli

TF-IDF “qiziq” ni D1 uchun muhim so'z deb aniqladi.

- ① ✓ **Keltirib chiqardik:** NLP vazifalari taksonomiyasi — tasniflash, teglash, generatsiya, qidiruv; O'zbek kapstone ilovalari.
- ② ✓ **Amalga oshirdik:** tokenizatsiya, normalizatsiya, stopword filtrlash, stemming — o'zbek apostrofining U+2019 muammosi bilan birga.
- ③ ✓ **Hisobladik:** 3 hujjatli korpus uchun BoW matritsasi; $IDF(nlp) \approx 0.405$, $TF-IDF(qiziq, D1) \approx 1.099$.
- ④ ✓ **Kodda bog'ladik:** `TfidfVectorizer(smooth_idf=False, norm=None)` ni qo'lda hisoblangan qiymatlar bilan moslashtirdik.

Ertaga P1: Preprocessing Pipeline Qurasiz



P1 da qurasiz:

- Uzbek-aware regex tokenizer
- Stopword filtri + Snowball stemmer
- CountVectorizer → BoW matritsa
- TfidfVectorizer → TF-IDF matritsa
- m01_text_preprocessor.py saqlash

Birinchi assert (bu slayd [I3]):

```
assert abs(nlp_score - 0.405) < 1e-3  
assert abs(qiziq_score - 1.099) <  
1e-3
```

*# Ma'ruza L1 [I3]-slayd bilan
solishtiring*

- ❶ Salton, G., Wong, A., Yang, C.S. (1975). *A Vector Space Model for Automatic Indexing*. CACM 18(11):613–620.
- ❷ Jurafsky, D., Martin, J.H. (2023). *Speech and Language Processing*, 3-nashr (online). 2-bob: Regular Expressions, Tokenization; 6-bob: Naive Bayes & TF-IDF.
- ❸ Bird, S., Klein, E., Loper, E. (2009). *Natural Language Processing with Python*. O'Reilly. 3-bob: Processing Raw Text.
- ❹ Scikit-learn hujjatlari: `CountVectorizer`, `TfidfVectorizer` — scikit-learn.org/stable/modules/feature_extraction.html
- ❺ NLTK Book, 3-bob: Processing Raw Text — nltk.org/book/ch03.html

S1: Logarifm va IDF Hisoblash (Math Refresher)

$$\ln(1) = 0 \quad \ln(e) \approx 2.718 \Rightarrow \ln(e) = 1 \quad \ln(a/b) = \ln a - \ln b$$

Keng qo'llaniladigan qiymatlar:

N	df	N/df	$IDF = \ln(N/df)$
3	1	3.00	$\ln(3) \approx 1.099$
3	2	1.50	$\ln(1.5) \approx 0.405$
3	3	1.00	$\ln(1) = 0.000$
10	1	10.0	$\ln(10) \approx 2.303$
10	5	2.00	$\ln(2) \approx 0.693$

Python da: `import math; math.log(3/2)` yoki `import numpy as np; np.log(1.5)`

S2: BoW Matritsasi Qo'lda Qurilishi — Algoritm

- 1 Barcha hujjatlarni tokenizatsiya + preprocessing qiling
- 2 Barcha noyob tokenlarni yig'ing $\rightarrow$ lug'at V , ularni tartiblang (alfavit bo'yicha)
- 3 $|D| \times |V|$ o'lchamli nol matritsa yarating
- 4 Har hujjat uchun: har tokenni V da toping $\rightarrow$ tegishli katakni oshiring

Bizning misolimiz:

Hujjat	foydali	nlp	python	qiziq
D1: "nlp qiziq"	0	1	0	1
D2: "python foydali"	1	0	1	0
D3: "nlp foydali"	1	1	0	0

Sklearn: `CountVectorizer().fit_transform(corpus).toarray()`

S3: Stemming Algoritmolari va O'zbek Uchun Moslash

Taniqli algoritmalar:

- **Porter Stemmer** (1980) — ingliz, oddiy
- **Snowball** (Porter2) — ko'p til, tavsiya
- **Lancaster** — tajovuzkor qirqish
- **Lemmatizatsiya** — lug'at asosida, aniqroq

`SnowballStemmer('russian')` —
o'zbek uchun eng yaqin taxmin
(morfologik jihatdan o'xshash).

Oddiy regex yondashuvi:

```
import re
UZ_SFX = (
    r'(lar|da|dan|ga|ni|ning|
    r'|lik|ish|chi|man|di|
    r'|siz|imiz|ingiz)$'
)
def stem_uz(w):
    return re.sub(UZ_SFX, '', w)
```

Bu oddiy suffix qirqish — to'liq morfologik tahlilchi emas. P1 da ishlatiladi.