

Vektor fazo modellari va semantik munosabatlar

Tabiiy tilni qayta ishlash — 3-ma'ruza

A.A. Abdulali

11:00–12:20 · mavzu №3

18-iyun 2026

Prezentatsiya rejasi

- 1 Kirish: TF-IDF dan embeddinggacha
- 2 Zich vektorlar: so'z embeddinglari
- 3 Kosinus o'xshashligi
- 4 So'z analogiyalari va semantik munosabatlar
- 5 PCA bilan vizualizatsiya
- 6 Xulosa va amaliyotga ko'prik

Takrorlash: bugun ertalab nima qurdik?

1-savol

P2 da sentiment klassifikatori **nima** ustida ishladi — xom matn ustidami yoki vektor ustida?

Vektorni qaysi usul yaratdi?

2-savol

TF-IDF fazosida "qiziq" va "qiziqarli" so'zlari bir-biriga **qanchalik yaqin**?

Takrorlash: bugun ertalab nima qurdik?

1-savol

P2 da sentiment klassifikatori **nima** ustida ishladi — xom matn ustidami yoki vektor ustida?

Vektorni qaysi usul yaratdi?

2-savol

TF-IDF fazosida "qiziq" va "qiziqarli" so'zlari bir-biriga **qanchalik yaqin**?

1-javob

Vektor ustida — **TF-IDF / BoW** matritsasi. Model xom matnni emas, sonli vektorni ko'radi.

2-javob

Umuman yaqin emas! Ular ikki **alohida ustun** — o'xshashligi 0.

TF-IDF so'z ma'nosini bilmaydi. Bugun shuni hal qilamiz.

Siz bugungi dars oxirida quyidagilarni bajara olasiz:

- ➊ **Keltirib chiqara olasiz:** distributiv gipotezadan zich vektor (embedding) g'oyasini — nega siyrak TF-IDF ma'noni ushlay olmaydi.
- ➋ **Qo'lda hisoblay olasiz:** ikki vektor orasidagi kosinus o'xshashlikni (kichik misol: $\cos = 2/3$).
- ➌ **Yecha olasiz:** vektor arifmetikasi bilan so'z analogiyasini ($\mathbf{b} - \mathbf{a} + \mathbf{c}$).
- ➍ **Kodda bog'lay olasiz:** `cosine_similarity`, `most_similar` va PCA chaqiriqlarini formulaning qaysi qadami ekanligini ko'rsata olasiz.

L1 dan: BoW / TF-IDF vektor. Matematikadan: vektor, skalyar ko'paytma, norma (uzunlik). Eslamasangiz — ilova slayd **S2** ga qarang.

Bugungi dars rejasi:

Tsikl	Mavzu	Vaqt	Hosil bo'luvchi natija
1	So'z embeddinglari: distributiv gipoteza, zich vektor	18 daq	Embedding tushunchasi
2	Kosinus o'xshashligi	22 daq	Qo'lda hisoblangan $\cos = 2/3$
3	So'z analogiyalari va semantik munosabatlar	18 daq	Vektor arifmetikasi
4	PCA bilan vizualizatsiya	12 daq	2D embedding fazosi
	Xulosa va 3-amaliyotga ko'rsatmalar	10 daq	Ertaga nima qurishinigiz

Har bir tsikl qanday qurilgan

intuitsiya → rasmiy ta'rif → qo'lda misol → sizning vazifangiz → kod bilan ishlash uchun ko'prik. Bugungi $\cos = 2/3$ ertangi amaliyotda assert sifatida tekshiriladi.

Bugungi dars uchun muammo: TF-IDF “qiziq” va “qiziqarli” ni butunlay begona deb biladi

L1 oxirida savol qoldirgandik:

“TF-IDF qiziq va qiziqarli ni bir xil ma’no deb ko’ra oladimi?”

Javob: yo’q!

Lug’atda ular ikki **alohida o’lcham**:

qiziq $\rightarrow (1, 0)$

qiziqarli $\rightarrow (0, 1)$

Skalyar ko’paytma $= 0 \Rightarrow$ o’xshashlik $= 0$,
ma’nosi yaqin bo’lsa ham.

Yana ikki kamchilik:

- **Siyraklik**: vektor o’lchami $= |V|$ — minglab nol.
- **Sinonim ko’rmaydi**: avtomobil $\neq$ mashina.

Bugungi yechim

Zich vektor (embedding): kichik o’lchamli, ma’noni ushlaydigan ifoda. O’xshash so’zlar — yaqin vektorlar.

Prezentatsiya rejasi

- 1 Kirish: TF-IDF dan embeddinggacha
- 2 Zich vektorlar: so'z embeddinglari
- 3 Kosinus o'xshashligi
- 4 So'z analogiyalari va semantik munosabatlar
- 5 PCA bilan vizualizatsiya
- 6 Xulosa va amaliyotga ko'prik

So'zni qanday qilib raqamga aylantiramiz? Siyrakdan zichgacha

Siyrak (one-hot / TF-IDF):

$nlp \rightarrow (0, \dots, 1, \dots, 0)$

$|V|$ o'lchamli — masalan 50 000.

Faqat bitta 1, qolgani nol.

Har so'z boshqalardan **teng uzoqlikda**.

Zich (embedding):

$nlp \rightarrow (0.21, -0.08, 0.66, \dots)$

Kichik o'lchamli — masalan 100–300.

Barcha qiymatlar to'la (nol emas).

O'xshash so'zlar — **yaqin** vektorlar.

“So'zni uning hamrohlaridan bilib olasan.”
(Firth, 1957)

O'xshash **kontekstda** uchraydigan so'zlar —
o'xshash ma'noga ega.

choy, kofe ko'pincha bir xil so'zlar bilan keladi:
“*issiq* ____ *ichdim*” $\Rightarrow$ vektorlari yaqin bo'lishi
kerak.

Soʻz embeddingi: rasmiy taʼrif

Embedding — lugʻatdagi har bir soʻzni d oʻlchamli zich haqiqiy vektorga akslantiruvchi funksiya:

$$E : V \longrightarrow \mathbb{R}^d, \quad d \ll |V|$$

Oʻxshash maʼnoli soʻzlar fazoda **yaqin** joylashadi.

bunda: V = lugʻat; $|V|$ = lugʻat hajmi (masalan 50 000); d = embedding oʻlchami (masalan 100–300); $E(w) \in \mathbb{R}^d = w$ soʻzining vektori

- One-hot: $d = |V|$, faqat bitta 1 — maʼno **yoʻq**.
- Embedding: d kichik, zich — maʼno vektor **yoʻnalishida**.
- Vektorlar matndan **oʻrganiladi** (Word2Vec, GloVe — L6, GloVe maqolasi).

Nega one-hot vektorlar ma'noni ushlay olmaydi?

1-qadam. Ikki har xil so'zning one-hot vektorlari:

$$\text{qiziq} \rightarrow \mathbf{u} = (1, 0, 0, \dots), \quad \text{qiziqarli} \rightarrow \mathbf{v} = (0, 1, 0, \dots)$$

Nega one-hot vektorlar ma'noni ushlay olmaydi?

1-qadam. Ikki har xil so'zning one-hot vektorlari:

$$\text{qiziq} \rightarrow \mathbf{u} = (1, 0, 0, \dots), \quad \text{qiziqarli} \rightarrow \mathbf{v} = (0, 1, 0, \dots)$$

2-qadam. Skalyar ko'paytmasini hisoblaymiz:

$$\mathbf{u} \cdot \mathbf{v} = 1 \cdot 0 + 0 \cdot 1 + \dots = 0 \quad (\text{umumiy "faol" o'lcham yo'q})$$

Nega one-hot vektorlar ma'noni ushlay olmaydi?

1-qadam. Ikki har xil so'zning one-hot vektorlari:

$$\text{qiziq} \rightarrow \mathbf{u} = (1, 0, 0, \dots), \quad \text{qiziqarli} \rightarrow \mathbf{v} = (0, 1, 0, \dots)$$

2-qadam. Skalyar ko'paytmasini hisoblaymiz:

$$\mathbf{u} \cdot \mathbf{v} = 1 \cdot 0 + 0 \cdot 1 + \dots = 0 \quad (\text{umumiy "faol" o'lcham yo'q})$$

3-qadam. Demak **istalgan** ikki har xil so'z uchun o'xshashlik $= 0$ — ma'no qanchalik yaqin bo'lishidan qat'i nazar.

Xulosa: one-hot fazosida “yaqinlik” tushunchasi yo'q. Embedding aynan shu bo'shliqni to'ldiradi — vektorlarni ma'noga qarab **bir-biriga yaqinlashtiradi**. Endi “yaqinlik”ni qanday **o'lchashni** ko'ramiz (2-tsikl).

Qo'lda misol: bir xil so'zlar, ikki xil ifoda

One-hot (siyrak):

qiziq $\rightarrow \mathbf{u} = (1, 0)$

qiziqarli $\rightarrow \mathbf{v} = (0, 1)$

$$\mathbf{u} \cdot \mathbf{v} = 1 \cdot 0 + 0 \cdot 1 = 0$$

Vektorlar **perpendikular** — umuman bog'lanmagan.

Zich (o'rgangan embedding):

qiziq $\rightarrow \mathbf{a} = (0.9, 0.4)$

qiziqarli $\rightarrow \mathbf{b} = (0.8, 0.5)$

$$\mathbf{a} \cdot \mathbf{b} = 0.72 + 0.20 = \mathbf{0.92}$$

Vektorlar **deyarli bir yo'nalishda** — ma'nosi yaqin.

Muhim kuzatuv

Bir xil ikki so'z: one-hot da o'xshashlik 0, zich embeddingda yuqori. Yo'nalishni **sonli** o'lchash uchun — keyingi tsiklda kosinus o'xshashligi.

Sizning vazifangiz: qaysi juft yaqinroq?

Savol — 60 soniya

Distributiv gipotezaga ko'ra, embedding fazosida qaysi juft so'z bir-biriga **yaqinroq** bo'lishi kerak?

(a) (avtomobil, mashina) (b) (avtomobil, banan)

Qarorni qanday asoslaysiz?

Sizning vazifangiz: qaysi juft yaqinroq?

Savol — 60 soniya

Distributiv gipotezaga ko'ra, embedding fazosida qaysi juft so'z bir-biriga **yaqinroq** bo'lishi kerak?

- (a) (avtomobil, mashina) (b) (avtomobil, banan)

Qarorni qanday asoslaysiz?

Javob

(a) (avtomobil, mashina).


Bu ikki so'z bir xil kontekstlarda uchraydi: *“yangi ____ sotib oldim”, “____ ni haydadi”*. Kontekstlari o'xshash $\Rightarrow$ vektorlari yaqin.

banan esa butunlay boshqa kontekstda (*“meva”, “yedim”*) $\Rightarrow$ uzoq vektor.

Prezentatsiya rejasi

- 1 Kirish: TF-IDF dan embeddinggacha
- 2 Zich vektorlar: so'z embeddinglari
- 3 Kosinus o'xshashligi**
- 4 So'z analogiyalari va semantik munosabatlar
- 5 PCA bilan vizualizatsiya
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: o'xshashlik — bu vektorlar orasidagi burchak



Asosiy g'oya (so'z bilan):

- Har so'z (yoki hujjat) — fazodagi **vektor**
- O'xshashlik = vektorlar orasidagi **burchak**
- Burchak kichik $\Rightarrow$ ma'no yaqin
- Burchak $90^\circ \Rightarrow$ bog'lanmagan

Nega burchak, uzunlik emas? Uzun hujjat ham, qisqasi ham bir mavzuda bo'lishi mumkin — burchak buni adolatli o'lchaydi.

Kosinus o'xshashligi: rasmiy ta'rif

$$\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|} = \frac{\sum_{i=1}^n a_i b_i}{\sqrt{\sum_{i=1}^n a_i^2} \sqrt{\sum_{i=1}^n b_i^2}}$$

bunda: $\mathbf{a}, \mathbf{b} \in \mathbb{R}^n$ — vektorlar (TF-IDF yoki embedding); n — o'lcham; $\mathbf{a} \cdot \mathbf{b}$ — skalyar ko'paytma; $\|\cdot\|$ — Evklid normasi (uzunlik).

- Qiymatlar oralig'i: $[-1, 1]$; TF-IDF manfiy emas $\Rightarrow$ amalda $[0, 1]$.
- $\cos = 1$: bir xil yo'nalish; $\cos = 0$: umumiy o'lcham yo'q.

Keltirib chiqarish: nega normaga bo'lamiz?

1-qadam. Skalyar ko'paytmaning geometrik ta'rifi:

$$\mathbf{a} \cdot \mathbf{b} = \|\mathbf{a}\| \|\mathbf{b}\| \cos \theta \quad (\text{chiziqli algebradan})$$

Keltirib chiqarish: nega normaga bo'lamiz?

1-qadam. Skalyar ko'paytmaning geometrik ta'rifi:

$$\mathbf{a} \cdot \mathbf{b} = \|\mathbf{a}\| \|\mathbf{b}\| \cos \theta \quad (\text{chiziqli algebradan})$$

2-qadam. Bizga kerak bo'lgan $\cos \theta$ ni ajratamiz:

$$\cos \theta = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|} \quad (\text{ikkala tomonni normalarga bo'ldik})$$

Keltirib chiqarish: nega normaga bo'lamiz?

1-qadam. Skalyar ko'paytmaning geometrik ta'rif:

$$\mathbf{a} \cdot \mathbf{b} = \|\mathbf{a}\| \|\mathbf{b}\| \cos \theta \quad (\text{chiziqli algebradan})$$

2-qadam. Bizga kerak bo'lgan $\cos \theta$ ni ajratamiz:

$$\cos \theta = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|} \quad (\text{ikkala tomonni normalarga bo'ldik})$$

3-qadam. Vektorni ikki marta uzaytirsak ($\mathbf{a}' = 2\mathbf{a}$):

$$\cos(\mathbf{a}', \mathbf{b}) = \frac{2(\mathbf{a} \cdot \mathbf{b})}{2\|\mathbf{a}\| \|\mathbf{b}\|} = \cos(\mathbf{a}, \mathbf{b})$$

Xulosa: kosinus uzunlikka **bog'liq emas** — faqat yo'nalishni o'lchaydi. Aynan shuning uchun matn va NLP da standart o'xshashlik o'lchovi.

Qo'lda hisob: ikki vektorning kosinus o'xshashligi

H_1 : "nlp juda qiziq" $\rightarrow \mathbf{a} = (1, 1, 1, 0)$ H_2 : "nlp juda foydali" $\rightarrow \mathbf{b} = (1, 1, 0, 1)$

Lug'at tartibi: (nlp, juda, qiziq, foydali)

Hisoblaymiz:

$$\mathbf{a} \cdot \mathbf{b} = 1 \cdot 1 + 1 \cdot 1 + 1 \cdot 0 + 0 \cdot 1 = 2$$

$$\|\mathbf{a}\| = \sqrt{1 + 1 + 1 + 0} = \sqrt{3}$$

$$\|\mathbf{b}\| = \sqrt{1 + 1 + 0 + 1} = \sqrt{3}$$

Natija:

$$\cos = \frac{2}{\sqrt{3}\sqrt{3}} = \frac{2}{3} \approx \mathbf{0.667}$$

4 so'zdan 2 tasi (nlp, juda) mos — intuitsiya bilan ham $\approx 2/3$ chiqishi tabiiy.

Ertangi P3 birinchi assert:

`abs(cos_val - 0.667) < 1e-3`

Ma'ruza L3 [I2]-slayd

Sizning vazifangiz: kosinusni hisoblang

Savol — 2 daqiqa

H_1 : "nlp juda qiziq" $\rightarrow \mathbf{a} = (1, 1, 1, 0, 0, 0)$

H_3 : "python juda qulay" $\rightarrow \mathbf{c} = (0, 1, 0, 0, 1, 1)$

Lug'at: (nlp, juda, qiziq, foydali, python, qulay)

$\cos(\mathbf{a}, \mathbf{c})$ ni hisoblang.

Sizning vazifangiz: kosinusni hisoblang

Savol — 2 daqiqa

H_1 : "nlp juda qiziq" $\rightarrow \mathbf{a} = (1, 1, 1, 0, 0, 0)$

H_3 : "python juda qulay" $\rightarrow \mathbf{c} = (0, 1, 0, 0, 1, 1)$

Lug'at: (nlp, juda, qiziq, foydali, python, qulay)

$\cos(\mathbf{a}, \mathbf{c})$ ni hisoblang.

Javob

$\mathbf{a} \cdot \mathbf{c} = 1$ (faqat juda mos); $\|\mathbf{a}\| = \|\mathbf{c}\| = \sqrt{3}$

$$\cos = \frac{1}{\sqrt{3}\sqrt{3}} = \frac{1}{3} \approx \mathbf{0.333}$$

H_1 va H_3 faqat "juda" da mos — mavzu boshqa (nlp vs python) $\Rightarrow$ past o'xshashlik.

Kod $\leftrightarrow$ formula: har qator formulaning qaysi qismi?

```
1 import numpy as np
2 from sklearn.metrics.pairwise \
3     import cosine_similarity
4
5 a = np.array([[1, 1, 1, 0]])
6 b = np.array([[1, 1, 0, 1]])
7
8 # (1) skalyar ko'paytma
9 skalyar = (a * b).sum()           # 2
10 # (2) normalar
11 na = np.linalg.norm(a)           # 1.732
12 nb = np.linalg.norm(b)           # 1.732
13 # (3) kosinus = (1) / (2)
14 print(skalyar / (na * nb))       # 0.667
15
16 # bitta qatorda:
17 print(cosine_similarity(a, b))
```

Moslik jadvali:

Kod	Formula
<code>(a*b).sum()</code>	$\sum_i a_i b_i$
<code>norm(a)</code>	$\ a\ $
<code>skalyar/(na*nb)</code>	$\cos(a, b)$

Ertangi P3 da xuddi shu hisob **haqiqiy embedding vektorlarda** bajariladi — bugungi 2/3 uning birlik testi (sanity check) bo'ladi.

Kosinus tuzog'i: 1D massiv cosine_similarity ni sindiradi

Haqiqiy xato — tez-tez uchraydi

cosine_similarity **2D** massiv kutadi ((namuna, o'lcham) shaklida). 1D bersak — xato.

Embedding vektori odatda 1D (shape=(100,)) bo'lib keladi — shuning uchun bu xato amaliyotda ko'p uchraydi.


```
a = np.array([1, 1, 1, 0])
cosine_similarity(a, b)
# XATO: Expected 2D array!

# To'g'ri: (1, n) shaklga keltiring
cosine_similarity(
    a.reshape(1, -1),
    b.reshape(1, -1))
```

Prezentatsiya rejasi

- 1 Kirish: TF-IDF dan embeddinggacha
- 2 Zich vektorlar: so'z embeddinglari
- 3 Kosinus o'xshashligi
- 4 So'z analogiyalari va semantik munosabatlar**
- 5 PCA bilan vizualizatsiya
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: ma'no farqi — vektorlar orasidagi yo'nalish



Asosiy g'oya:

Bir xil **munosabat** — bir xil **yo'nalish** vektori.

$qirol - erkak \approx malika - ayol$

Mashhur misol (ingliz):

$king - man + woman \approx queen.$

Embedding fazosi semantik munosabatlarni **geometrik** saqlaydi.

So'z analogiyasi: rasmiy ta'rif

“ a ga b qanday bo'lsa, c ga **nima** shunday” savoliga javob vektor:

$$\mathbf{t} = \mathbf{b} - \mathbf{a} + \mathbf{c}, \quad \hat{d} = \arg \max_{w \in V \setminus \{a, b, c\}} \cos(E(w), \mathbf{t})$$

bunda: $\mathbf{a} = E(a)$, $\mathbf{b} = E(b)$, $\mathbf{c} = E(c)$ — so'z vektorlari; $\mathbf{t}$ — maqsad vektor; $\hat{d}$ — $\mathbf{t}$ ga kosinus bo'yicha eng yaqin so'z.

- $\mathbf{b} - \mathbf{a}$ — “ a dan b ga” munosabat yo'nalishi.
- Uni $\mathbf{c}$ ga qo'shamiz $\Rightarrow$ kerakli mintaqaga boramiz.
- Eng yaqin so'zni **kosinus** bilan topamiz (2-tsikl ishlaydi!).

Analogiyani qadamma-qadam yechamiz

Savol: uzbekiston : toshkent :: rossiya : ? (poytaxt munosabati)

1-qadam. Munosabat yo'nalishini topamiz:

$$\mathbf{b} - \mathbf{a} = E(\text{toshkent}) - E(\text{uzbekiston}) \quad (\text{"davlat} \rightarrow \text{poytaxt"} \text{ yo'nalishi})$$

Analogiyani qadamma-qadam yechamiz

Savol: uzbekiston : toshkent :: rossiya : ? (poytaxt munosabati)

1-qadam. Munosabat yo'nalishini topamiz:

$$\mathbf{b} - \mathbf{a} = E(\text{toshkent}) - E(\text{uzbekiston}) \quad (\text{"davlat} \rightarrow \text{poytaxt"} \text{ yo'nalishi})$$

2-qadam. Uni yangi davlatga qo'llaymiz:

$$\mathbf{t} = \mathbf{b} - \mathbf{a} + \mathbf{c} = E(\text{toshkent}) - E(\text{uzbekiston}) + E(\text{rossiya})$$

Analogiyani qadamma-qadam yechamiz

Savol: uzbekiston : toshkent :: rossiya : ? (poytaxt munosabati)

1-qadam. Munosabat yo'nalishini topamiz:

$$\mathbf{b} - \mathbf{a} = E(\text{toashkent}) - E(\text{uzbekiston}) \quad (\text{"davlat} \rightarrow \text{poytaxt"} \text{ yo'nalishi})$$

2-qadam. Uni yangi davlatga qo'llaymiz:

$$\mathbf{t} = \mathbf{b} - \mathbf{a} + \mathbf{c} = E(\text{toashkent}) - E(\text{uzbekiston}) + E(\text{rossiya})$$

3-qadam. $\mathbf{t}$ ga eng yaqin so'zni qidiramiz:

$$\hat{d} = \arg \max_w \cos(E(w), \mathbf{t}) = \text{moskva}$$

Embedding "poytaxt" munosabatini hech kim aytmadan, faqat matndan o'rgangan — bu distributiv gipotezaning kuchli isboti.

Qo'lda hisob: analogiyani 2D vektorlarda yechamiz

$E(\text{uzbekiston}) = (2, 0)$, $E(\text{toshkent}) = (3, 1)$, $E(\text{rossiya}) = (6, 0)$

Nomzodlar: $E(\text{moskva}) = (7, 1)$, $E(\text{parij}) = (9, 5)$

Maqsad vektor:

$$\begin{aligned}\mathbf{t} &= \mathbf{b} - \mathbf{a} + \mathbf{c} \\ &= (3, 1) - (2, 0) + (6, 0) \\ &= (7, 1)\end{aligned}$$

Eng yaqinini topamiz:

$\mathbf{t} = (7, 1)$ ga:
moskva = $(7, 1)$ — aynan mos!
parij = $(9, 5)$ — uzoq.
 $\Rightarrow \hat{d} = \text{moskva}$

Javob

uzbekiston : toshkent :: rossiya : moskva — poytaxt munosabati vektor arifmetikasi bilan topildi.

Sizning vazifangiz: analogiyani yeching

Savol — 2 daqiqa

$E(\text{erkak}) = (1, 1)$, $E(\text{qirol}) = (3, 2)$, $E(\text{ayol}) = (1, 3)$

Nomzodlar: $E(\text{malika}) = (3, 4)$, $E(\text{dehqon}) = (2, 1)$

erkak : qirol :: ayol : ?

Sizning vazifangiz: analogiyani yeching

Savol — 2 daqiqa

$E(\text{erkak}) = (1, 1)$, $E(\text{qirol}) = (3, 2)$, $E(\text{ayol}) = (1, 3)$

Nomzodlar: $E(\text{malika}) = (3, 4)$, $E(\text{dehqon}) = (2, 1)$

erkak : qirol :: ayol : ?

Javob

$\mathbf{t} = \mathbf{b} - \mathbf{a} + \mathbf{c} = (3, 2) - (1, 1) + (1, 3) = (3, 4)$

$\mathbf{t} = (3, 4)$ ga eng yaqin: malika = (3, 4) (aynan mos) $\gg$ dehqon = (2, 1).

$\Rightarrow$ **erkak : qirol :: ayol : malika.**

Kod $\leftrightarrow$ formula: most_similar va analogiya

```
1 from gensim.models import KeyedVectors
2
3 vv = KeyedVectors.load("cc_uz_100k.kv")
4
5 # Eng o'xshash so'zlar (kosinus bilan)
6 vv.most_similar("toshkent", topn=3)
7
8 # Analogiya: b - a + c
9 # uzbekiston:toshkent :: rossiya:?
10 vv.most_similar(
11     positive=["toshkent", "rossiya"],
12     negative=["uzbekiston"],
13     topn=1)
14 # -> [("moskva", 0.78)]
```

Argument $\rightarrow$ formula:

Kod	Formula
positive=[c, b]	$+c + b$
negative=[a]	$-a$
most_similar	$\arg \max \cos$

Eslatma

positive = qo'shiladigan, negative = ayriladigan vektorlar. P3 da aynan shu API ishlatiladi.

Prezentatsiya rejasi

- 1 Kirish: TF-IDF dan embeddinggacha
- 2 Zich vektorlar: so'z embeddinglari
- 3 Kosinus o'xshashligi
- 4 So'z analogiyalari va semantik munosabatlar
- 5 PCA bilan vizualizatsiya**
- 6 Xulosa va amaliyotga ko'prik


Intuitsiya: 300 o'lchamli fazoni qanday "ko'ramiz"?

Muammo:

Embedding 100–300 o'lchamli.
Inson faqat 2–3 o'lchamni ko'radi.

Yechim — PCA:

Yuqori o'lchamli nuqtalarni eng ko'p **tarqalish**
(varianta) saqlanadigan 2 o'lchamga **proyeksiya**
qiladi.



Semantik klasterlar 2D da ko'rinadi — o'xshash
so'zlar guruhlanadi.

PCA: asosiy komponentlar tahlili (nazariy ta'rif)

PCA — ma'lumotni **eng katta varianta** yo'nalishlari bo'ylab yangi o'qlarga (asosiy komponentlarga) burib, faqat birinchi k o'qni saqlaydigan o'lcham qisqartirish usuli.

bunda: markazlashtirilgan ma'lumot X ; kovariatsiya matritsasi $C = \frac{1}{n}X^T X$; asosiy komponentlar — C ning eng katta xos qiymatlariga mos xos vektorlari; k — saqlanadigan o'lcham (bizda 2).

- PC1 — varianta eng katta bo'lgan yo'nalish.
- PC2 — PC1 ga perpendikular, qolgan eng katta varianta.
- `explained_variance_ratio_` — har komponent qancha “ma'lumot” saqlaganini ko'rsatadi.

Qo'lda misol: qaysi o'q ko'proq ma'lumot saqlaydi?

$$w_1 = (2, 0.1), \quad w_2 = (-2, -0.1), \quad w_3 = (0, 0)$$

Har o'q bo'ylab tarqalish:

$$\text{Var}(x) \propto 2^2 + (-2)^2 + 0^2 = 8$$

$$\text{Var}(y) \propto 0.1^2 + 0.1^2 + 0^2 = 0.02$$

x o'qida tarqalish ≈ 400 marta katta.

Xulosa:

PC1 $\approx x$ o'qi (deyarli barcha variant).

2D $\rightarrow$ 1D: faqat x ni saqlaymiz:

$w_1 \rightarrow 2, w_2 \rightarrow -2, w_3 \rightarrow 0$.

Nuqtalar farqi **saqlanib qoldi**, y deyarli yo'qotilmadi.

PCA aynan shuni avtomatik qiladi: kam ma'lumotli o'qni tashlab, ko'p ma'lumotli o'qni saqlaydi. Bu yerda $\text{explained_variance} \approx 8/8.02 \approx 99.8\%$.

Sizning vazifangiz: PCA nimani saqlaydi, nimani yo'qotadi?

Savol — 90 soniya

300 o'lchamli o'zbek embeddinglari PCA bilan 2 o'lchamga tushirildi va `explained_variance_ratio_ = [0.31, 0.18]` chiqdi.

- (a) Vizualizatsiya ma'lumotning qancha qismini saqladi?
- (b) Ikki so'z 2D rasmda yaqin ko'rinsa, ular embedding fazosida ham yaqinligi **kafolatlanadimi?**

Sizning vazifangiz: PCA nimani saqlaydi, nimani yo'qotadi?

Savol — 90 soniya

300 o'lchamli o'zbek embeddinglari PCA bilan 2 o'lchamga tushirildi va `explained_variance_ratio_ = [0.31, 0.18]` chiqdi.

- (a) Vizualizatsiya ma'lumotning qancha qismini saqladi?
- (b) Ikki so'z 2D rasmda yaqin ko'rinsa, ular embedding fazosida ham yaqinligi **kafolatlanadimi?**

Javob

- (a) Atigi $0.31 + 0.18 = \mathbf{0.49}$ — ya'ni $\approx 49\%$. Qolgan 51% tarqalish (nozik farqlar) **yo'qoladi**.
- (b) **Yo'q.** 2D yaqinlik — taxminiy. To'liq fazoda uzoq so'zlar proyeksiyada tasodifan yaqin tushishi mumkin. Aniq qaror uchun **to'liq vektorda** kosinusni hisoblang.

Kod ↔ formula: PCA bilan 2D vizualizatsiya

```
from sklearn.decomposition import PCA
import matplotlib.pyplot as plt

# X: (so'zlar_soni, 100) embedding matritsa
pca = PCA(n_components=2) # k = 2
xy = pca.fit_transform(X) # -> (N, 2)

plt.scatter(xy[:, 0], xy[:, 1])
for i, soz in enumerate(sozlar):
    plt.annotate(soz, xy[i])

print(pca.explained_variance_ratio_)
# -> [0.41, 0.22] (jami ~63%)
```

Kod → tushuncha:

Kod	Ma'no
n_components=2	k = 2 o'q
fit_transform	proyeksiya
variance_ratio	saqlangan ulush

Eslatma

2 komponent ko'pincha ma'lumotning atigi yarmini saqlaydi — vizualizatsiya **taxminiy**, isbot emas.

Prezentatsiya rejasi

- 1 Kirish: TF-IDF dan embeddinggacha
- 2 Zich vektorlar: so'z embeddinglari
- 3 Kosinus o'xshashligi
- 4 So'z analogiyalari va semantik munosabatlar
- 5 PCA bilan vizualizatsiya
- 6 Xulosa va amaliyotga ko'prik

Tayyor embeddinglar o'zbek tili uchun cheklangan qamrovga ega

Asosiy muammo:

Mashhur GloVe / Word2Vec vektorlari asosan **ingliz** korpusida o'qitilgan.

O'zbek so'zlarining ko'pi ularda **umuman yo'q** (OOV — out of vocabulary).

Agglutinatsiya buni kuchaytiradi:
kitob, kitoblar, kitobimizdan — **har biri**
alohida (yoki yo'q) vektor.

OOV ta'siri

OOV so'z → vektor yo'q → o'xshashlik hisoblanmaydi. Ertaga P3 da `oov_rate()` ni o'lchaysiz — o'zbek korpusida u yuqori chiqadi.

Yechimlar:

- O'zbek korpusida **noldan** o'qitish (L6, P6).
- Stemming bilan shakllarni birlashtirish (m01).
- Subword (FastText / BPE) — OOV ni kamaytiradi (4-hafta).

Qachon nima ishlatamiz? Siyrak va zich vektorlar taqqoslovi

Mezon	Siyrak (TF-IDF / BoW)	Zich (embedding)
O'lcham	$ V $ (katta)	$d = 100-300$ (kichik)
Ma'no	Ushlamaydi	Ushlaydi (yaqinlik)
Sinonim	Begona ($\cos = 0$)	Yaqin vektor
OOV (yangi so'z)	0-ustun (xavfsiz)	Vektor yo'q (muammo)
Talqin qilish	Oson (so'z = o'lcham)	Qiyin (yashirin o'lcham)
O'zbek uchun	Stemming kerak	Korpus + qamrov muhim
Qachon	Klassik ML, kichik data	Semantik qidiruv, neyron model

Amaliy qoida

Kichik, oddiy vazifa $\Rightarrow$ TF-IDF bilan boshlang. Ma'no, o'xshashlik, semantik qidiruv kerak bo'lsa $\Rightarrow$ embedding. Ikkalasida ham kosinus o'xshashlik o'lchovi ishlaydi.

Seminal maqola: GloVe (Pennington va b., 2014)

Pennington, J., Socher, R., Manning, C.D. (2014). **GloVe: Global Vectors for Word Representation**. *EMNLP 2014*.

Maqola haqida:

- So'zlarning **global** birga-uchrash (co-occurrence) statistikasidan zich vektor o'rganadi.
- Word2Vec lokal oynadan, GloVe esa butun matritsadan o'rganadi.
- Analogiya vazifalarida ($\text{king} - \text{man} + \text{woman}$) kuchli natija.
- Bugungi BERT, GPT ham "embedding" g'oyasiga tayanadi.


Muhokama savoli (P3 gacha o'ylang)

Ingliz korpusida o'qitilgan GloVe o'zbek so'zlari uchun deyarli foydasiz. Kam-resursli o'zbek tili uchun **qaysi** afzal: tayyor inglizcha vektorni moslashtirishmi yoki o'zbek korpusida noldan o'qitishmi? Nega?

Bugungi maqsadlar bajarildi

- 1 ✓ **Keltirib chiqardik:** distributiv gipotezadan zich vektor (embedding) g'oyasini — one-hot o'xshashligi nega har doim 0.
- 2 ✓ **Hisobladik:** ikki vektorning kosinus o'xshashligi — $\cos(\mathbf{a}, \mathbf{b}) = 2/3 \approx 0.667$ ([I2]-slayd).
- 3 ✓ **Yechdik:** vektor arifmetikasi bilan analogiya — `uzbekiston:toshkent :: rossiya:moskva`.
- 4 ✓ **Kodda bog'ladik:** `cosine_similarity`, `most_similar` va PCA chaqiriqlarini formulaga moslashtirdik.

Ertaga P3: tayyor embeddinglar bilan ishlaysiz



P3 da qurasiz:

- KeyedVectors bilan .kv yuklash
- most_similar, analogiya yechish
- oov_rate() — o'zbek qamrovi
- PCA bilan semantik klasterlarni chizish
- m03_pretrained_embedder.py saqlash

Birinchi assert (bu slayd [I2]):

```
assert abs(cos_val - 0.667) < 1e-3
```

*# Ma'ruza L3 [I2]-slayd bilan
solishtiring*

Tayyorlab keling: Kaggle hisobi ishlashini tekshiring; muhokama savoliga [O] javob.

- ❶ Pennington, J., Socher, R., Manning, C.D. (2014). *GloVe: Global Vectors for Word Representation*. EMNLP 2014.
- ❷ Mikolov, T. va b. (2013). *Efficient Estimation of Word Representations in Vector Space*. ICLR 2013. (Word2Vec — L6 da batafsil.)
- ❸ Jurafsky, D., Martin, J.H. (2023). *Speech and Language Processing*, 3-nashr (online). 6-bob: Vector Semantics and Embeddings.
- ❹ Firth, J.R. (1957). *A Synopsis of Linguistic Theory*. (Distributiv gipoteza manbasi.)
- ❺ Scikit-learn hujjatlari: `cosine_similarity`, PCA — scikit-learn.org.

Ilova S1: kosinus va Evklid masofa bog'liqligi

L_2 -normallashtirilgan vektorlar uchun ($\|\mathbf{a}\| = \|\mathbf{b}\| = 1$):

$$\|\mathbf{a} - \mathbf{b}\|^2 = \|\mathbf{a}\|^2 + \|\mathbf{b}\|^2 - 2\mathbf{a} \cdot \mathbf{b} = 2 - 2\cos(\mathbf{a}, \mathbf{b})$$

bunda: $\|\mathbf{a}\| = \|\mathbf{b}\| = 1$ deb olindi.

Demak normallashtirilgan fazoda Evklid masofasi va kosinus **ekvivalent tartib** beradi — shuning uchun ko'p kutubxonalar ikkalasini almashtirib ishlatadi. Bu LSH va qidiruvda muhim (L4, P4).

Ilova S2: vektor, norma va skalyar ko'paytma eslatmasi

Skalyar ko'paytma: $\mathbf{a} \cdot \mathbf{b} = \sum_i a_i b_i$

Evklid normasi (uzunlik): $\|\mathbf{a}\| = \sqrt{\sum_i a_i^2}$

Perpendikular vektorlar: $\mathbf{a} \cdot \mathbf{b} = 0$

Misol: $\mathbf{a} = (3, 4)$ uchun $\|\mathbf{a}\| = \sqrt{9 + 16} = \sqrt{25} = 5$.

Python da: `import numpy as np; np.linalg.norm([3,4]) → 5.0; np.dot(a, b)` — skalyar ko'paytma.

Ilova S3: PCA matematik asoslari

- 1 Ma'lumotni markazlashtiring: har ustundan o'rtachani ayiring.
- 2 Kovariatsiya matritsasi: $C = \frac{1}{n}X^T X$.
- 3 C ning xos qiymat va xos vektorlarini toping.
- 4 Eng katta k xos qiymatga mos xos vektorlarni tanlang — bular asosiy komponentlar.
- 5 Ma'lumotni shu k vektorga proyeksiya qiling.

`explained_variance_ratio_[i]` = $\lambda_i / \sum_j \lambda_j$, bunda λ_i — i -xos qiymat. Bu kursda PCA ni `sklearn` amalga oshiradi — qo'lda xos qiymat hisoblanmaydi.