

Masofaga asoslangan qidiruv va imlo tuzatish

Tabiiy tilni qayta ishlash — 4-ma'ruza

A.A. Abdulali

11:00–12:20 · mavzu №4

19-iyun 2026

- 1 Kirish: o'xshashlikdan qidiruv va tuzatishgacha
- 2 Tez o'xshashlik qidiruvi: LSH
- 3 Imlo tuzatish: noisy channel modeli
- 4 Tahrir masofasi: Levenshtein va DP
- 5 Avtomatik tuzatish tizimi
- 6 Xulosa va amaliyotga ko'prik

Takrorlash: o'xshashlikni qanday o'lchagandik?

1-savol

L3 da ikki vektor (yoki so'z) o'xshashligini qaysi o'lchov bilan baholadik?

Qiyamat oralig'i qanday edi?

2-savol

Bugun ertalab P3 da `most_similar` eng o'xshash so'zni topdi. U **nechta** so'z bilan solishtirdi?

Takrorlash: o'xshashlikni qanday o'lchagandik?

1-savol

L3 da ikki vektor (yoki so'z) o'xshashligini qaysi o'lchov bilan baholadik?
Qiyamat oralig'i qanday edi?

2-savol

Bugun ertalab P3 da `most_similar` eng o'xshash so'zni topdi. U **nechta** so'z bilan solishtirdi?

1-javob

Kosinus o'xshashligi, oralig'i $[0, 1]$ (TF-IDF/embedding uchun).

2-javob

Hammasi bilan! Lug'atdagi har bir so'z bilan — ya'ni $O(N)$.
Millionlab hujjatda bu sekin. Bugun tezlatamiz.

Siz bugungi dars oxirida quyidagilarni bajara olasiz:

- ➊ **Keltirib chiqara olasiz:** tahrir masofasi (Levenshtein) dinamik dasturlash rekurrensiyasini va MinHash–Jaccard bog'lanishini.
- ➋ **Qo'lda hisoblay olasiz:** kichik so'zlar uchun tahrir masofasini DP jadvali bilan ($\text{edit}(\text{qo}'1, \text{ko}'1) = 1$).
- ➌ **Qo'llay olasiz:** noisy channel modeli — $\arg \max_w P(x|w)P(w)$ bilan eng ehtimoliy tuzatishni topish.
- ➍ **Taqqoslay olasiz:** aniq qidiruv (k-NN) va taxminiy qidiruv (LSH) — qachon qaysi biri.

L1 dan: tokenizatsiya, apostrof muammosi. L2 dan: ehtimollik, $\arg \max$. L3 dan: o'xshashlik tushunchasi.
Matematikadan: matritsa, minimum, to'plam amallari.

Bugungi dars rejasi:

Blok	Mavzu	Vaqt	Hosil natija	bo'luvchi
1	Tez o'xshashlik qidiruvi: KNN, LSH	18 daq	Jaccard, LSH	MinHash,
2	Imlo tuzatish: noisy channel	16 daq	$\arg \max P(x w)P(w)$	
3	Tahrir masofasi (Levenshtein) + DP	24 daq	Qo'lda hisoblangan DP jadval	
4	Avtomatik tuzatish tizimi	12 daq	To'liq tuzatish quvuri	
	Xulosa va 4-amaliyotga ko'rsatmalar	10 daq	Ertaga nima qurishin-giz	

Bu dars 1-haftaning yakuni

Tozalash (m01) $\rightarrow$ tasniflash (m02) $\rightarrow$ embedding (m03) $\rightarrow$ **qidiruv va tuzatish (m04)**. Bugungi $\text{edit}(\text{qo}'1, \text{ko}'1) = 1$ ertangi amaliyotda assert bo'ladi.

Bugungi dars uchun muammo: foydalanuvchi “telfon” deb yozsa, aniq moslik topilmaydi

Ikki real muammo:

1. Imlo xatosi

Qidiruvda "telfon" yozildi.
Lug'atda "telefon" bor.
Aniq (exact) moslik $\Rightarrow$ **0 natija**.
Qaysi so'z nazarda tutilgan?

2. Sekin qidiruv

Million hujjat orasidan eng o'xshashini topish:
har biriga kosinus $\Rightarrow O(N)$, juda sekin.

Bugungi yechimlar:

- 1 **Tahrir masofasi + noisy channel**: eng ehtimoliy to'g'ri so'zni topadi.
- 2 **LSH**: o'xshash hujjatlarni bir “savat”ga tushiradi $\Rightarrow$ qidiruv tez.

Ikkalasi ham **taxminiy** (approximate) usullar
— aniqlikni tezlik va moslashuvchanlikka almashtiradi.

Prezentatsiya rejasi

- 1 Kirish: o'xshashlikdan qidiruv va tuzatishgacha
- 2 Tez o'xshashlik qidiruvi: LSH**
- 3 Imlo tuzatish: noisy channel modeli
- 4 Tahrir masofasi: Levenshtein va DP
- 5 Avtomatik tuzatish tizimi
- 6 Xulosa va amaliyotga ko'prik


Intuitsiya: o'xshashlarni avval “savatlarga” ajratamiz

Aniq qidiruv (k-NN):

So'rovni **barcha** N hujjat bilan solishtiramiz
 $\Rightarrow O(N)$. 1 000 hujjatda — mayli; million hujjatda — sekin.

LSH g'oyasi:

O'xshash hujjatlar **katta ehtimol bilan** bir xil “savat” (bucket) ga tushadigan xesh quramiz.
So'rov uchun faqat **o'sha savatni** tekshiramiz.



Solishtirishlar soni $O(N)$ dan savat hajmiga tushadi — amalda subchiziqli (sublinear).

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} \in [0, 1]$$

bunda: A, B — hujjatning *shingle* (so'z yoki k -belgi bo'laklari) to'plamlari; $|A \cap B|$ — umumiy bo'laklar soni; $|A \cup B|$ — jami noyob bo'laklar.

- **MinHash:** tasodifiy permutatsiya bo'yicha minimal element — $P[\text{minhash}(A) = \text{minhash}(B)] = J(A, B)$.
- **LSH:** MinHash imzosini b “band”ga bo'lib, har bandni savatga xeshlaymiz; bitta bandda mos kelsa — nomzod.
- Natija: Jaccard yuqori juftlar bir savatga tushish ehtimoli yuqori.

Keltirib chiqarish: nega MinHash to'qnashuvi = Jaccard?

1-qadam. Tasodifiy permutatsiya π ni olamiz; $h_\pi(A)$ — A ning π bo'yicha **eng kichik** elementi.

Keltirib chiqarish: nega MinHash to'qnashuvi = Jaccard?

1-qadam. Tasodifiy permutatsiya π ni olamiz; $h_\pi(A)$ — A ning π bo'yicha **eng kichik** elementi. **2-qadam.** $h_\pi(A) = h_\pi(B)$ qachon? Faqat $A \cup B$ ning π bo'yicha minimal elementi **ikkalasida ham** ($A \cap B$ da) bo'lsa.

Keltirib chiqarish: nega MinHash to'qnashuvi = Jaccard?

1-qadam. Tasodifiy permutatsiya π ni olamiz; $h_\pi(A)$ — A ning π bo'yicha **eng kichik** elementi. **2-qadam.** $h_\pi(A) = h_\pi(B)$ qachon? Faqat $A \cup B$ ning π bo'yicha minimal elementi **ikkalasida ham** ($A \cap B$ da) bo'lsa. **3-qadam.** π tasodifiy bo'lgani uchun $A \cup B$ ning minimal elementi teng ehtimol bilan istalgan element bo'lishi mumkin:

$$P[h_\pi(A) = h_\pi(B)] = \frac{|A \cap B|}{|A \cup B|} = J(A, B)$$

Xulosa: bitta MinHash — Jaccard ning (shovqinli) bahosi. k ta mustaqil permutatsiya ishlatsak, teng MinHash ulushi J ga yaqinlashadi — ko'p permutatsiya, aniqroq baho.

Qo'lda hisob: ikki hujjatning Jaccard o'xshashligi

$$A = \{\text{nlp, juda, qiziq}\} \quad B = \{\text{nlp, juda, foydali}\}$$

Hisoblaymiz:

$$A \cap B = \{\text{nlp, juda}\} \Rightarrow |A \cap B| = 2$$

$$A \cup B = \{\text{nlp, juda, qiziq, foydali}\} \\ \Rightarrow |A \cup B| = 4$$

$$J(A, B) = \frac{2}{4} = \mathbf{0.5}$$

Eslatma: L3 da **aynan shu** ikki hujjat uchun kosinus = $2/3 \approx 0.667$ edi.

Jaccard **to'plam** (bor/yo'q), kosinus esa **chastota** bilan ishlaydi — shuning uchun farq.

Sizning vazifangiz: Jaccard ni hisoblang

Savol — 90 soniya

$A = \{\text{nlp, juda, qiziq}\}$ $C = \{\text{python, juda, qulay}\}$

$J(A, C) = ?$

Sizning vazifangiz: Jaccard ni hisoblang

Savol — 90 soniya

$A = \{\text{nlp, juda, qiziq}\}$ $C = \{\text{python, juda, qulay}\}$

$J(A, C) = ?$

Javob

$A \cap C = \{\text{juda}\} \Rightarrow |A \cap C| = 1$

$A \cup C = \{\text{nlp, juda, qiziq, python, qulay}\} \Rightarrow |A \cup C| = 5$

$J(A, C) = \frac{1}{5} = \mathbf{0.2}$ — faqat “juda” umumiy, mavzu boshqa $\Rightarrow$ past o'xshashlik.

Kod ↔ formula: MinHash va MinHashLSH

```
1 from datasketch import MinHash, MinHashLSH
2
3 def to_minhash(tokens, num_perm=128):
4     m = MinHash(num_perm=num_perm)
5     for t in set(tokens):
6         m.update(t.encode("utf-8"))
7     return m
8
9 lsh = MinHashLSH(threshold=0.5, num_perm=128)
10 lsh.insert("D1", to_minhash(["nlp", "juda", "qiziq"]))
11 lsh.insert("D2", to_minhash(["nlp", "juda", "foydali"]))
12
13 q = to_minhash(["nlp", "juda", "yangi"])
14 print(lsh.query(q))    # -> ['D1', 'D2']
```

Kod → formula:

Kod	Tushuncha
MinHash	imzo $\approx J$
num_perm	permutatsiyalar
threshold	b, r sozlash
query	savatni tekshir

Ertangi P4 da m04 ushbu API bilan LSH indeks quradi.

Asosiy cheklovlar

- **False negative:** o'xshash juft boshqa savatga tushib, topilmay qolishi mumkin.
- **False positive:** o'xshamagan juft bir savatga tushib, ortiqcha tekshiruv qo'shadi.
- b (band) va r (qator) ni sozlash kerak — tezlik va aniqlik orasidagi murosa.

Nomzod bo'lish ehtimoli (S -egri chiziq):

$$P(s) = 1 - (1 - s^r)^b$$


b, r ni shunday tanlaymizki, “chegara” o'xshashlikdan yuqori juftlar deyarli har doim, pastlari deyarli hech qachon nomzod bo'lmaydi.

Batafsil: ilova S2.

Prezentatsiya rejasi

- 1 Kirish: o'xshashlikdan qidiruv va tuzatishgacha
- 2 Tez o'xshashlik qidiruvi: LSH
- 3 Imlo tuzatish: noisy channel modeli**
- 4 Tahrir masofasi: Levenshtein va DP
- 5 Avtomatik tuzatish tizimi
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: imlo xatosi “shovqinli kanal”dan o'tgan so'z



Foydalanuvchi **to'g'ri** so'z w ni o'ylagan, lekin kanal uni **xato** x ga aylantirgan. Biz faqat x ni ko'ramiz va “orqaga” — eng ehtimoliy w ni tiklamoqchimiz.

Bu nutqni aniqlash, tarjima va OCR da ham ishlatiladigan umumiy “noisy channel” g'oyasi — bugun imlo tuzatishga qo'llaymiz.

Noisy channel modeli: rasmiy ta'rif

$$\hat{w} = \arg \max_{w \in V} P(w | x) = \arg \max_{w \in V} \underbrace{P(x | w)}_{\text{xato modeli}} \underbrace{P(w)}_{\text{til modeli}}$$

bunda: x — kuzatilgan (xato) so'z; w — nomzod to'g'ri so'z; $P(w)$ — unigram chastota (so'z qanchalik keng tarqalgan); $P(x|w)$ — w dan x ga xato qilish ehtimoli. Nomzodlar V — x ga **tahrir masofasi kichik** so'zlar (odatda ≤ 2). Bu masofani keyingi blokda DP bilan aniq hisoblaymiz.

Keltirib chiqarish: formula qayerdan keladi?

1-qadam. Bizga $P(w \mid x)$ kerak — Bayes teoremi:

$$P(w \mid x) = \frac{P(x \mid w) P(w)}{P(x)}$$

Keltirib chiqarish: formula qayerdan keladi?

1-qadam. Bizga $P(w \mid x)$ kerak — Bayes teoremi:

$$P(w \mid x) = \frac{P(x \mid w) P(w)}{P(x)}$$

2-qadam. Biz w bo'yicha maksimum qidiramiz; $P(x)$ esa **barcha** w uchun bir xil (kuzatilgan x o'zgarmaydi):

$$\hat{w} = \arg \max_w \frac{P(x \mid w) P(w)}{P(x)} = \arg \max_w P(x \mid w) P(w)$$

Keltirib chiqarish: formula qayerdan keladi?

1-qadam. Bizga $P(w | x)$ kerak — Bayes teoremi:

$$P(w | x) = \frac{P(x | w) P(w)}{P(x)}$$

2-qadam. Biz w bo'yicha maksimum qidiramiz; $P(x)$ esa **barcha** w uchun bir xil (kuzatilgan x o'zgarmaydi):

$$\hat{w} = \arg \max_w \frac{P(x | w) P(w)}{P(x)} = \arg \max_w P(x | w) P(w)$$

Xulosa: ikki bilim manbasini birlashtiramiz — **xato modeli** $P(x|w)$ (qanday xato qilinadi) va **til modeli** $P(w)$ (qaysi so'z keng tarqalgan). Yolg'iz biri yetarli emas.

Qo'lda hisob: “kitop” ni qanday tuzatamiz?

Ikki nomzod (tahrir masofasi = 1): kitob va kotib.

Nomzod w	$P(w)$	$P(x w)$	ko'paytma
kitob	0.80	0.10	0.080
kotib	0.10	0.02	0.002

$$\hat{w} = \arg \max = \text{kitob} \quad (0.080 > 0.002)$$

Ikkala nomzod ham x ga bir xil yaqin (masofa 1), lekin kitob **keng tarqalgan** ($P(w)$ yuqori) — shuning uchun u g'olib. Til modeli muhim!

Sizning vazifangiz: “maktab” ni tuzating

Savol — 2 daqiqa

$x = \text{"maktab"}$. Nomzodlar:

w	$P(w)$	$P(x w)$
maktab	0.70	0.20
maktub	0.20	0.05

Qaysi nomzod g'olib? Ko'paytmalarni hisoblang.

Sizning vazifangiz: “maktab” ni tuzating

Savol — 2 daqiqa

$x = \text{"maktab"}$. Nomzodlar:

w	$P(w)$	$P(x w)$
maktab	0.70	0.20
maktub	0.20	0.05

Qaysi nomzod g'olib? Ko'paytmalarni hisoblang.

Javob

maktab: $0.70 \times 0.20 = \mathbf{0.14}$ maktub: $0.20 \times 0.05 = 0.01$

$\hat{w} = \text{maktab}$ ($0.14 > 0.01$) — keng tarqalgan so'z yana g'olib.

Kod $\leftrightarrow$ formula: correct() funksiyasi

```
def correct(x, candidates, P_w, P_err):  
    # candidates: tahrir masofasi <= 2 so'zlar  
    best, best_score = x, 0.0  
    for w in candidates:  
        # noisy channel:  $P(x|w) * P(w)$   
        score = P_err(x, w) * P_w(w)  
        if score > best_score:  
            best, best_score = w, score  
    return best  
  
correct("kitop", ["kitob", "kotib"],  
        P_w, P_err)          # -> "kitob"
```

Kod $\rightarrow$ formula:

Kod	Formula
P_err(x,w)	$P(x w)$
P_w(w)	$P(w)$
score=...	ko'paytma
max score	arg max

Ertangi P4 da m04.correct() aynan shu tartiblashni bajaradi.

Cheklovlar

- Faqat tahrir masofasi = 1 nomzodlarni olsak, masofa 2 xatolarni **o'tkazib** yuboramiz.
- Masofa ≤ 2 nomzodlar soni juda katta — hammasini baholash sekin.
- $P(x|w)$ ni aniq baholash uchun **xatolar korpusi** kerak; bo'lmasa soddalashtiriladi.

Tipik xato

$P(w)$ ni **e'tibordan** chiqarish: faqat $P(x|w)$ ga qarab tuzatsak, kamdan-kam uchraydigan so'z ham g'olib chiqishi mumkin.

Tezlashtirish: nomzodlarni lug'at-trie yoki BK-tree bilan tez topish, keyin tartiblash.

Prezentatsiya rejasi

- 1 Kirish: o'xshashlikdan qidiruv va tuzatishgacha
- 2 Tez o'xshashlik qidiruvi: LSH
- 3 Imlo tuzatish: noisy channel modeli
- 4 Tahrir masofasi: Levenshtein va DP**
- 5 Avtomatik tuzatish tizimi
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: bir so'zni boshqasiga "arzon" aylantirish

"kitob" dan "kitob" ga — 0 amal.

"kitop" dan "kitob" ga — 1 amal ($p \rightarrow b$ almashtirish).

"kitb" dan "kitob" ga — 1 amal (o qo'shish).

Tahrir masofasi — shu **minimal** amallar soni. Uch amal: qo'shish, o'chirish, almashtirish.

Masofa kichik bo'lsa — so'zlar yaqin (imlo xatosi ehtimoli yuqori). Noisy channel nomzodlari aynan shu yaqin so'zlar.

Naive yondashuv — barcha amal ketma-ketliklarini sinash — eksponensial. DP buni $O(mn)$ ga tushiradi.

Tahrir masofasi (Levenshtein): rasmiy ta'rif

$$D[i][j] = \begin{cases} D[i-1][j-1], & \text{agar } s_1[i] = s_2[j] \\ 1 + \min(D[i-1][j], D[i][j-1], D[i-1][j-1]), & \text{aks holda} \end{cases}$$

bunda: $D[i][j]$ — s_1 ning birinchi i , s_2 ning birinchi j belgisi orasidagi masofa; uch had mos ravishda **o'chirish**, **qo'shish**, **almashtirish**. Asos: $D[i][0] = i$ (hammasini o'chirish), $D[0][j] = j$ (hammasini qo'shish).

Keltirib chiqarish: nega aynan shu uch had?

1-qadam. $D[i][j]$ ni hisoblashda oxirgi belgilarni qaraymiz: $s_1[i]$ va $s_2[j]$.

Keltirib chiqarish: nega aynan shu uch had?

1-qadam. $D[i][j]$ ni hisoblashda oxirgi belgilarni qaraymiz: $s_1[i]$ va $s_2[j]$. **2-qadam.** Agar ular **teng** bo'lsa — amal kerak emas, masofa $D[i-1][j-1]$ ga teng.

Keltirib chiqarish: nega aynan shu uch had?

1-qadam. $D[i][j]$ ni hisoblashda oxirgi belgilarni qaraymiz: $s_1[i]$ va $s_2[j]$. **2-qadam.** Agar ular **teng** bo'lsa — amal kerak emas, masofa $D[i-1][j-1]$ ga teng. **3-qadam.** Aks holda eng arzon amalni tanlaymiz (1 narx):

- $D[i-1][j] + 1$ — $s_1[i]$ ni **o'chirish**,
- $D[i][j-1] + 1$ — $s_2[j]$ ni **qo'shish**,
- $D[i-1][j-1] + 1$ — $s_1[i] \rightarrow s_2[j]$ **almashtirish**.

Xulosa: har katak faqat uch qo'shnisiga tayanadi — shuning uchun jadvalni chap-yuqoridan to'ldiramiz; murakkablik $O(mn)$.

Qo'lda hisob: $\text{edit_distance}(\text{"qo'l"}, \text{"ko'l"}) = 1$

DP jadval ($s_1 = \text{qo'l}$, $s_2 = \text{ko'l}$):

	""	k	o	'	l
""	0	1	2	3	4
q	1	1	2	3	4
o	2	2	1	2	3
'	3	3	2	1	2
l	4	4	3	2	1

Natija: $D[4][4] = 1$

Faqat birinchi belgi farq qiladi: $q \rightarrow k$ (1 almashtirish). Qolgan o'l bir xil.

Ikkinchi tekshiruv

$\text{edit}(\text{dastur}, \text{dastir}) = 1$ ($u \rightarrow i$ almashtirish, 5-belgi). To'liq jadval: ilova S1.

Ertangi P4 birinchi assert:

$\text{edit_distance}(\text{"qo'l"}, \text{"ko'l"}) == 1$

Ma'ruza L4 [13]-slayd

Sizning vazifangiz: tahrir masofasini toping

Savol — 2 daqiqa

a) `edit(maktab, maktub) = ?`

b) `edit(kitob, kitoblar) = ?`

Har biri uchun qaysi amal(lar) ishlatiladi?

Sizning vazifangiz: tahrir masofasini toping

Savol — 2 daqiqa

a) edit(maktab, maktub) =?

b) edit(kitob, kitoblar) =?

Har biri uchun qaysi amal(lar) ishlatiladi?

Javob

a) **1** — a→u bitta **almashtirish** (4-belgi).

b) **3** — l, a, r uchta **qo'shish** (so'z oxiriga).

Eslatma: o'zbek qo'shimchalari (-lar, -da...) tahrir masofasini oshiradi — bu [M]-slaydda muhim bo'ladi.

Kod $\leftrightarrow$ formula: tahrir masofasi DP da

```
def edit_distance(s1, s2):
    m, n = len(s1), len(s2)
    D = [[0]*(n+1) for _ in range(m+1)]
    for i in range(m+1): D[i][0] = i      # o'chirish
    for j in range(n+1): D[0][j] = j      # qo'shish
    for i in range(1, m+1):
        for j in range(1, n+1):
            if s1[i-1] == s2[j-1]:
                D[i][j] = D[i-1][j-1]
            else:
                D[i][j] = 1 + min(
                    D[i-1][j],      # o'chirish
                    D[i][j-1],      # qo'shish
                    D[i-1][j-1])    # almashtirish

    return D[m][n]

edit_distance("qo'l", "ko'l")      # -> 1
```

Kod $\rightarrow$ formula:

Kod	Formula
D[i][0]=i	asos (o'chirish)
s1[i-1]==s2[j-1]	belgilar teng
1+min(...)	3 amal minimumi
D[m][n]	yakuniy masofa

Ertangi P4 da m04
SpellLSHRetriever.edit_distance()
aynan shu DP ni amalga oshiradi.

Usulning cheklovlari

- Masofa **ma'noni** bilmaydi: ot va it masofasi 1, lekin ma'no boshqa.
- Barcha juftga $O(mn)$ — katta lug'atda nomzodlarni avval filtrlash kerak.
- Almashtirish narxi har doim 1 — klaviatura yaqinligi (q/w) hisobga olinmaydi.

Tipik xato

Asos qatorini unutish:

$D[i][0]=i$ va $D[0][j]=j$ qo'yilmasa, bo'sh satrga masofa noto'g'ri (0) bo'lib, butun jadval buziladi.

Asos qatorlar — DP ning poydevori.

Prezentatsiya rejasi

- 1 Kirish: o'xshashlikdan qidiruv va tuzatishgacha
- 2 Tez o'xshashlik qidiruvi: LSH
- 3 Imlo tuzatish: noisy channel modeli
- 4 Tahrir masofasi: Levenshtein va DP
- 5 Avtomatik tuzatish tizimi**
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: alohida bloklar bitta tizimga birlashadi


Bugun uch “g’isht” o’rgandik:

- **Tahrir masofasi** — nomzodlarni topadi,
- **Noisy channel** — nomzodlarni tartiblaydi,
- **LSH** — katta korpusda tez qidiradi.

Endi ularni **bitta quvurga** ulaymiz: xato so’zdan tuzatilgan so’zgacha, va so’rovdan o’xshash hujjatgacha.

Yaxshi tizim — har blok alohida tekshiriladigan, almashtiriladigan komponent. Ertaga P4 da m04 shu komponentlarni birga quradi.

Avtomatik tuzatish tizimi: komponentlar va oqim



Komponentlar:

- 1 Normallashtirish (apostrof, kichik harf) — m01
- 2 Lug'at tekshiruvi (bor bo'lsa — tuzatish shart emas)
- 3 Nomzod generatsiyasi (tahrir masofasi)
- 4 Tartiblash (noisy channel: $P(x|w)P(w)$)

Hujjat qidiruvi uchun

Katta korpusda o'xshash hujjatni topish uchun shu quvurga **MinHash LSH indeks** qo'shiladi — m04 da ikkalasi birga keladi.

Qo'lda misol: "telfon" tizim bo'ylab qanday tuzatiladi?

#	Komponent	Natija
1	Normallashtirish	"telfon" (kichik harf, apostrofsiz)
2	Lug'atda bormi?	Yo'q $\Rightarrow$ tuzatish kerak
3	Nomzodlar ($\text{edit} \leq 2$)	{telefon, telpon, telfor}
4	Noisy channel tartiblash	telefon: $P(w) \cdot P(x w) = 0.9 \times 0.3 = \mathbf{0.27}$ telpon: $0.05 \times 0.2 = 0.010$
5	Chiqish	"telefon" (eng yuqori ko'paytma)

Tahrir masofasi (3-qadam) **nomzodlarni** berdi; noisy channel (4-qadam) ular orasidan **eng ehtimoliysini** tanladi. Ikki blok birgalikda ishlaydi.

Sizning vazifangiz: “kitb” qaysi bloklardan o’tadi?

Savol — 90 soniya

Foydalanuvchi "kitb" deb yozdi (lug’atda yo’q). Tizimning qaysi 4 bloki ishga tushadi va natija nima?

Maslahat: $\text{edit}(\text{kitb}, \text{kitob}) = 1$.

Sizning vazifangiz: "kitb" qaysi bloklardan o'tadi?

Savol — 90 soniya

Foydalanuvchi "kitb" deb yozdi (lug'atda yo'q). Tizimning qaysi 4 bloki ishga tushadi va natija nima?

Maslahat: $\text{edit}(\text{kitb}, \text{kitob}) = 1$.

Javob

- 1) Normallashtirish $\rightarrow$ kitb.
- 2) Lug'atda yo'q $\Rightarrow$ tuzatish.
- 3) Nomzodlar ($\text{edit} \leq 2$): $\{\text{kitob}, \text{kita}, \dots\}$ (kitob — o'qo'shish, masofa 1).
- 4) Noisy channel: kitob eng keng tarqalgan $\Rightarrow$ chiqish "kitob".

Prezentatsiya rejasi

- 1 Kirish: o'xshashlikdan qidiruv va tuzatishgacha
- 2 Tez o'xshashlik qidiruvi: LSH
- 3 Imlo tuzatish: noisy channel modeli
- 4 Tahrir masofasi: Levenshtein va DP
- 5 Avtomatik tuzatish tizimi
- 6 Xulosa va amaliyotga ko'prik

O'zbek tilida: apostrof va qo'shimchalar tahrir masofasini chalg'itadi

1. Apostrof muammosi:

Juft	edit
yo'l vs yol	1
to'g'ri vs togri	2

Apostrof tushib qolsa, bir xil so'z "xato" ko'rinadi. Yana ASCII ' va U+2019 — byte-darajada **turli** belgilar (L1 dan eslang).

2. Agglutinatsiya:

kitob, kitobni, kitobimizdan — bir o'zak, lekin o'zaro tahrir masofasi katta.

Oqibat

Nomzodlar fazosi ulkanlashadi; lug'at har bir qo'shimchali shaklni o'z ichiga ololmaydi ⇒ OOV.

Yechim: masofadan oldin **normallashtirish** (apostrof + stem, m01) — xato signalini kamaytiradi.

Sintez: 1-haftada o'xshashlikni uch darajada o'lchadik

Usul	Nimani o'lchaydi	Qachon
Levenshtein	Belgi-darajasi (imlo)	Imlo tuzatish, yaqin so'z
Jaccard + LSH	To'plam (bor/yo'q)	Yaqin-nusxa hujjat, tez qidiruv
Kosinus + embedding	Vektor (ma'no)	Semantik o'xshashlik (L3)

1-hafta kapstone yoyi

m01 tozalash → **m02** TF-IDF tasniflash → **m03** embedding o'xshashlik → **m04** imlo tuzatish + LSH qidiruv. To'rt modul birgalikda — hujjat yordamchingizning klassik yadrosi. 2-haftada neyron usullarga o'tamiz.

Seminal manba: Norvig (2009)

Norvig, P. (2009). **How to Write a Spelling Corrector.** norvig.com/spell-correct.html

Asosiy g'oya:

- 21 qatorlik Python: noisy channel + tahrir masofasi + unigram LM.
- Nomzodlar — tahrir masofasi 1 va 2 dagi so'zlar.
- $P(w)$ katta korpus chastotasidan; $P(x|w)$ soddalashtirilgan.


Muhokama savoli (P4 gacha o'ylang)

Norvig faqat tahrir masofasi ≤ 2 nomzodlarni ko'radi. O'zbek agglutinatив so'zlari (kitobimizdan) uchun bu **yetarlimi**? Nima qo'shish kerak?

Bugungi maqsadlar bajarildi

- 1 ✓ **Keltirib chiqardik:** Levenshtein DP rekurrensiyasi va MinHash–Jaccard bog'lanishi ($P[\text{minhash teng}] = J$).
- 2 ✓ **Hisobladik:** $\text{edit}(\text{qo}'1, \text{ko}'1) = 1$ DP jadval bilan ([I3]-slayd); $J = 0.5$, $J = 0.2$.
- 3 ✓ **Qo'lladik:** noisy channel — kitop $\rightarrow$ kitob ($0.080 > 0.002$).
- 4 ✓ **Taqqosladik:** aniq k-NN va taxminiy LSH; Levenshtein / Jaccard / kosinus — qachon qaysi.

Ertaga P4: imlo tuzatish va LSH qidiruvini qurasiz



P4 da qurasiz:

- `edit_distance(s1, s2)` — DP jadval
- `correct(word)` — noisy channel top-nomzod
- `index_docs / retrieve_lsh` — datasketch
- k-NN va LSH qidiruv tezligini taqqoslash

Birinchi assert (bu slayd [I3]):

```
assert
edit_distance("qo'l", "ko'l")==1
# Ma'ruza L4 [I3]-slayd bilan
# solishtiring
```

Tayyorlab keling: P3 notebook'ingiz ochiq bo'lsin;
muhokama savoliga [O] javob.

- ① Norvig, P. (2009). *How to Write a Spelling Corrector*. norvig.com/spell-correct.html
- ② Jurafsky, D., Martin, J.H. (2023). *Speech and Language Processing*, 3-nashr. 2-bob: Minimum Edit Distance; B-ilova: Spelling.
- ③ Levenshtein, V.I. (1966). *Binary codes capable of correcting deletions, insertions, and reversals*. Soviet Physics Doklady.
- ④ Broder, A. (1997). *On the resemblance and containment of documents*. (MinHash) — va Indyk & Motwani (1998), LSH.
- ⑤ datasketch hujjatlari: MinHash, MinHashLSH.

Ilova S1: “dastur” va “dastir” to’liq DP jadvali

DP jadval ($s_1 = \text{dastur}$, $s_2 = \text{dastir}$):

	""	d	a	s	t	i	r
""	0	1	2	3	4	5	6
d	1	0	1	2	3	4	5
a	2	1	0	1	2	3	4
s	3	2	1	0	1	2	3
t	4	3	2	1	0	1	2
u	5	4	3	2	1	1	2
r	6	5	4	3	2	2	1

$D[6][6] = 1$: faqat $u \rightarrow i$ almashtirish (5-belgi). Diagonal bo'ylab nollar — mos belgilar.

Ilova S2: MinHash va LSH banding matematikasi

b band, har biri r qatordan ($n = b \cdot r$ xesh). Jaccard s bo'lgan juftning kamida bitta bandda to'liq mos kelishi (nomzod bo'lishi) ehtimoli:

$$P_{\text{nomzod}}(s) = 1 - (1 - s^r)^b$$

bunda: s — haqiqiy Jaccard; r — band qatorlari; b — bandlar soni.

Bu funksiya s ga nisbatan S-shaklli (sigmoid-simon): b, r ni sozlab, “chegara” o'xshashlikni (masalan $s \approx 0.5$) tanlash mumkin — undan yuqori juftlar deyarli har doim, pastlari deyarli hech qachon nomzod bo'lmaydi.