

Neyron so'z embeddinglari: Word2Vec (CBOW)

Tabiiy tilni qayta ishlash — 6-ma'ruza

A.A. Abdulali

11:00–12:20 · mavzu №6

23-iyun 2026

Prezentatsiya rejasi

- 1 Kirish: so'zlarni o'rganilgan vektorlar bilan ifodalaymiz
- 2 Nega o'rganiladigan zich vektorlar?
- 3 CBOW arxitekturasini kontekstdan markazga
- 4 Neyron tarmoqni o'qitish: yo'qotish va backprop
- 5 O'qitish jarayoni va embedding sifatini baholash
- 6 Xulosa va amaliyotga ko'prik

Takrorlash: o'tgan darsdan ikki savol

1-savol

L5 da N-gram modeli so'zlarni **diskret** (alo-hida) tokenlar deb hisobladi: kitob va kitobni — butunlay bog'liqsiz. Bu agglutinatativ o'zbek tilida qanday muammoga olib keladi?

2-savol

Bugun ertalab P5 da autocomplete **sanashga** (count) tayandi. Sanash ikki so'zning **ma'no o'xshashligini** o'rgata oladimi?

Takrorlash: o'tgan darsdan ikki savol

1-savol

L5 da N-gram modeli so'zlarni **diskret** (alo-hida) tokenlar deb hisobladi: kitob va kitobni — butunlay bog'liqsiz. Bu agglutinatativ o'zbek tilida qanday muammoga olib keladi?

1-javob

Lug'at portlaydi (vocabulary explosion): har qo'shimchali shakl alohida token. Lug'at kattalashadi, sanoqlar **siyraklashadi**.

2-savol

Bugun ertalab P5 da autocomplete **sanashga** (count) tayandi. Sanash ikki so'zning **ma'no o'xshashligini** o'rgata oladimi?

2-javob

Yo'q. Sanash faqat “birga uchradimi” ni biladi; film va kino ni yaqin deb bilmaydi. Bugun buni **o'rganamiz**.

Siz bugungi dars oxirida quyidagilarni bajara olasiz:

- ❶ **Keltirib chiqara olasiz:** nega one-hot (diskret) ifoda yetarli emas — siyraklik va o'xshashlikni ko'rsata olmaslik.
- ❷ **Tushuntira olasiz:** CBOW arxitekturasini — kontekst vektorlarini o'rtachalab markaziy so'zni bashorat qiladi ($\text{CBOW}_{\text{kirish}} = [0.3, 0.5]$).
- ❸ **Hisoblay olasiz:** softmax bashorati, cross-entropy yo'qotish va gradientning bir qadamini qo'lda.
- ❹ **Baholay olasiz:** o'rganilgan embeddinglar sifatini kosinus o'xshashlik va analogiya orqali.

L3 dan: vektor, kosinus o'xshashlik. L5 dan: softmax g'oyasi yo'q edi — bugun kiritamiz. Matematikadan: vektor o'rtachasi, ko'paytma, exp, ln, hosila (zanjir qoidasi).

Bugungi dars rejasi:

Tsiki	Mavzu	Vaqt	Hosil natija	bo'luvchi
1	Nega zich vektor? (one-hot → embedding)	15 daq	$\cos(\text{one-hot}) = 0$	
2	CBOW arxitekturasi (kontekst → markaz)	18 daq	$\text{CBOW}_{\text{kirish}} = [0.3, 0.5]$	
3	O'qitish: softmax, yo'qotish, backprop	20 daq	$\hat{y}(\text{nlp}) = 0.690$	
4	O'qitish jarayoni va embedding baholash	17 daq	$\cos(\text{film}, \text{kino}) = 0.96$	
	Xulosa va 6-amaliyotga ko'rsatmalar	10 daq	Ertaga nima qurishingiz	

Bu dars 2-haftani davom ettiradi

Ehtimollik modellari (L5) dan **o'rganiladigan** ifodalarga o'tamiz. Bugungi $\text{CBOW}_{\text{kirish}} = [0.3, 0.5]$ ertangi

Bugungi dars uchun muammo: “film” va “kino” yaqin ekanini qanday bilamiz?

Sodda yechim qayerda qiynaladi:

1. One-hot: har so'z alohida o'q

$\text{film} = (1, 0, 0, \dots)$, $\text{kino} = (0, 1, 0, \dots)$. Ular **ortogonal** — o'xshashlik 0, garchi ma'no bir xil bo'lsa ham.

2. Pretrained (L3) o'zbek uchun siyrak

P3 da ko'rdik: tayyor GloVe/Word2Vec o'zbek so'zlari uchun OOV darajasi baland — coverage past.

Bugungi yechim:

- 1 So'z uchun **zich** (dense), kichik o'lchamli vektor.
- 2 Uni **korpusdan o'rganamiz** — kontekstdan.
- 3 Yaqin kontekstda kelgan so'zlar yaqin vektor oladi ($\text{film} \approx \text{kino}$).

Bu g'oyaning nomi — **Word2Vec**. Bugun uning **CBOW** variantini o'rganamiz.

Prezentatsiya rejasi

- 1 Kirish: so'zlarni o'rganilgan vektorlar bilan ifodalaymiz
- 2 Nega o'rganiladigan zich vektorlar?
- 3 CBOW arxitekturasini kontekstdan markazga
- 4 Neyron tarmoqni o'qitish: yo'qotish va backprop
- 5 O'qitish jarayoni va embedding sifatini baholash
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: soʻz maʼnosi uning “hamrohlari”da yashiringan

Taqsimot gipotezasi (distributional hypothesis):

“Soʻzni hamrohlaridan tanaymiz.”

film va kino bir xil kontekstlarda uchraydi:

... yaxshi _____ koʻrdim

... qiziq _____ chiqdi

Demak ularning vektorlari **yaqin** boʻlishi kerak —
agar vektorni kontekstdan oʻrgansak.

One-hot da har soʻz **alohida oʻq** — hech
qaysi ikkitasi yaqin emas. Bizga **zich** fazo
kerak: yaqin maʼno $\Rightarrow$ yaqin nuqta.

One-hot va embedding: rasmiy ta'rif

$$\mathbf{x}_w \in \{0, 1\}^{|V|}, \quad \sum_i x_{w,i} = 1 \quad \implies \quad \mathbf{e}_w = W^T \mathbf{x}_w \in \mathbb{R}^d$$

bunda: $|V|$ — lug'at hajmi; $\mathbf{x}_w$ — w so'zning one-hot vektori (bitta 1, qolgani 0); W — embedding matritsasi ($|V| \times d$); $d \ll |V|$ — embedding o'lchami; $\mathbf{e}_w$ — w ning zich vektori (aslida W ning bir qatori). **Asosiy farq:**

$$d \ll |V| : \quad |V| \sim 10^5 \text{ ga qarshi } d \sim 100\text{--}300$$

One-hot — siyrak (sparse) va kontekstsiz; embedding — zich (dense) va o'rganilgan.

Keltirib chiqarish: nega one-hot o'xshashlikni ko'rsata olmaydi?

1-qadam. Ikki har xil so'zning one-hot vektorlari: faqat *turli* pozitsiyada 1 bor.

Keltirib chiqarish: nega one-hot o'xshashlikni ko'rsata olmaydi?

1-qadam. Ikki har xil so'zning one-hot vektorlari: faqat *turli* pozitsiyada 1 bor. **2-qadam.** Ularning skalyar ko'paytmasi — bir-biriga to'g'ri keladigan pozitsiya yo'q:

$$\mathbf{x}_a \cdot \mathbf{x}_b = \sum_i x_{a,i} x_{b,i} = 0 \quad (a \neq b)$$

Keltirib chiqarish: nega one-hot o'xshashlikni ko'rsata olmaydi?

1-qadam. Ikki har xil so'zning one-hot vektorlari: faqat *turli* pozitsiyada 1 bor. **2-qadam.** Ularning skalyar ko'paytmasi — bir-biriga to'g'ri keladigan pozitsiya yo'q:

$$\mathbf{x}_a \cdot \mathbf{x}_b = \sum_i x_{a,i} x_{b,i} = 0 \quad (a \neq b)$$

3-qadam. Demak kosinus o'xshashlik ham nol:

$$\cos(\mathbf{x}_a, \mathbf{x}_b) = \frac{\mathbf{x}_a \cdot \mathbf{x}_b}{\|\mathbf{x}_a\| \|\mathbf{x}_b\|} = \frac{0}{1 \cdot 1} = 0$$

Xulosa: one-hot fazoda **barcha** so'zlar bir xil (nol) o'xshash — ma'no farqi yo'qoladi. Zich vektor bu muammoni hal qiladi.

Qo'lda misol: one-hot o'xshashligi har doim nol

$\text{film} = (1, 0, 0), \quad \text{kino} = (0, 1, 0), \quad \text{yomg'ir} = (0, 0, 1).$

Hisoblaymiz:

$$\begin{aligned} \mathbf{x}_{\text{film}} \cdot \mathbf{x}_{\text{kino}} &= 1 \cdot 0 + 0 \cdot 1 + 0 \cdot 0 = 0 \\ \cos(\text{film}, \text{kino}) &= \frac{0}{1 \cdot 1} = \mathbf{0} \end{aligned}$$

film va kino ma'noda yaqin, ammo one-hot ularni film va yomg'ir kabi **butunlay bog'liqsiz** deydi (ikkalasi ham $\cos = 0$).

Sizning vazifangiz: zich vektorlarda o'xshashlik

Savol — 90 soniya

Endi **o'rganilgan** zich vektorlar ($\text{dim} = 2$):

$$\mathbf{e}_{\text{film}} = [0.8, 0.6], \quad \mathbf{e}_{\text{kino}} = [0.6, 0.8].$$

$$\cos(\mathbf{film}, \mathbf{kino}) = ? \quad (\text{har ikkala vektor uzunligi } 1)$$

Sizning vazifangiz: zich vektorlarda o'xshashlik

Savol — 90 soniya

Endi **o'rganilgan** zich vektorlar ($\text{dim} = 2$):

$$\mathbf{e}_{\text{film}} = [0.8, 0.6], \quad \mathbf{e}_{\text{kino}} = [0.6, 0.8].$$

$$\cos(\mathbf{film}, \mathbf{kino}) = ? \quad (\text{har ikkala vektor uzunligi } 1)$$

Javob

$$\mathbf{e}_{\text{film}} \cdot \mathbf{e}_{\text{kino}} = 0.8 \cdot 0.6 + 0.6 \cdot 0.8 = 0.48 + 0.48 = 0.96$$

$$\cos = \frac{0.96}{1 \cdot 1} = \mathbf{0.96}$$

One-hot da 0 edi, zich fazoda 0.96 — ma'no yaqinligi **ko'rinadi**. Mana shuni o'rganmoqchimiz.

Kod $\leftrightarrow$ formula: one-hot va embedding qidiruv

```
1 import numpy as np
2
3 V = ["film", "kino", "yomg'ir"] # |V| = 3
4 d = 2 # embedding o'
5     lchami
6
7 # embedding matritsasi: |V| x d
8 W = np.array([[0.8, 0.6],
9               [0.6, 0.8],
10              [-0.6, 0.8]])
11
12 def onehot(w):
13     x = np.zeros(len(V)); x[V.index(w)] = 1
14     return x
15
16 # e_w = W^T x_w == W ning w-qatori
17 e_film = W.T @ onehot("film") # [0.8, 0.6]
18 print(e_film)
```

Kod $\rightarrow$ formula:

Kod	Formula
onehot(w)	$\mathbf{x}_w$
W	$W (V \times d)$
W.T @ x	$W^T \mathbf{x}_w = \mathbf{e}_w$

Amalda W.T @ x o'rniga shunchaki W[index] — qator tanlanadi (matritsa ko'paytmasi shart emas).

Tuzoq: embedding o'zicha paydo bo'lmaydi — uni o'rgatish kerak

Tasodifiy boshlang'ich vektor ma'nosiz

W ni tasodifiy ($\mathcal{N}(0, 0.01)$) boshlaymiz. Bu paytda film va kino **yaqin emas** — hali hech narsa o'rganilmagan.

Zich vektorning “sehri” o'z-o'zidan emas, **o'qitish** jarayonidan keladi.

Savol: W ni qanday yangilaymizki, kontekstdosh so'zlar yaqin bo'lib qolsin? $\Rightarrow$ 2- va 3-tsikl: CBOW va backprop.

Prezentatsiya rejasi

- 1 Kirish: so'zlarni o'rganilgan vektorlar bilan ifodalaymiz
- 2 Nega o'rganiladigan zich vektorlar?
- 3 CBOW arxitekturasini kontekstdan markazga**
- 4 Neyron tarmoqni o'qitish: yo'qotish va backprop
- 5 O'qitish jarayoni va embedding sifatini baholash
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: kontekstni o'rtachalab markaziy so'zni taxmin qilamiz

CBOW = *Continuous Bag of Words*.

Topshiriq: atrofdagi so'zlar berilgan, **o'rtadagi** so'zni topish.

[men, sevaman] → ?

Javob: nlp bo'lishi kerak.

Qanday? Kontekst so'zlarining vektorlarini **o'rtachalaymiz**, shu o'rtacha bilan markaziy so'zni bashorat qilamiz.

“Bag” (qop) — tartib hisobga olinmaydi: [men, sevaman] va [sevaman, men] bir xil o'rtacha beradi. Bu soddalashtirish — CBOW ning narxi.

CBOW arxitekturası: rasmiy ta'rif

$$\mathbf{h} = \frac{1}{2m} \sum_j \mathbf{e}_{c_j}, \quad u_k = \mathbf{v}'_k \cdot \mathbf{h}, \quad \hat{y}_k = \frac{e^{u_k}}{\sum_{k'} e^{u_{k'}}}$$

bunda: c_j — kontekst so'zlari ($2m$ ta, oyna radiusi m); $\mathbf{e}_{c_j}$ — ularning kirish embeddinglari; $\mathbf{h}$ — **proyeksiya** (o'rtacha) qatlam; $\mathbf{v}'_k$ — k so'zning **chiqish** vektori (W' ning ustuni); u_k — ball (score); $\hat{y}_k$ — softmax bashorati. Diqqat: **ikki** matritsa bor — kirish W (embedding) va chiqish W' . Odatda embedding sifatida W ishlatiladi.

Keltirib chiqarish: nega kontekstni o'rtachalaymiz?

1-qadam. “Bag” taxmini: kontekst so'zlari — tartibsiz to'plam, har biri markaziy so'zga **teng** hissa qo'shadi.

Keltirib chiqarish: nega kontekstni o'rtachalaymiz?

1-qadam. “Bag” taxmini: kontekst so'zlari — tartibsiz to'plam, har biri markaziy so'zga **teng** hissa qo'shadi. **2-qadam.** Teng hissa $\Rightarrow$ simmetrik birlashtirish. Yig'indi yoki o'rtacha bo'lishi mumkin; **o'rtacha** kontekst so'zlari soniga normallaydi (turli oyna o'lchamlarini solishtirsa bo'ladi):

$$\mathbf{h} = \frac{1}{2m} \sum_{j=1}^{2m} \mathbf{e}_{c_j}$$

Keltirib chiqarish: nega kontekstni o'rtachalaymiz?

1-qadam. “Bag” taxmini: kontekst so'zlari — tartibsiz to'plam, har biri markaziy so'zga **teng** hissa qo'shadi. **2-qadam.** Teng hissa $\Rightarrow$ simmetrik birlashtirish. Yig'indi yoki o'rtacha bo'lishi mumkin; **o'rtacha** kontekst so'zlari soniga normallaydi (turli oyna o'lchamlarini solishtirsa bo'ladi):


$$\mathbf{h} = \frac{1}{2m} \sum_{j=1}^{2m} \mathbf{e}_{c_j}$$

3-qadam. Bu **chiziqli** amal — nochiziqlilik (tanh, ReLU) *yo'q*. Aynan shuning uchun proyeksiya qatlami arzon:

$$\mathbf{h} \text{ hisobi} = O(2m \cdot d) \quad (\text{juda tez})$$

Xulosa: CBOW “yashirin qatlam”i — shunchaki o'rtacha. Soddalik $\Rightarrow$ ulkan korpusda tez o'qish (Mikolov 2013 ning maqsadi).

CBOW oqimi: kontekst $\rightarrow$ o'rtacha $\rightarrow$ chiqish



Proyeksiya qatlami — shunchaki **o'rtacha**, na'munaviy "yashirin qatlam" kabi nochiziqli emas. Aynan shu soddalik CBOW ni tez qiladi.

Qo'lda misol: CBOW kirishi = $[0.3, 0.5]$

$\mathbf{e}_{\text{men}} = [0.5, 0.3]$, $\mathbf{e}_{\text{sevaman}} = [0.1, 0.7]$. Oyna: $2m = 2$ kontekst so'z.

Proyeksiya (o'rtacha):

$$\begin{aligned}\mathbf{h} &= \frac{1}{2}(\mathbf{e}_{\text{men}} + \mathbf{e}_{\text{sevaman}}) \\ &= \frac{1}{2}([0.5, 0.3] + [0.1, 0.7]) \\ &= \frac{1}{2}[0.6, 1.0] = [\mathbf{0.3}, \mathbf{0.5}]\end{aligned}$$

Bu $\mathbf{h} = [0.3, 0.5]$ — markaziy so'zni bashorat qilish uchun ishlatiladigan “kontekst xulosasi”.

Ertangi P6 birinchi assert:
`np.allclose(cbow_input,
[0.3, 0.5])`
Ma'ruza L6 [l2]-slayd

Sizning vazifangiz: boshqa kontekst uchun proyeksiya

Savol — 90 soniya

Kontekst = [men, kitobni], dim= 2:

$\mathbf{e}_{\text{men}} = [0.4, 0.2]$, $\mathbf{e}_{\text{kitobni}} = [0.2, 0.6]$.

$\mathbf{h} = ?$

Sizning vazifangiz: boshqa kontekst uchun proyeksiya

Savol — 90 soniya

Kontekst = [men, kitobni], dim= 2:

$\mathbf{e}_{\text{men}} = [0.4, 0.2]$, $\mathbf{e}_{\text{kitobni}} = [0.2, 0.6]$.

$\mathbf{h} = ?$

Javob

$$\mathbf{h} = \frac{1}{2}([0.4, 0.2] + [0.2, 0.6]) = \frac{1}{2}[0.6, 0.8] = [\mathbf{0.3}, \mathbf{0.4}]$$

Proyeksiya — har o'lcham bo'yicha o'rtacha. Kontekst so'zlari soni o'zgarsa ham formula bir xil ($\frac{1}{2m} \sum$).

Kod ↔ formula: CBOW proyeksiyasi

```
1 import numpy as np
2
3 # kontekst so'zlarining embeddinglari
4 e_men      = np.array([0.5, 0.3])
5 e_sevaman  = np.array([0.1, 0.7])
6
7 context = np.stack([e_men, e_sevaman])
8
9 #  $h = (1 / 2m) * \sum(e_{c_j})$ 
10 h = context.mean(axis=0)
11 print(h)    # [0.3 0.5]
```

Kod → formula:

Kod	Formula
<code>np.stack</code>	$\{e_{c_j}\}$
<code>.mean(axis=0)</code>	$\frac{1}{2m} \sum_j e_{c_j}$
<code>h</code>	h

Ertangi P6 da m06 CustomWord2Vec ichida aynan shu o'rtacha proyeksiya bo'ladi.

CBOW tuzog'i: "bag" tartibni unutadi

Tartib yo'qoladi

O'rtacha kommutativ: [men, sevaman] va [sevaman, men] bir xil **h** beradi.

"it odamni qopdi" va *"odam itni qopdi"* — CBOW uchun kontekst bir xil.

Bu so'z **vektorlarini** o'rganishga ko'pincha xalal bermaydi (maqsad — so'z ma'nosi, gap tahlili emas).

Tartib muhim bo'lsa: pozitsion kodlash, RNN (L7), Transformer (3-hafta) kerak bo'ladi.

Prezentatsiya rejasi

- 1 Kirish: so'zlarni o'rganilgan vektorlar bilan ifodalaymiz
- 2 Nega o'rganiladigan zich vektorlar?
- 3 CBOW arxitekturasini kontekstdan markazga
- 4 Neyron tarmoqni o'qitish: yo'qotish va backprop
- 5 O'qitish jarayoni va embedding sifatini baholash
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: xatoni o'lchaymiz, vektorlarni xato kamayadigan tomonga suramiz

O'qitish sikli (har kontekst–markaz jufti uchun):

- ➊ **Forward:** $\mathbf{h}$ dan softmax bashorat $\hat{y}$.
- ➋ **Yo'qotish:** bashorat to'g'ri markaz so'zdan qancha uzoq?
- ➌ **Backward:** har vektorni xatoni kamaytiradigan tomonga biroz suramiz (gradient).

Minglab juftlar ustida takrorlasak — kontekstdosh so'zlar yaqinlashadi.

“O'rganish” = W va W' ni **yangilash**.
Yangilash yo'nalishi — yo'qotishning gradienti (eng tik pasayish).

Cross-entropy yo'qotish va gradient: ta'rif

$$\mathcal{L} = -\ln \hat{y}_c = -\ln \frac{e^{u_c}}{\sum_k e^{u_k}}$$

bunda: c — haqiqiy (target) markaz so'z indeksi; $\hat{y}_c$ — modelning shu so'zga bergan ehtimoli; $\mathcal{L}$ kichik $\Leftrightarrow$ model to'g'ri so'zga yuqori ehtimol bergan.

$$\frac{\partial \mathcal{L}}{\partial u_k} = \hat{y}_k - y_k \quad (\mathbf{y} \text{ — target one-hot})$$

Bu Word2Vec ning eng nafis natijasi: gradient — shunchaki **bashorat minus haqiqat**.

Keltirib chiqarish: $\partial \mathcal{L} / \partial u_k = \hat{y}_k - y_k$

1-qadam. Yo'qotish: $\mathcal{L} = -u_c + \ln \sum_k e^{u_k}$ (softmaxni logarifmga ochdik).

Keltirib chiqarish: $\partial \mathcal{L} / \partial u_k = \hat{y}_k - y_k$

1-qadam. Yo'qotish: $\mathcal{L} = -u_c + \ln \sum_k e^{u_k}$ (softmaxni logarifmga ochdik). **2-qadam.** u_k bo'yicha hosila — ikki had:

$$\frac{\partial \mathcal{L}}{\partial u_k} = -\frac{\partial u_c}{\partial u_k} + \frac{e^{u_k}}{\sum_{k'} e^{u_{k'}}} = -y_k + \hat{y}_k$$

Keltirib chiqarish: $\partial \mathcal{L} / \partial u_k = \hat{y}_k - y_k$

1-qadam. Yo'qotish: $\mathcal{L} = -u_c + \ln \sum_k e^{u_k}$ (softmaxni logarifmga ochdik). **2-qadam.** u_k bo'yicha hosila — ikki had:

$$\frac{\partial \mathcal{L}}{\partial u_k} = -\frac{\partial u_c}{\partial u_k} + \frac{e^{u_k}}{\sum_{k'} e^{u_{k'}}} = -y_k + \hat{y}_k$$

3-qadam. Demak ball bo'yicha gradient ($\mathbf{y}$ — one-hot):

$$\frac{\partial \mathcal{L}}{\partial u_k} = \hat{y}_k - y_k$$

Xulosa: to'g'ri so'z uchun ($y_c=1$) gradient $\hat{y}_c - 1 < 0$ — ballni **oshir**; boshqalar uchun $\hat{y}_k > 0$ — ballni **pasaytir**. Zanjir qoidasi bilan W, W' ga tarqaladi.

Qo'lda misol: forward, yo'qotish va gradient

Chiqish vektorlari: $\mathbf{v}'_{\text{nlp}} = [1, 1]$, $\mathbf{v}'_{\text{kitob}} = [0, 0]$.

Ballar:

$$u_{\text{nlp}} = [1, 1] \cdot [0.3, 0.5] = 0.8$$

$$u_{\text{kitob}} = [0, 0] \cdot [0.3, 0.5] = 0$$

Softmax (target nlp):

$$\hat{y}_{\text{nlp}} = \frac{e^{0.8}}{e^{0.8} + e^0} = \frac{2.226}{3.226} \approx \mathbf{0.690}$$

Yo'qotish:

$$\mathcal{L} = -\ln 0.690 \approx \mathbf{0.371}$$

Gradient ($\hat{y} - y$):

$$\frac{\partial \mathcal{L}}{\partial u_{\text{nlp}}} = 0.690 - 1 = -0.310$$

Manfiy $\Rightarrow u_{\text{nlp}}$ ni oshirish kerak: model nlp ga **ko'proq** ehtimol bersin.

Sizning vazifangiz: teng ballarda yo'qotish

Savol — 90 soniya

Agar ikkala ball ham teng bo'lsa: $u_{\text{nlp}} = 0$, $u_{\text{kitob}} = 0$ (2 nomzod). Target — nlp.

$\hat{y}_{\text{nlp}} = ?$ **va** $\mathcal{L} = ?$

Sizning vazifangiz: teng ballarda yo'qotish

Savol — 90 soniya

Agar ikkala ball ham teng bo'lsa: $u_{\text{nlp}} = 0$, $u_{\text{kitob}} = 0$ (2 nomzod). Target — nlp.

$\hat{y}_{\text{nlp}} = ?$ **va** $\mathcal{L} = ?$

Javob

$$\hat{y}_{\text{nlp}} = \frac{e^0}{e^0 + e^0} = \frac{1}{2} = \mathbf{0.5}; \quad \mathcal{L} = -\ln 0.5 \approx \mathbf{0.693}$$

Bu — “hech narsa bilmaslik” holati (tasodifiy taxmin, 2 sinf). $0.693 = \ln 2$ — 2 nomzodli boshlang'ich yo'qotish. O'qitish uni pasaytiradi.

Kod $\leftrightarrow$ formula: softmax, yo'qotish, gradient

```
1 import numpy as np
2
3 h = np.array([0.3, 0.5])
4 Wout = np.array([[1, 1],          #  $v'_{nlp}$ 
5                  [0, 0]])         #  $v'_{kitob}$ 
6
7 u = Wout @ h                      # ballar [0.8, 0.0]
8 yhat = np.exp(u) / np.exp(u).sum() # softmax
9
10 y = np.array([1, 0])             # target one-hot (
11     nlp)
12 loss = -np.log(yhat[0])          # 0.371
13 grad_u = yhat - y               # [-0.310, 0.310]
14
15 print(round(yhat[0], 3), round(loss, 3))
```

Kod $\rightarrow$ formula:

Kod	Formula
Wout @ h	$u_k = \mathbf{v}'_k \cdot \mathbf{h}$
exp/sum	$\hat{y}_k$ (softmax)
-log(yhat)	$\mathcal{L} = -\ln \hat{y}_c$
yhat - y	$\hat{y}_k - y_k$

Haqiqiy Word2Vec $|V|$ katta bo'lgani uchun to'liq softmax o'rniga **negative sampling** ishlatadi ([L]).

O'qitish tuzog'i: to'liq softmax $|V|$ da juda qimmat

Maxraj butun lug'at bo'ylab

$\hat{y}_k$ maxraji $\sum_{k'} e^{u_{k'}}$ — har qadamda **butun** lug'at ($|V| \sim 10^5$) bo'yicha hisoblanadi. Bu juda sekin.

Yechim

Negative sampling: har qadamda target + bir nechta tasodifiy “salbiy” so'z bilan ishlaymiz — maxraj kichrayadi.

Muqobil: hierarchical softmax. Gensim (P6) standart sifatida negative sampling ishlatadi.

Prezentatsiya rejasi

- 1 Kirish: so'zlarni o'rganilgan vektorlar bilan ifodalaymiz
- 2 Nega o'rganiladigan zich vektorlar?
- 3 CBOW arxitekturasini kontekstdan markazga
- 4 Neyron tarmoqni o'qitish: yo'qotish va backprop
- 5 O'qitish jarayoni va embedding sifatini baholash**
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: yaxshi embedding — yaqin ma'no yaqin vektor

Korpus bo'ylab ko'p marta o'tib (epoch), W ni yangilab boramiz. Sifatni qanday tekshiramiz?

- **Kosinus o'xshashlik:** sinonimlar yaqinmi? (film $\approx$ kino)
- **Analogiya:** shoh — erkak + ayol $\approx$ malika?
- **Eng o'xshashlar:** most_similar mazmunlimi?

Yo'qotishning pasayishi — o'qitish ketayotganini ko'rsatadi, ammo **sifat** faqat shunday *mazmunli* testlar bilan baholanadi.

Kosinus o'xshashlik va analogiya: ta'rif

$$\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|} \in [-1, 1]$$

bunda: $\mathbf{a} \cdot \mathbf{b}$ — skalyar ko'paytma; $\|\cdot\|$ — Yevklid uzunligi; 1 — bir xil yo'nalish (ma'no yaqin), 0 — bog'liqsiz, -1 — qarama-qarshi.

$$\mathbf{e}_{\text{shoh}} - \mathbf{e}_{\text{erkak}} + \mathbf{e}_{\text{ayol}} \approx \mathbf{e}_{\text{malika}}$$

Semantik munosabat (jins) vektor *ayirmasi* sifatida saqlanadi — L3 dagi vektor arifmetikasi.

Keltirib chiqarish: nega kosinus, uzunlik emas?

1-qadam. Skalyar ko'paytma yo'nalish va uzunlikni aralashtiradi: $\mathbf{a} \cdot \mathbf{b} = \|\mathbf{a}\| \|\mathbf{b}\| \cos \theta$.

Keltirib chiqarish: nega kosinus, uzunlik emas?

1-qadam. Skalyar ko'paytma yo'nalish va uzunlikni aralashtiradi: $\mathbf{a} \cdot \mathbf{b} = \|\mathbf{a}\| \|\mathbf{b}\| \cos \theta$.

2-qadam. Embeddingda biz **ma'no yo'nalishini** qiziqitiramiz, uzunlikni (so'z chastotasiga bog'liq) emas.

Keltirib chiqarish: nega kosinus, uzunlik emas?

1-qadam. Skalyar ko'paytma yo'nalish va uzunlikni aralashtiradi: $\mathbf{a} \cdot \mathbf{b} = \|\mathbf{a}\| \|\mathbf{b}\| \cos \theta$.

2-qadam. Embeddingda biz **ma'no yo'nalishini** qiziqtiramiz, uzunlikni (so'z chastotasiga bog'liq) emas. **3-qadam.** Uzunlikka bo'lib, faqat yo'nalishni qoldiramiz:

$$\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|} = \cos \theta$$

Xulosa: kosinus — ikki vektor orasidagi **burchak**. Shuning uchun ko'p/kam uchraydigan so'zlarni adolatli taqqoslaydi.

Qo'lda misol: o'rganilgan embeddinglar sifati

$$\mathbf{e}_{\text{film}} = [0.8, 0.6], \quad \mathbf{e}_{\text{kino}} = [0.6, 0.8]. \quad (\text{har birining uzunligi } 1)$$

Hisoblaymiz:

$$\mathbf{e}_{\text{film}} \cdot \mathbf{e}_{\text{kino}} = 0.8 \cdot 0.6 + 0.6 \cdot 0.8 = 0.96$$

$$\cos(\text{film}, \text{kino}) = \frac{0.96}{1 \cdot 1} = \mathbf{0.96}$$

0.96 — juda yuqori. Model film va kino ni **sinonim** sifatida o'rgangan (one-hot da bu 0 edi — [l1]). **Sifat yaxshi.**

Sizning vazifangiz: bog'liqsiz juftning o'xshashligi

Savol — 90 soniya

$\mathbf{e}_{\text{film}} = [0.8, 0.6]$, $\mathbf{e}_{\text{yomg'ir}} = [-0.6, 0.8]$ (ikkalasi uzunligi 1):

$\cos(\mathbf{film}, \mathbf{yomg'ir}) = ?$

Sizning vazifangiz: bog'liqsiz juftning o'xshashligi

Savol — 90 soniya

$\mathbf{e}_{\text{film}} = [0.8, 0.6]$, $\mathbf{e}_{\text{yomg'ir}} = [-0.6, 0.8]$ (ikkalasi uzunligi 1):
 $\cos(\text{film}, \text{yomg'ir}) = ?$

Javob

$$\mathbf{e}_{\text{film}} \cdot \mathbf{e}_{\text{yomg'ir}} = 0.8 \cdot (-0.6) + 0.6 \cdot 0.8 = -0.48 + 0.48 = 0$$

$$\cos = \frac{0}{1 \cdot 1} = 0$$

Bog'liqsiz so'zlar $\Rightarrow \cos \approx 0$. Model $\text{film} \approx \text{kino}$ (0.96) ni $\text{film} / \text{yomg'ir}$ (0) dan ajrata oladi — aynan kerakli xulq.

Kod $\leftrightarrow$ formula: o'xshashlik va eng o'xshashlar

```
1 import numpy as np
2
3 def cosine(a, b):
4     return a @ b / (np.linalg.norm(a) *
5                     np.linalg.norm(b))
6
7 e_film      = np.array([0.8, 0.6])
8 e_kino      = np.array([0.6, 0.8])
9 e_yomgir    = np.array([-0.6, 0.8])
10
11 print(round(cosine(e_film, e_kino), 2))    #
12     0.96
13 print(round(cosine(e_film, e_yomgir), 2))  # 0.0
14
15 # gensim: model.wv.most_similar("film")
```

Kod $\rightarrow$ formula:

Kod	Formula
$a @ b$	$\mathbf{a} \cdot \mathbf{b}$
$\text{norm}(a)$	$\ \mathbf{a}\ $
$a @ b / (\dots)$	$\cos(\mathbf{a}, \mathbf{b})$

Ertangi P6 da m06.most_similar aynan kosinusga tayanadi — L3 dagi m03 bilan bir xil o'lchov.

Baholash tuzog'i: kam ma'lumotda embedding "shovqinli"

Kam korpus

Kam uchragan so'z (masalan 2–3 marta) yetarli kontekst ko'rmaydi — uning vektori **shovqinli**, cos qiymatlari tasodifiy bo'lib chiqadi.

Yechim: `min_count` bilan kam so'zlarni tashlash; korpusni kattalashtirish; o'zbek uchun — stemming (m01) bilan shakllarni birlashtirish.

Eslatma: `dim=2` misol — pedagogik; amalda $d = 100\text{--}300$.

Prezentatsiya rejasi

- 1 Kirish: so'zlarni o'rganilgan vektorlar bilan ifodalaymiz
- 2 Nega o'rganiladigan zich vektorlar?
- 3 CBOW arxitekturasini kontekstdan markazga
- 4 Neyron tarmoqni o'qitish: yo'qotish va backprop
- 5 O'qitish jarayoni va embedding sifatini baholash
- 6 Xulosa va amaliyotga ko'prik

O'zbek tilida: agglutinatsiya lug'atni portlatadi — CBOW yordam bera oladimi?

1. Vocabulary explosion:

o'rganaman, o'rganadi, o'rgandim — bir o'zak, **uch alohida** token.

Oqibat

Lug'at $|V|$ portlaydi; har shakl kam uchraydi $\Rightarrow$ kam kontekst $\Rightarrow$ shovqinli vektor (4-tsikl [L]).

2. CBOW qisman yordam beradi:

Bu shakllar **o'xshash kontekstlarda** keladi $\Rightarrow$ CBOW ularga **yaqin** vektorlar berishi mumkin.

Lekin to'liq emas

CBOW so'zni **bo'linmas** deb biladi — o'zak umumiylikini ko'rmaydi. To'liq yechim: **subword** (FastText) — keyingi mavzular.

Bugungi amaliy: m01 stemming CBOW dan oldin lug'atni kichraytiradi.

Sintez: soʻz ifodalari — siyrakdan zich, oʻrganilganga

Ifoda	Oʻlcham	Oʻxshashlik	Izoh
One-hot TF-IDF (L1)	$ V $ (katta) $ V $	yoʻq ($\cos = 0$) qisman	siyrak, kontekstsiz hujjat-darajali, siyrak
Pretrained (L3)	d (kichik)	bor	tayyor; oʻzbek coverage past
CBOW (bu-gun)	d (kichik)	bor	korpusdan oʻrganilgan

Asosiy gʻoya

CBOW: **kontekstni oʻrtachalab** markazni bashorat qiladi; xato ($\hat{y} - y$) vektorlarni yangilaydi; natijada **yaqin maʼno** $\rightarrow$ **yaqin vektor**. Bu — oʻz korpusingizda oʻrganiladigan zich ifoda.

Seminal manba: Mikolov va boshqalar (2013)

Mikolov, T., Chen, K., Corrado, G., Dean, J. (2013). **Efficient Estimation of Word Representations in Vector Space**. *ICLR 2013 (Workshop Track)*.

Ahamiyati:

- **Word2Vec** ni kiritdi — CBOW va Skip-gram (40 000+ iqtibos).
- Sodda, sayoz model — ulkan korpusda tez o'qiydi.
- Vektor arifmetikasi: $\text{shoh} - \text{erkak} + \text{ayol} \approx \text{malika}$.


Muhokama savoli (P6 gacha o'ylang)

CBOW kontekstdan markazni, Skip-gram markazdan kontekstni bashorat qiladi. **Kam ma'lumotli** o'zbek korpusi uchun qaysi biri afzalroq bo'lishi mumkin — nega?

Bugungi maqsadlar bajarildi

- 1 ✓ **Keltirib chiqardik:** nega one-hot yetarli emas — $\cos(\text{film}, \text{kino}) = 0$ (o'xshashlik yo'qoladi).
- 2 ✓ **Tushuntirdik:** CBOW arxitekturasini — $\text{CBOW}_{\text{kirish}} = [0.3, 0.5]$ (kontekst o'rtachasi).
- 3 ✓ **Hisobladik:** $\text{softmax } \hat{y}(\text{nlp}) = 0.690$, yo'qotish 0.371 , gradient $\hat{y} - y$.
- 4 ✓ **Baholadik:** o'rganilgan embedding — $\cos(\text{film}, \text{kino}) = 0.96$.

Ertaga P6: o'zbek korpusida CBOW ni noldan o'qitamiz



P6 da qurasiz:

- m06 CustomWord2Vec: CBOW proyeksiya + o'qitish
- `embed(word)`, `most_similar`
- O'zbek korpusida sinonim/analogiya testi

Birinchi assert (bu slayd [I2]):

```
assert np.allclose(  
    cbow_input, [0.3, 0.5])  
  
# Ma'ruza L6 [I2]-slayd bilan  
# solishtiring (kontekst o'rtachasi)
```

- ① Mikolov, T., Chen, K., Corrado, G., Dean, J. (2013). *Efficient Estimation of Word Representations in Vector Space*. ICLR 2013.
- ② Mikolov, T., Sutskever, I., et al. (2013). *Distributed Representations of Words and Phrases and their Compositionality*. NeurIPS 26. (Negative sampling.)
- ③ Rong, X. (2014). *word2vec Parameter Learning Explained*. arXiv:1411.2738. (Backprop batafsil keltirib chiqarish.)
- ④ Jurafsky, D., Martin, J.H. (2023). *Speech and Language Processing*, 3-nashr. 6-bob: Vektor semantikasi va embeddinglar.
- ⑤ `gensim.models.Word2Vec` hujjatlari — CBOW va Skip-gram.

Ilova S1: Skip-gram — CBOW ning teskarisi

CBOW kontekstdan markazni bashorat qiladi; **Skip-gram** markazdan har bir kontekst so'zni bashorat qiladi:

$$\mathcal{L}_{SG} = - \sum_j \ln P(c_j \mid w_{\text{markaz}})$$

bunda: w_{markaz} — markaziy so'z; c_j — oyna ichidagi kontekst so'zlari.

Amaliy farq: Skip-gram kam uchraydigan so'zlar va kichik korpusda ko'pincha yaxshiroq; CBOW tez va tez-tez uchraydigan so'zlarda silliqroq. (O ning muhokama savoliga ishora.)

Ilova S2: negative sampling yo'qotishi

To'liq softmax ($|V|$ bo'yicha) o'rniga, har juft uchun target $+ K$ ta tasodifiy salbiy so'z:

$$\mathcal{L}_{\text{neg}} = -\ln \sigma(\mathbf{v}'_c \cdot \mathbf{h}) - \sum_{i=1}^K \ln \sigma(-\mathbf{v}'_{n_i} \cdot \mathbf{h})$$

bunda: σ — sigmoid; c — target; n_i — salbiy namunalar; $K \sim 5-20$.

Natija: har qadam $|V|$ emas, $K+1$ ta hisob — o'qitish bir necha tartibga tezlashadi. Gensim (P6) buni standart sifatida ishlatadi.