

Rekurrent neyron tarmoqlar (RNN)

Tabiiy tilni qayta ishlash — 7-ma'ruza

A.A. Abdulali

11:00–12:20 · mavzu №7

25-iyun 2026

Prezentatsiya rejasi

- 1 Kirish: ketma-ketlikni xotira bilan modellaymiz
- 2 Sobit oynadan ketma-ket xotiraga
- 3 RNN konsepsiyasi: yashirin holat
- 4 Vaqt bo'ylab yoyilish va BPTT
- 5 Til modellashtirish va matn tasniflash
- 6 Xulosa va amaliyotga ko'prik

Takrorlash: o'tgan darslardan ikki savol

1-savol

L5 da bigram faqat **1 oldingi** so'zga qaradi. "men kitobni do'stinga ____" — kesim uzoqda. Sobit oyna uzoq bog'liqlikni ko'ra oladimi?

2-savol

Bugun ertalab P6 da Word2Vec har **so'zga** vektor berdi. Lekin gap — so'zlar **ketma-ketligi**. Embedding o'zi tartibni/xotirani saqlaydimi?

Takrorlash: o'tgan darslardan ikki savol

1-savol

L5 da bigram faqat **1 oldingi** so'zga qaradi. “men kitobni do'stimga _____” — kesim uzoqda. Sobit oyna uzoq bog'liqlikni ko'ra oladimi?

2-savol

Bugun ertalab P6 da Word2Vec har **so'zga** vektor berdi. Lekin gap — so'zlar **ketma-ketligi**. Embedding o'zi tartibni/xotirani saqlaydimi?

1-javob

Yo'q. Sobit oyna faqat $n-1$ so'zni ko'radi; undan uzoqdagi kesim ko'rinmaydi (Markov cheklovi).

2-javob

Yo'q. Har vektor mustaqil — ketma-ketlik tartibi yo'qoladi. Bugun **xotirali** model quramiz: RNN.

Siz bugungi dars oxirida quyidagilarni bajara olasiz:

- ➊ **Tushuntira olasiz:** nega sobit oyna (N-gram/feedforward) uzoq bog'liqlikni ushlay olmaydi.
- ➋ **Hisoblay olasiz:** RNN bir qadamini qo'lda — $h_t = \tanh(W_h h_{t-1} + W_x x_t)$, $h_1 = [0.762, 0.000]$.
- ➌ **Tushuntira olasiz:** vaqt bo'ylab yoyilish (unrolling), og'irliklar ulashilishi va BPTT g'oyasini.
- ➍ **Qo'llay olasiz:** RNN ni til modellashtirish va matn tasniflashda (ko'p-dan-bir).

L5 dan: til modeli, Markov taxmini. L6 dan: embedding (kirish vektori), softmax, gradient. Matematikadan: matritsa-vektor ko'paytma, tanh, zanjir qoidasi.

Bugungi dars rejasi:

Tsiki	Mavzu	Vaqt	Hosil natija	bo'luvchi
1	Sobit oynadan ketma-ket xotiraga	16 daq	Oyna cheklovi	
2	RNN konsepsiyasi: yashirin holat	20 daq	$h_1 = [0.762, 0.000]$	
3	Vaqt bo'ylab yoyilish va BPTT	18 daq	$h_2 = [0.642, 0.762]$	
4	Til modeli va matn tasniflash	16 daq	softmax $\rightarrow$ ijobiy	
	Xulosa va 7-amaliyotga ko'rsatmalar	10 daq	Ertaga nima qurishingiz	

Bu dars neyron ketma-ketlik modellarini ochadi

N-gram (L5) va embedding (L6) dan **rekurrent** modellarga o'tamiz. Bugungi $h_1 = [0.762, 0.000]$ ertangi P7 da assert bo'ladi.

Bugungi dars uchun muammo: gap uzunligi har xil, kesim uzoqda

Sodda yechim qayerda qiynaladi:

Sobit oyna ko'r

Embeddinglarni **sobit** oynada birlashtiramiz (feedforward LM). "men kitobni do'stinga berdim" — kesim berdim oynadan tashqarida qolsa, ko'rinmaydi.

Oynani kattalashtirish qimmat

Oyna k ortsa, parametrlar soni ham ortadi; baribir **chegaralangan** uzunlik.

Bugungi yechim:

- 1 So'zlarni **birma-bir** o'qiymiz.
- 2 Har qadamda **yashirin holat**ni (xotira) yangilaymiz.
- 3 Holat o'tmishning "xulosasi" — ixtiyoriy uzunlikni ushlaydi.

Bu g'oyaning nomi — **rekurrent neyron tarmoq (RNN)**: bir xil amalni ketma-ketlik bo'ylab **takrorlaydi**.

Prezentatsiya rejasi

- 1 Kirish: ketma-ketlikni xotira bilan modellaymiz
- 2 **Sobit oynadan ketma-ket xotiraga**
- 3 RNN konsepsiyasi: yashirin holat
- 4 Vaqt bo'ylab yoyilish va BPTT
- 5 Til modellashtirish va matn tasniflash
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: sobit oyna — “teshikdan” qarash

Feedforward neyron til modeli: oxirgi k so'z embeddingini **birlashtirib** (concat) keyingisini bashorat qiladi.

[men] [kitobni] $\rightarrow$ keyingi so'z?

Muammo: k **sobit**. k dan uzoqdagi so'z umuman kirmaydi — xuddi tor teshikdan qaragandek.

N-gram sanadi, feedforward LM **o'rganadi** — lekin ikkalasi ham sobit oynaga bog'liq. Bizga oyna emas, **xotira** kerak.

Feedforward neyron til modeli: rasmiy ta'rif

$$\mathbf{c} = [\mathbf{e}_{w_{t-k}}; \dots; \mathbf{e}_{w_{t-1}}], \quad \hat{\mathbf{y}} = \text{softmax}(W \mathbf{c} + \mathbf{b})$$

bunda: $\mathbf{e}_w$ — w so'zning embeddingi (L6); $[\ ; \]$ — **birlashtirish** (concatenation); k — sobit oyna o'lchami; $\mathbf{c}$ — $k \cdot d$ o'lchamli kirish; $\hat{\mathbf{y}}$ — lug'at ustidan keyingi so'z taqsimoti. **Diqqat:** kirish o'lchami $k \cdot d$ — **sobit**. Gap uzunligi o'zgaruvchan bo'lsa ham, model faqat k ta so'zni ko'radi.

Keltirib chiqarish: nega sobit oyna uzoq bog'liqlikni uzadi?

1-qadam. Bashorat faqat $\mathbf{c} = [\mathbf{e}_{w_{t-k}}; \dots; \mathbf{e}_{w_{t-1}}]$ ga bog'liq — k so'zdan narisi kirmaydi.

Keltirib chiqarish: nega sobit oyna uzoq bog'liqlikni uzadi?

1-qadam. Bashorat faqat $\mathbf{c} = [\mathbf{e}_{w_{t-k}}; \dots; \mathbf{e}_{w_{t-1}}]$ ga bog'liq — k so'zdan narisi kirmaydi.

2-qadam. O'zbekcha SOV: *“men kitobni do'stinga berdim”* — kesim berdim gap oxirida. Agar $k = 2$ bo'lsa, *men/kitobni* berdim ni bashoratlashga ta'sir qila olmaydi.

Keltirib chiqarish: nega sobit oyna uzoq bog'liqlikni uzadi?

1-qadam. Bashorat faqat $\mathbf{c} = [\mathbf{e}_{w_{t-k}}; \dots; \mathbf{e}_{w_{t-1}}]$ ga bog'liq — k so'zdan narisi kirmaydi.

2-qadam. O'zbekcha SOV: *“men kitobni do'stinga berdim”* — kesim berdim gap oxirida.

Agar $k = 2$ bo'lsa, men/kitobni berdim ni bashoratlashga ta'sir qila olmaydi. **3-qadam.** k ni oshirish — W o'lchami $k \cdot d$ ga proporsional ortadi (parametr portlashi), va baribir uzunlik **chegaralangan**.

Xulosa: kerakli narsa — sobit oyna emas, o'tmishni **ixcham holat**ga jamlaydigan mexanizm. Bu — RNN.

Qo'lda misol: kontekst vektorini birlashtirish

$$\mathbf{e}_{\text{men}} = [0.5, 0.3], \quad \mathbf{e}_{\text{kitobni}} = [0.2, 0.6].$$

Birlashtiramiz:

$$\begin{aligned}\mathbf{c} &= [\mathbf{e}_{\text{men}}; \mathbf{e}_{\text{kitobni}}] \\ &= [0.5, 0.3, 0.2, 0.6]\end{aligned}$$

$$\text{Kirish o'lchami} = k \cdot d = 2 \cdot 2 = 4.$$

Uchinchi so'z qo'shilsa, $\mathbf{c}$ **6** o'lchamli bo'lardi — W ham kattalashadi. Sobit k shuning uchun zarur, ammo cheklovchi.

Sizning vazifangiz: yana bir birlashtirish

Savol — 60 soniya

$\mathbf{e}_u = [0.1, 0.9]$, $\mathbf{e}_{\text{keldi}} = [0.4, 0.4]$, oyna $k = 2$:

$\mathbf{c} = ?$ **va uning o'lchami nechta?**

Sizning vazifangiz: yana bir birlashtirish

Savol — 60 soniya

$\mathbf{e}_u = [0.1, 0.9]$, $\mathbf{e}_{keldi} = [0.4, 0.4]$, oyna $k = 2$:

$\mathbf{c} = ?$ **va uning o'lchami nechta?**

Javob

$\mathbf{c} = [\mathbf{e}_u; \mathbf{e}_{keldi}] = [0.1, 0.9, 0.4, 0.4]$, o'lcham $= 2 \cdot 2 = 4$.

Har qo'shilgan so'z kirishni d ga kattalashtiradi — model o'zgaruvchan uzunlikka moslasha olmaydi.

Kod ↔ formula: sobit-oynali kirish

```
1 import numpy as np
2
3 e_men      = np.array([0.5, 0.3])
4 e_kitobni = np.array([0.2, 0.6])
5
6 # sobit oyna: embeddinglarni birlashtirish
7 c = np.concatenate([e_men, e_kitobni])
8 print(c, c.shape)      # [0.5 0.3 0.2 0.6] (4,)
9
10 # W ning ustun soni = k * d ga bog'liq (sobit)
11 W = np.random.randn(10, c.shape[0])
```

Kod → formula:

Kod	Formula
concatenate	$[e; e]$
c.shape	$k \cdot d$
W @ c	Wc

W ning kengligi sobit — gap uzunligiga moslasha olmaydi. RNN buni hal qiladi.

Sobit oyna tuzog'i: ikki yomon tanlov

Murosa

- Kichik $k \Rightarrow$ uzoq bog'liqlik yo'qoladi.
- Katta $k \Rightarrow$ parametr portlashi, ortiqcha moslashish.
- Har holatda uzunlik **chegaralangan**.

Yechim: o'tmishni sobit o'lchamli **holat**ga jamlash va uni har qadamda **bir xil** og'irliklar bilan yangilash — RNN (2-tsikl).

Prezentatsiya rejasi

- 1 Kirish: ketma-ketlikni xotira bilan modellaymiz
- 2 Sobit oynadan ketma-ket xotiraga
- 3 RNN konsepsiyasi: yashirin holat**
- 4 Vaqt bo'ylab yoyilish va BPTT
- 5 Til modellashtirish va matn tasniflash
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: o'qiyotganda “xayolda” xulosa saqlaymiz

Gapni o'qiyotganda har so'zdan keyin **tushunchamizni** yangilaymiz — boshidan qayta o'qimaymiz.

RNN ham shunday: **yashirin holat** h_t — “shu paytgacha o'qilganlarning xulosasi”.

Har qadam: h_t — oldingi holat h_{t-1} va joriy so'z x_t dan.

Bir xil amal (bir xil W_h, W_x) har qadamda **takrorlanadi** — shuning uchun “rekurrent”. Uzunlik muhim emas.

RNN rekurrensiyasi: rasmiy ta'rif

$$h_t = \tanh(W_h h_{t-1} + W_x x_t + b)$$

bunda: x_t — t qadamdagi kirish (so'z embeddingi); h_t — yashirin holat (xotira); W_h — holat→holat, W_x — kirish→holat og'irliklari; b — bias; $\tanh$ — nochiziqlilik; $h_0 = \mathbf{0}$. **Asosiy nuqta:** W_h, W_x

barcha qadamlarda bir xil (ulashilgan). Holat o'lchami sobit — gap uzunligidan mustaqil.

Keltirib chiqarish: rekurrensiya qayerdan keladi?

1-qadam. Maqsad: butun o'tmish $x_1 \dots x_t$ ni **sobit o'lchamli** holatga jamlash.

Keltirib chiqarish: rekurrensiya qayerdan keladi?

1-qadam. Maqsad: butun o'tmish $x_1 \dots x_t$ ni **sobit o'lchamli** holatga jamlash. **2-qadam.** Rekursiv ta'rif — yangi holat eski holat va yangi kirishdan:

$$h_t = f(h_{t-1}, x_t)$$

Keltirib chiqarish: rekurrensiya qayerdan keladi?

1-qadam. Maqsad: butun o'tmish $x_1 \dots x_t$ ni **sobit o'lchamli** holatga jamlash. **2-qadam.** Rekursiv ta'rif — yangi holat eski holat va yangi kirishdan:

$$h_t = f(h_{t-1}, x_t)$$

3-qadam. f ni eng sodda o'rganiladigan ko'rinishda olamiz: chiziqli birikma + nochiziqlilik:

$$h_t = \tanh(W_h h_{t-1} + W_x x_t + b)$$

Xulosa: h_t rekursiya orqali $x_1 \dots x_t$ ning hammasiga bog'liq — sobit oyna yo'q. $\tanh$ holatni $[-1, 1]$ da ushlaydi.

Qo'lda misol: RNN bir qadami — $h_1 = [0.762, 0.000]$

$$W_h = W_x = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \text{ (birlik matritsa), } b = \mathbf{0}, \quad h_0 = [0, 0].$$

Hisoblaymiz:

$$\begin{aligned} h_1 &= \tanh(W_h h_0 + W_x x_1) \\ &= \tanh([0, 0] + [1, 0]) \\ &= [\tanh(1), \tanh(0)] \\ &= [\mathbf{0.762}, \mathbf{0.000}] \end{aligned}$$

$\tanh(1) \approx 0.7616$, $\tanh(0) = 0$. Holat
birinchi so'zning "izi"ni saqladi.

Ertangi P7 birinchi assert:
`np.allclose(h1,
[0.762, 0.0], atol=1e-3)`
Ma'ruza L7 [12]-slyd

Sizning vazifangiz: boshqa kirish uchun h_1

Savol — 90 soniya

Xuddi shu RNN ($W_h = W_x = I$, $b = 0$, $h_0 = [0, 0]$), lekin $x_1 = [0, 1]$:
 $h_1 = ?$

Sizning vazifangiz: boshqa kirish uchun h_1

Savol — 90 soniya

Xuddi shu RNN ($W_h = W_x = I$, $b = 0$, $h_0 = [0, 0]$), lekin $x_1 = [0, 1]$:
 $h_1 = ?$

Javob

$$h_1 = \tanh([0, 0] + [0, 1]) = [\tanh(0), \tanh(1)] = [0.000, 0.762]$$

Kirish ikkinchi o'lchamda edi $\Rightarrow$ "iz" ham ikkinchi o'lchamda. Birlik matritsada har kirish o'z o'rnida saqlanadi.

Kod $\leftrightarrow$ formula: RNN bir qadami

```
1 import numpy as np
2
3 Wh = np.eye(2)           # I_2
4 Wx = np.eye(2)           # I_2
5 b  = np.zeros(2)
6
7 def rnn_step(h_prev, x):
8     return np.tanh(Wh @ h_prev + Wx @ x + b)
9
10 h0 = np.zeros(2)
11 h1 = rnn_step(h0, np.array([1.0, 0.0]))
12 print(h1)                 # [0.762 0.0]
```

Kod $\rightarrow$ formula:

Kod	Formula
Wh @ h_prev	$W_h h_{t-1}$
Wx @ x	$W_x x_t$
np.tanh(...)	$\tanh(\cdot)$

Ertangi P7 da m07 RNNClassifier aynan shu qadamni (PyTorch nn.RNN) ishlatadi.

RNN tuzog'i: holatni boshlash va tartib muhim

Keng tarqalgan xatolar


- h_0 ni unutib, oldingi gap holatini olib qolish.
- So'z tartibini buzish — RNN tartibga **sezgir** (“it odamni qopdi” $\neq$ “odam itni qopdi”).
- $\tanh$ o'rniga noto'g'ri noxiziqlilik.

Yechim: har ketma-ketlik uchun $h_0 = \mathbf{0}$ dan boshlang; so'z tartibini saqlang. Tartibga sezgirlik — RNN ning **kuchi**.

Prezentatsiya rejasi

- 1 Kirish: ketma-ketlikni xotira bilan modellaymiz
- 2 Sobit oynadan ketma-ket xotiraga
- 3 RNN konsepsiyasi: yashirin holat
- 4 Vaqt bo'ylab yoyilish va BPTT**
- 5 Til modellashtirish va matn tasniflash
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: bir katakni vaqt bo'ylab yoyamiz



Bu — **bitta** katakning uch qadamga “yoyilgani” (unrolling). Uchala nusxa **bir xil** W_h , W_x ni ulashadi — shuning uchun har xil uzunlikdagi gaplar uchun ishlaydi.

$$\frac{\partial \mathcal{L}}{\partial W_h} = \sum_{t=1}^T \frac{\partial \mathcal{L}_t}{\partial W_h}, \quad \frac{\partial h_t}{\partial h_{t-1}} = \text{diag}(1 - h_t^2) W_h$$

bunda: T — ketma-ketlik uzunligi; yoyilgan tarmoq oddiy chuqur tarmoqdek; W_h **ulashilgani** uchun gradientlar barcha qadamlar bo'ylab **yig'iladi**; $1 - h_t^2$ — tanh hosilasi. Yoyilgandan keyin — bu shunchaki chuqur tarmoq; oddiy backprop qo'llanadi, faqat W_h takror ishlatilgani uchun gradientlar qo'shiladi.

Keltirib chiqarish: gradient nega qadamlar ko'paytmasi?

1-qadam. h_T uzoq h_t ga zanjir qoidasi orqali bog'liq:

$$\frac{\partial h_T}{\partial h_t} = \prod_{s=t+1}^T \frac{\partial h_s}{\partial h_{s-1}}$$

Keltirib chiqarish: gradient nega qadamlar ko'paytmasi?

1-qadam. h_T uzoq h_t ga zanjir qoidasi orqali bog'liq:

$$\frac{\partial h_T}{\partial h_t} = \prod_{s=t+1}^T \frac{\partial h_s}{\partial h_{s-1}}$$

2-qadam. Har bo'g'in $\frac{\partial h_s}{\partial h_{s-1}} = \text{diag}(1 - h_s^2) W_h$ — **ko'paytma** hosil bo'ladi.

Keltirib chiqarish: gradient nega qadamlar ko'paytmasi?

1-qadam. h_T uzoq h_t ga zanjir qoidasi orqali bog'liq:

$$\frac{\partial h_T}{\partial h_t} = \prod_{s=t+1}^T \frac{\partial h_s}{\partial h_{s-1}}$$

2-qadam. Har bo'g'in $\frac{\partial h_s}{\partial h_{s-1}} = \text{diag}(1 - h_s^2) W_h$ — **ko'paytma** hosil bo'ladi. **3-qadam.** Ko'p bo'g'in ko'paytmasi: agar har bo'g'in < 1 bo'lsa, ko'paytma **eksponensial so'nadi** (vanishing); > 1 bo'lsa portlaydi (exploding).

Xulosa: uzoq bog'liqlik gradienti so'nadi $\Rightarrow$ RNN uzoq xotirani **o'rganishda qiynaladi**. Bu — L8 (LSTM/GRU) sababi.

Qo'lda misol: ikkinchi qadam — $h_2 = [0.642, 0.762]$

$$h_1 = [0.762, 0.000] \text{ (oldingi tsikldan), } x_2 = [0, 1].$$

Hisoblaymiz:

$$\begin{aligned} h_2 &= \tanh(W_h h_1 + W_x x_2) \\ &= \tanh([0.762, 0] + [0, 1]) \\ &= [\tanh(0.762), \tanh(1)] \\ &= [\mathbf{0.642}, \mathbf{0.762}] \end{aligned}$$

$\tanh(0.762) \approx 0.642$. Holat endi **ikkala** so'zning izini saqlaydi — xotira ketma-ket to'planadi.

Sizning vazifangiz: tanh hosilasini bahola

Savol — 90 soniya

BPTT bo'g'inida tanh hosilasi $1 - h^2$. Agar holat komponenti $h = 0.762$ bo'lsa:

$1 - h^2 = ?$ **(bu < 1 mi?)**

Sizning vazifangiz: tanh hosilasini bahola

Savol — 90 soniya

BPTT bo'g'inida tanh hosilasi $1 - h^2$. Agar holat komponenti $h = 0.762$ bo'lsa:

$1 - h^2 = ?$ **(bu < 1 mi?)**

Javob

$1 - 0.762^2 = 1 - 0.581 = \mathbf{0.419}$ (< 1).

Har bo'g'in ≈ 0.42 bo'lsa, 10 qadamdan keyin $0.42^{10} \approx 1.7 \times 10^{-4}$ — gradient **so'nadi**. Mana vanishing gradient.

Kod $\leftrightarrow$ formula: ketma-ketlik bo'ylab aylanish

```
import numpy as np

Wh = np.eye(2); Wx = np.eye(2)

def rnn_forward(xs, h0):
    h = h0
    for x in xs:                                # vaqt bo'ylab
                                                yoyilish
        h = np.tanh(Wh @ h + Wx @ x)
    return h

xs = [np.array([1.0, 0.0]),
      np.array([0.0, 1.0])]
hT = rnn_forward(xs, np.zeros(2))
print(hT)                                     # [0.642
0.762]
```

Kod $\rightarrow$ formula:

Kod	Formula
for x in xs	$t = 1 \dots T$
h =	h_t rekursiya
tanh(...)	
return h	h_T

Bir xil W_h , W_x har aylanishda — og'irliklar ulashilishi. Sikl — yoyilishning kod ko'rinishi.

Yoyilish tuzog'i: yo'qoluvchi va portlovchi gradient

Uzoq bog'liqlik so'nadi

$\tanh$ hosilasi ≤ 1 ; ko'p qadam ko'paytmasi $\Rightarrow$ gradient **nolga intiladi**. RNN 10–20 qadamdan uzoqni eslab qola olmaydi.

Yechimlar

- Gradient kesish (clipping) — portlashga.
- **LSTM / GRU** — darvozalar bilan xotira (L8).

O'zbekcha uzun qo'shimcha zanjiri va SOV — aynan uzoq bog'liqlik talab qiladi ([M]).

Prezentatsiya rejasi

- 1 Kirish: ketma-ketlikni xotira bilan modellaymiz
- 2 Sobit oynadan ketma-ket xotiraga
- 3 RNN konsepsiyasi: yashirin holat
- 4 Vaqt bo'ylab yoyilish va BPTT
- 5 Til modellashtirish va matn tasniflash**
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: bir xil RNN, ikki vazifa

Til modeli (ko'p-dan-ko'p): har qadamda keyingi so'zni bashorat — har h_t ustidan softmax.

Matn tasniflash (ko'p-dan-bir): butun gapni o'qib, **oxirgi** holat h_T dan sinf (masalan ijobiy/salbiy).

Yadro bir xil — rekurrensiya. Faqat **chiqish** qatlami vazifaga qarab o'zgaradi. Ertaga P7 da ijobiy/salbiy tasniflaymiz.

RNN chiqish qatlami: rasmiy ta'rif

$$\mathbf{z} = W_o h_T + b_o, \quad \hat{\mathbf{y}} = \text{softmax}(\mathbf{z})$$

bunda: h_T — oxirgi yashirin holat (butun gap xulosasi); W_o — chiqish og'irliklari; $\mathbf{z}$ — sinf ballari (logits); $\hat{\mathbf{y}}$ — sinflar ehtimoli (ijobiy/salbiy). **Til modeli uchun:** har h_t ustidan softmax (lug'at ustidan) — keyingi so'z taqsimoti (L6 dagi softmax bilan bir xil).

Keltirib chiqarish: nega oxirgi holat h_T ?

1-qadam. h_T rekursiya orqali $x_1 \dots x_T$ ning **hammasiga** bog'liq — butun gapning xulosasi.

Keltirib chiqarish: nega oxirgi holat h_T ?

1-qadam. h_T rekursiya orqali $x_1 \dots x_T$ ning **hammasiga** bog'liq — butun gapning xulosasi.

2-qadam. Tasniflash uchun bitta vektor kerak; h_T aynan shu — o'zgaruvchan uzunlikni **sobit** o'lchamga jamlaydi.

Keltirib chiqarish: nega oxirgi holat h_T ?

1-qadam. h_T rekursiya orqali $x_1 \dots x_T$ ning **hammasiga** bog'liq — butun gapning xulosasi.

2-qadam. Tasniflash uchun bitta vektor kerak; h_T aynan shu — o'zgaruvchan uzunlikni **sobit** o'lchamga jamlaydi. **3-qadam.** Uni chiziqli qatlam + softmax bilan sinfga aylantiramiz:

$$\hat{\mathbf{y}} = \text{softmax}(W_o h_T + b_o)$$

Xulosa: RNN o'zgaruvchan uzunlikdagi matnni sobit vektorga (h_T) “kodlaydi” — keyin oddiy klassifikator yetarli.

Qo'lda misol: oxirgi holatdan sentimentga

Chiqish vektorlari: W_o qatorlari $\mathbf{w}_{ijobiy} = [1, 0]$, $\mathbf{w}_{salbiy} = [0, 1]$; $b_o = 0$.

Ballar va softmax:

$$z_{ijobiy} = [1, 0] \cdot [1, 0] = 1$$

$$z_{salbiy} = [0, 1] \cdot [1, 0] = 0$$

$$\hat{y}_{ijobiy} = \frac{e^1}{e^1 + e^0} \approx \mathbf{0.731}$$

$0.731 > 0.5 \Rightarrow$ bashorat **ijobiy**.
RNN gapni o'qib, oxirgi holatdan sinfni aniqladi.

Sizning vazifangiz: teskari ball

Savol — 60 soniya

Agar $h_T = [0, 1]$ bo'lsa (xuddi shu W_o):

$\hat{y}_{ijobiy} = ?$ **bashorat qaysi sinf?**

Sizning vazifangiz: teskari ball

Savol — 60 soniya

Agar $h_T = [0, 1]$ bo'lsa (xuddi shu W_o):

$\hat{y}_{ijobiy} = ?$ **bashorat qaysi sinf?**

Javob

$$z_{ijobiy} = [1, 0] \cdot [0, 1] = 0, \quad z_{salbiy} = [0, 1] \cdot [0, 1] = 1.$$

$$\hat{y}_{ijobiy} = \frac{e^0}{e^0 + e^1} \approx \mathbf{0.269} \Rightarrow \text{bashorat } \mathbf{salbiy}.$$

Oxirgi holat ikkinchi o'lchamga "egilgan" $\Rightarrow$ salbiy sinf ustun.

Kod ↔ formula: PyTorch nn.RNN

```
1 import torch.nn as nn
2
3 class RNNClassifier(nn.Module):
4     def __init__(self, vocab, dim, hid, n_cls):
5         super().__init__()
6         self.emb = nn.Embedding(vocab, dim)
7         self.rnn = nn.RNN(dim, hid, batch_first=
            True)
8         self.out = nn.Linear(hid, n_cls)
9
10    def forward(self, x):
11        e = self.emb(x)                # embedding
12        _, h = self.rnn(e)             # h: oxirgi
13                                       # holat  $h_T$ 
14        return self.out(h[-1])         #  $W_o h_T +$ 
15                                       #  $b_o$ 
```

Kod → formula:

Kod	Formula
nn.Embedding	x_t (L6)
nn.RNN	$h_t = \tanh(\dots)$
h[-1]	h_T
nn.Linear	$W_o h_T + b_o$

Ertangi P7 da m07
RNNClassifier aynan shu
arxitekturani quradi.

Qo'llash tuzog'i: padding va o'zgaruvchan uzunlik

Batch da uzunlik har xil

Gaplar har xil uzunlikda; batch uchun **padding** kerak. Lekin padding tokenlari h_T ga ta'sir qilib, natijani buzishi mumkin.

Yechim: `pack_padded_sequence` (PyTorch) yoki `masking` — haqiqiy oxirgi holatni olish. P7 da periferiya sifatida beriladi.

Prezentatsiya rejasi

- 1 Kirish: ketma-ketlikni xotira bilan modellaymiz
- 2 Sobit oynadan ketma-ket xotiraga
- 3 RNN konsepsiyasi: yashirin holat
- 4 Vaqt bo'ylab yoyilish va BPTT
- 5 Til modellashtirish va matn tasniflash
- 6 Xulosa va amaliyotga ko'prik

O'zbek tilida: SOV tartibi va uzun qo'shimchalar RNN ni sinaydi

1. SOV — kesim oxirida:

“men kitobni do'stinga berdim”

Kesim (berdim) **oxirida**. RNN gapni birma-bir o'qib, h_T da butun gapni “eslab” qolishi kerak — aynan uzoq xotira talabi.

2. Uzun qo'shimcha zanjiri:

o'rgan-il-gan-lar-dan — bir so'z, ko'p morfema.

Oqibat

Token-darajali RNN uzoq zanjir va SOV kesimini ushlashi kerak — ammo **vanishing gradient** buni so'ndiradi.

Yechim: LSTM/GRU (L8) — darvozali xotira; yoki m01 stemming.

Sintez: sobit oynadan rekurrent xotiraga

Model	Kontekst	Parametr	Cheklov
N-gram (L5)	sobit $n-1$	lug'at ⁿ (siyrak)	uzoq bog'liqlik yo'q
Feedforward LM	sobit k	$k \cdot d$ ga bog'liq	chegaralangan oyna
RNN (bugun)	ixtiyoriy uzunlik	ulashilgan W_h, W_x	vanishing gradient

Asosiy g'oya

RNN o'tmishni sobit o'lchamli **holat**ga jamlaydi va har qadamda **bir xil** og'irliklar bilan yangilaydi $\Rightarrow$ ixtiyoriy uzunlik. Narxi: uzoq bog'liqlikda gradient so'nadi (L8 buni hal qiladi).

Seminal manba: Rumelhart, Hinton, Williams (1986)

Rumelhart, D.E., Hinton, G.E., Williams, R.J. (1986). **Learning Representations by Back-Propagating Errors.** *Nature*, 323, 533–536.

Ahamiyati:

- Backpropagation ni mashhur qildi — chuqur va rekurrent tarmoqlar asosi.
- BPTT — shu g'oyaning vaqt bo'ylab yoyilgan ko'rinishi.
- Zamonaviy NLP modellarining (RNN→LSTM→Transformer) o'qitish ildizi.


Muhokama savoli (P7 gacha o'ylang)

Agar gradient uzoq qadamlarda so'nsa, RNN “men ... **sevaman**” dagi uzoq bog'liqlikni qanday o'rganadi? Bu cheklovni qanday yengish mumkin? (Maslahat: L8 — darvozalar.)

Bugungi maqsadlar bajarildi

- ① ✓ **Tushuntirdik:** nega sobit oyna (N-gram/feedforward) uzoq bog'liqlikni ushlay olmaydi.
- ② ✓ **Hisobladik:** RNN bir qadami — $h_1 = \tanh([1, 0]) = [0.762, 0.000]$.
- ③ ✓ **Tushuntirdik:** yoyilish, og'irliklar ulashilishi va BPTT ($h_2 = [0.642, 0.762]$; vanishing gradient).
- ④ ✓ **Qo'lladik:** oxirgi holatdan tasniflash — softmax → ijobiy.

Ertaga P7: RNN bilan matn tasniflagichi quramiz



P7 da qurasiz:

- m07 RNNClassifier: Embedding + nn.RNN + Linear
- ijobiy/salbiy tasniflash, F1 baho
- RNN bir qadami h_1 ni tekshirish

Birinchi assert (bu slayd [I2]):

```
assert np.allclose(  
    h1, [0.762, 0.0],  
    atol=1e-3)  
  
# Ma'ruza L7 [I2]-slayd bilan  
# solishtiring (RNN bir qadami)
```

- ❶ Rumelhart, D.E., Hinton, G.E., Williams, R.J. (1986). *Learning Representations by Back-Propagating Errors*. Nature 323:533–536.
- ❷ Elman, J.L. (1990). *Finding Structure in Time*. Cognitive Science 14(2). (Oddiy rekurrent tarmoq.)
- ❸ Werbos, P.J. (1990). *Backpropagation Through Time*. Proc. IEEE 78(10).
- ❹ Jurafsky, D., Martin, J.H. (2023). *Speech and Language Processing*, 3-nashr. 9-bob: RNN va LSTM.
- ❺ `torch.nn.RNN` hujjatlari — PyTorch rekurrent qatlamlar.

Ilova S1: BPTT — gradientlarning yig'ilishi

W_h barcha qadamlarda ulashilgani uchun to'liq gradient har qadam hissasining yig'indisi:

$$\frac{\partial \mathcal{L}}{\partial W_h} = \sum_{t=1}^T \sum_{s=1}^t \frac{\partial \mathcal{L}_t}{\partial h_t} \left(\prod_{r=s+1}^t \frac{\partial h_r}{\partial h_{r-1}} \right) \frac{\partial h_s}{\partial W_h}$$

bunda: ichki ko'paytma — s dan t gacha bo'lgan zanjir; aynan shu ko'paytma uzoq masofada so'nadi yoki portlaydi.

Amalda: gradient kesish (clipping) portlashni, LSTM/GRU darvozalari so'nishni yumshatadi.

Ilova S2: nega aynan tanh?

tanh chiqishni $[-1, 1]$ ga siqadi — holat qiymatlari portlamaydi va markazlashgan (0 atrofida), bu o'qitishni barqarorlashtiradi.

$$\tanh'(x) = 1 - \tanh^2(x) \in (0, 1]$$

bunda: hosila ≤ 1 bo'lgani uchun ko'p qadam ko'paytmasi so'nishga moyil — vanishing gradientning matematik ildizi.

Muqobil: ReLU tez, ammo rekurrentda beqaror bo'lishi mumkin; shuning uchun klassik RNN tanh ishlatadi.