

Neyron mashina tarjimasi: Seq2Seq va Attention

Tabiiy tilni qayta ishlash — 11-ma'ruza

A.A. Abdulali

11:00–12:20 · mavzu №11

2-iyul 2026

Prezentatsiya rejasi

- 1 Kirish: bir tildan boshqasiga tarjima qilamiz
- 2 Enkoder-Dekoder va bottleneck
- 3 Attention: dekodeer ortga qaraydi
- 4 Attention hisoblash: query, key, value
- 5 Tarjimani BLEU bilan baholash
- 6 Xulosa va amaliyotga ko'prik

Takrorlash: o'tgan darslardan ikki savol

1-savol

L9–L10 da LSTM butun gapni ketma-ket o'qib, oxirgi holat h_T da uni "jamladi". Tarjimada manba gapni qanday eslab qolamiz?

2-savol

Butun gapni **bitta** vektorga siqsak, uzun gapda nima yo'qoladi?

Takrorlash: o'tgan darslardan ikki savol

1-savol

L9–L10 da LSTM butun gapni ketma-ket o'qib, oxirgi holat h_T da uni "jamladi". Tarjimada manba gapni qanday eslab qolamiz?

2-savol

Butun gapni **bitta** vektorga siqsak, uzun gapda nima yo'qoladi?

1-javob

Enkoder LSTM manbani h_T ga jamlaydi, dekoder LSTM undan tarjima yaratadi (enkoder-dekoder). Bugun shu arxitekturaning quramini quramiz.

2-javob

Boshlang'ich so'zlar "yuviladi" — **information bottleneck**. Yechim: **attention** (har qadamda manbaga qaytib qarash).

Siz bugungi dars oxirida quyidagilarni bajara olasiz:

- ❶ **Tushuntira olasiz:** enkoder-dekoder arxitekturasini va uning information bottleneck muammosini.
- ❷ **Tushuntira olasiz:** attention — dekoder har qadamda manba so'zlariga "qarab" oladi.
- ❸ **Hisoblay olasiz:** attention vaznlarini — $\alpha = \text{softmax}([2, 1, 3]) = [0.245, 0.090, 0.665]$ va kontekst vektorini.
- ❹ **Hisoblay olasiz:** tarjima sifatini BLEU bilan.

L7–L10 dan: LSTM, Bi-LSTM, ketma-ketlik. L6/L9 dan: softmax. Matematikadan: skalyar ko'paytma, vaznlangan yig'indi, exp.

Bugungi dars rejasi:

Tsikl	Mavzu	Vaqt	Hosil natija	bo'luvchi
1	Enkoder-Dekoder va bottleneck	16 daq	sobit muammosi	kontekst
2	Attention: ortga qarash	16 daq	har qadam	yangi kontekst
3	Attention hisoblash (Q/K/V)	18 daq	α	=
4	BLEU bilan baholash	16 daq	[0.245, 0.090, 0.665] BLEU-1 = 0.667	
	Xulosa va 11-amaliyotga ko'rsatmalar	10 daq	Ertaga nima qurishingiz	

Bu dars attention'ga olib keladi

Enkoder-dekoder bottleneck'ini attention bilan yechamiz. Bugungi $\alpha = [0.245, 0.090, 0.665]$ ertangi P11 da assert bo'ladi.

Bugungi dars uchun muammo: uzun gapni bitta vektorga sig'dirib bo'lmaydi

Sodda yechim qayerda qiynaladi:

Sobit kontekst vektori

Enkoder butun manba gapni **bitta** h_T vektoriga siqadi. Dekoder faqat shunga tayanadi.

Uzun gap = ko'p yo'qotish

Gap uzunlashgani sari boshidagi so'zlar axboroti "yuviladi" — tarjima sifati tushadi.

Bugungi yechim:

- 1 Enkoder **har** so'z uchun holat saqlaydi ($h_1 \dots h_n$).
- 2 Dekoder har qadamda **kerakli** manba so'zlariga qaraydi.
- 3 Bu "qarash" — vaznlangan yig'indi (**attention**).

Bahdanau attention: dekoderga manbaning **tegishli** qismini har qadam tanlash imkonini beradi.

Prezentatsiya rejasi

- 1 Kirish: bir tildan boshqasiga tarjima qilamiz
- 2 **Enkoder-Dekoder va bottleneck**
- 3 Attention: dekodeer ortga qaraydi
- 4 Attention hisoblash: query, key, value
- 5 Tarjimani BLEU bilan baholash
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: o'qi, jamla, keyin yoz

Tarjima ikki bosqich:

- **Enkoder** (LSTM): manba gapni o'qiydi, ma'noni h_T ga jamlaydi.
- **Dekoder** (LSTM): h_T dan boshlab, maqsad tilda so'zma-so'z yozadi (autoregressiv, L9).

[men kitob o'qidim] $\rightarrow h_T \rightarrow$ [I read a book].

Muammo: h_T — **bitta** sobit vektor. Butun gap ma'nosi shunga sig'ishi kerak — uzun gapda bu yetmaydi (bottleneck).

Enkoder-Dekoder: rasmiy ta'rif

$$\mathbf{c} = h_n^{\text{enc}}, \quad s_t = \text{LSTM}_{\text{dec}}(s_{t-1}, [y_{t-1}; \mathbf{c}]), \quad \hat{y}_t = \text{softmax}(Ws_t)$$

bunda: h_n^{enc} — enkoderning oxirgi holati (kontekst $\mathbf{c}$); s_t — dekode holati; y_{t-1} — oldingi maqsad so'z; $\hat{y}_t$ — t qadamdagi so'z taqsimoti. Diqqat: $\mathbf{c}$ **barcha** dekode qadamlari uchun **bir xil** — mana shu bottleneck.

Keltirib chiqarish: nega sobit kontekst yetmaydi?

1-qadam. Butun manba gap ma'nosi $\mathbf{c} = h_n$ ga kodlanadi — o'lcham sobit (masalan 512).

Keltirib chiqarish: nega sobit kontekst yetmaydi?

1-qadam. Butun manba gap ma'nosi $\mathbf{c} = h_n$ ga kodlanadi — o'lcham sobit (masalan 512).

2-qadam. Gap uzunlashsa ham $\mathbf{c}$ o'lchami o'zgarmaydi $\Rightarrow$ axborot **zichlashadi**, boshidagi so'zlar yo'qoladi.

Keltirib chiqarish: nega sobit kontekst yetmaydi?

1-qadam. Butun manba gap ma'nosi $\mathbf{c} = h_n$ ga kodlanadi — o'lcham sobit (masalan 512).

2-qadam. Gap uzunlashsa ham $\mathbf{c}$ o'lchami o'zgarmaydi $\Rightarrow$ axborot **zichlashadi**, boshidagi so'zlar yo'qoladi. **3-qadam.** Dekoder har qadamda bir xil $\mathbf{c}$ ni ko'radi — qaysi manba so'zi hozir muhimligini **ajrata olmaydi**.

Xulosa: kerak bo'lgani — har dekodeer qadami uchun **boshqa**, tegishli kontekst. Buni attention beradi.

Qo'lda misol: sobit kontekst axborotni yo'qotadi

$h_1 = [1, 0]$ (men), $h_2 = [0, 1]$ (kitob), $h_3 = [1, 1]$ (o'qidim).

Attention'siz kontekst:

$$\mathbf{c} = h_3 = [1, 1]$$

Dekoder faqat h_3 ni ko'radi; h_1 (men), h_2 (kitob) bevosita yo'q.

Agar dekoder "men" ni tarjima qilmoqchi bo'lsa, unga h_1 kerak — ammo sobit $\mathbf{c} = h_3$ uni bevosita bermaydi.

Sizning vazifangiz: o'rtacha kontekst

Savol — 60 soniya

Ba'zan kontekst sifatida **o'rtacha** olinadi: $h_1 = [1, 0]$, $h_2 = [0, 1]$, $h_3 = [1, 1]$.

$$\mathbf{c}_{\text{avg}} = \frac{1}{3}(h_1 + h_2 + h_3) = ?$$

Sizning vazifangiz: o'rtacha kontekst

Savol — 60 soniya

Ba'zan kontekst sifatida **o'rtacha** olinadi: $h_1 = [1, 0]$, $h_2 = [0, 1]$, $h_3 = [1, 1]$.

$$\mathbf{c}_{\text{avg}} = \frac{1}{3}(h_1 + h_2 + h_3) = ?$$

Javob

$$\mathbf{c}_{\text{avg}} = \frac{1}{3}([1, 0] + [0, 1] + [1, 1]) = \frac{1}{3}[2, 2] = [0.667, 0.667]$$

O'rtacha ham sobit va **teng** vazn beradi — qaysi so'z muhimligini ajratmaydi. Attention esa **har xil** vazn beradi (3-tsikl).

Kod $\leftrightarrow$ formula: enkoder-dekoder skeleti

```
import torch.nn as nn

class Seq2Seq(nn.Module):
    def __init__(self, src_v, tgt_v, dim, hid):
        super().__init__()
        self.enc = nn.LSTM(dim, hid, batch_first=True)
        self.dec = nn.LSTM(dim, hid, batch_first=True)
        self.emb_s = nn.Embedding(src_v, dim)
        self.emb_t = nn.Embedding(tgt_v, dim)
        self.out = nn.Linear(hid, tgt_v)

    def encode(self, x):
        _, (h, c) = self.enc(self.emb_s(x))
        return h, c      # kontekst (sabit)
```

Kod $\rightarrow$ formula:

Kod	Formula
enc	enkoder LSTM
h, c dec	kontekst c dekoder LSTM

P11 da m11 shu skelet ustiga attention qo'shadi.

Bottleneck tuzog'i: uzun gapda BLEU tushadi

Uzunlik bilan sifat pasayadi

Attention'siz Seq2Seq qisqa gaplarda yaxshi, ammo gap 20–30 so'zdan oshganda BLEU keskin tushadi (Bahdanau, 2015 ko'rsatgan).

Yechim: attention — har dekoder qadami uchun manbaning tegishli qismidan **yangi** kontekst (2-tsikl).

Prezentatsiya rejasi

- 1 Kirish: bir tildan boshqasiga tarjima qilamiz
- 2 Enkoder-Dekoder va bottleneck
- 3 Attention: dekodeer ortga qaraydi**
- 4 Attention hisoblash: query, key, value
- 5 Tarjimani BLEU bilan baholash
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: har so'zni yozayotganda kerakli joyga qaraymiz

Inson tarjimon ham har maqsad so'zni yozayotganda manbaning **tegishli** so'ziga qaraydi.

Attention shuni modellaydi: dekodeer t qadamida enkoder holatlariga **vazn** beradi (α_i) va vaznlangan yig'indini kontekst qiladi.

Sabit kontekst o'rniga — har qadam **boshqa** kontekst $\mathbf{c}_t$. Vaznlar α_i qaysi manba so'zi muhimligini ko'rsatadi (alignment).

Attention konteksti: rasmiy ta'rif

$$\mathbf{c}_t = \sum_{i=1}^n \alpha_{t,i} h_i, \quad \sum_i \alpha_{t,i} = 1, \quad \alpha_{t,i} \geq 0$$

bunda: h_i — i -enkoder holati; $\alpha_{t,i}$ — t dekoder qadamida i -manba so'ziga berilgan vazn (e'tibor); $\mathbf{c}_t$ — shu qadam uchun vaznlangan kontekst. Endi dekoder s_t ni $\mathbf{c}_t$ (har qadam yangi) bilan hisoblaydi — $\alpha_{t,i}$ ni qanday topishni 3-tsiklda ko'ramiz.

1-qadam. Attention'siz: $\mathbf{c} = h_n$ (bitta, sobit).

Keltirib chiqarish: sobit kontekstdan vaznlanganga

1-qadam. Attention'siz: $\mathbf{c} = h_n$ (bitta, sobit). **2-qadam.** Umumlashtiramiz: kontekst — barcha holatlarning vaznlangan yig'indisi $\mathbf{c}_t = \sum_i \alpha_{t,i} h_i$.

Keltirib chiqarish: sobit kontekstdan vaznlanganga

1-qadam. Attention'siz: $\mathbf{c} = h_n$ (bitta, sobit). **2-qadam.** Umumlashtiramiz: kontekst — barcha holatlarning vaznlangan yig'indisi $\mathbf{c}_t = \sum_i \alpha_{t,i} h_i$. **3-qadam.** Vaznlar $\alpha_{t,i}$ ehtimol bo'lsin (≥ 0 , yig'indisi 1) $\Rightarrow$ ularni **softmax** bilan olamiz (keyingi tsikl). Sobit kontekst — bu attention'ning maxsus holati ($\alpha_{t,n} = 1$, qolgani 0).

Xulosa: attention — kontekstni **moslashuvchan** qiladi; har qadam manbaning boshqa qismiga e'tibor beradi.

Qo'lda misol: vaznlangan kontekst

$$h_1 = [1, 0], h_2 = [0, 1], h_3 = [1, 1]; \text{vaznlar } \alpha = [0.2, 0.3, 0.5].$$

Hisoblaymiz:

$$\begin{aligned} \mathbf{c} &= 0.2[1, 0] + 0.3[0, 1] + 0.5[1, 1] \\ &= [0.2 + 0.5, 0.3 + 0.5] = [0.7, 0.8] \end{aligned}$$

3-holatga eng katta vazn (0.5) berildi
 $\Rightarrow$ kontekst h_3 ga eng yaqin. Vaznlar
"qayerga qarashni" boshqaradi.

Sizning vazifangiz: boshqa vaznlar bilan kontekst

Savol — 60 soniya

$h_1 = [1, 0]$, $h_2 = [0, 1]$, $h_3 = [1, 1]$; vaznlar $\alpha = [0.5, 0.5, 0.0]$:

$\mathbf{c} = ?$

Sizning vazifangiz: boshqa vaznlar bilan kontekst

Savol — 60 soniya

$h_1 = [1, 0]$, $h_2 = [0, 1]$, $h_3 = [1, 1]$; vaznlar $\alpha = [0.5, 0.5, 0.0]$:

$\mathbf{c} = ?$

Javob

$$\mathbf{c} = 0.5[1, 0] + 0.5[0, 1] + 0[1, 1] = [0.5, 0.5]$$

Endi e'tibor 1- va 2-holatda; 3-holat e'tiborsiz. Kontekst butunlay o'zgardi — attention shu moslashuvchanlikni beradi.

Kod $\leftrightarrow$ formula: vaznlangan kontekst

```
1 import numpy as np
2
3 H = np.array([[1, 0],      # h_1
4               [0, 1],      # h_2
5               [1, 1]])     # h_3
6 alpha = np.array([0.2, 0.3, 0.5])
7
8 # kontekst = sum_i alpha_i h_i
9 context = alpha @ H
10 print(context)           # [0.7 0.8]
```

Kod $\rightarrow$ formula:

Kod	Formula
alpha	$\alpha_{t,i}$
alpha @ H	$\sum_i \alpha_i h_i$
context	$\mathbf{c}_t$

Vaznlangan yig'indi — bitta
matritsa-vektor ko'paytma. α
ni qanday topish — 3-tsikl.

Attention tuzog'i: vaznlar yig'indisi 1 bo'lishi shart

Normallanmagan vaznlar

Agar α yig'indisi 1 bo'lmasa, kontekst masshtabi buziladi — dekodeer beqaror bo'ladi. Shuning uchun α **softmax** bilan normallanadi.

Yechim: energiyalardan softmax — avtomatik $\sum \alpha = 1, \alpha \geq 0$ (3-tsikl, qulflangan misol).

Prezentatsiya rejasi

- 1 Kirish: bir tildan boshqasiga tarjima qilamiz
- 2 Enkoder-Dekoder va bottleneck
- 3 Attention: dekodeer ortga qaraydi
- 4 Attention hisoblash: query, key, value**
- 5 Tarjimani BLEU bilan baholash
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: so'rov kalitlarga mos kelganini izlaydi

Attention — "qidiruv" kabi:

- **So'rov (query)** q — dekoderning joriy holati ("nima kerak?").
- **Kalitlar (keys)** k_i — enkoder holatlari ("nima bor?").
- **Qiymatlar (values)** v_i — enkoder holatlari (qaytariladigan).

q qaysi k_i ga mos kelsa, o'sha v_i ko'proq olinadi.

Moslik darajasi — **energiya** e_i . Energiyalardan softmax bilan vaznlar α_i chiqadi.

Attention (additive, Bahdanau): rasmiy ta'rif

$$e_{t,i} = \mathbf{v}_a^\top \tanh(W_a s_{t-1} + U_a h_i), \quad \alpha_{t,i} = \frac{\exp(e_{t,i})}{\sum_j \exp(e_{t,j})}$$

bunda: s_{t-1} — dekode so'rovi (query); h_i — enkoder kaliti/qiymati (key/value); $e_{t,i}$ — moslik energiyasi; $\alpha_{t,i}$ — softmax vazni; $W_a, U_a, \mathbf{v}_a$ — o'rganiladigan parametrlar. So'ng kontekst $\mathbf{c}_t = \sum_i \alpha_{t,i} h_i$ (2-tsikl).

1-qadam. Har enkoder holati uchun moslik energiyasi: $e_{t,i} = \text{score}(s_{t-1}, h_i)$ (Bahdanau: additive tanh).

1-qadam. Har enkoder holati uchun moslik energiyasi: $e_{t,i} = \text{score}(s_{t-1}, h_i)$ (Bahdanau: additive tanh). **2-qadam.** Energiyalar ixtiyoriy haqiqiy sonlar — ularni ehtimolga aylantirish kerak (≥ 0 , yig'indi 1).

Keltirib chiqarish: energiyadan vaznlarga

1-qadam. Har enkoder holati uchun moslik energiyasi: $e_{t,i} = \text{score}(s_{t-1}, h_i)$ (Bahdanau: additive tanh). **2-qadam.** Energiyalar ixtiyoriy haqiqiy sonlar — ularni ehtimolga aylantirish kerak (≥ 0 , yig'indi 1). **3-qadam.** Aynan softmax buni qiladi (L6/L9 dagi kabi):

$$\alpha_{t,i} = \frac{\exp(e_{t,i})}{\sum_j \exp(e_{t,j})}$$

Xulosa: energiya "qanchalik mos"; softmax uni "e'tibor ulushi"ga aylantiradi. Endi qo'lda hisoblaymiz.

Qo'lda hisob: attention vaznlari $\alpha = [0.245, 0.090, 0.665]$

$$\exp(2) \approx 7.389, \quad \exp(1) \approx 2.718, \quad \exp(3) \approx 20.086.$$

Softmax:

$$\sum = 7.389 + 2.718 + 20.086 = 30.193$$

$$\alpha = \frac{[7.389, 2.718, 20.086]}{30.193}$$
$$= [0.245, 0.090, 0.665]$$

Eng katta energiya (3-holat, $e_3=3$) eng katta vazn (0.665) oldi — dekodeer shu manba so'ziga eng ko'p qaraydi.

Ertangi P11 birinchi assert:

```
np.allclose(alpha,  
             [0.245,0.090,0.665], atol=1e-3)  
# Ma'ruza L11 [I3]-slayd
```

Sizning vazifangiz: kontekst vektorini toping

Savol — 90 soniya

Yuqoridagi $\alpha = [0.245, 0.090, 0.665]$ va $h_1 = [1, 0]$, $h_2 = [0, 1]$, $h_3 = [1, 1]$:

$$\mathbf{c} = \sum_i \alpha_i h_i = ?$$

Sizning vazifangiz: kontekst vektorini toping

Savol — 90 soniya

Yuqoridagi $\alpha = [0.245, 0.090, 0.665]$ va $h_1 = [1, 0]$, $h_2 = [0, 1]$, $h_3 = [1, 1]$:

$$\mathbf{c} = \sum_i \alpha_i h_i = ?$$

Javob

$$\begin{aligned}\mathbf{c} &= 0.245[1, 0] + 0.090[0, 1] + 0.665[1, 1] = [0.245+0.665, 0.090+0.665] \\ &= [\mathbf{0.910}, \mathbf{0.755}]\end{aligned}$$

Kontekst h_3 ga eng yaqin (eng katta vazn) — dekodeer uchun moslashtirilgan kirish.

Kod $\leftrightarrow$ formula: attention to'liq

```
import numpy as np

def attention(energies, H):
    e = np.asarray(energies, dtype=float)
    alpha = np.exp(e) / np.exp(e).sum() # softmax
    context = alpha @ H # sum_i alpha_i h_i
    return alpha, context

H = np.array([[1,0],[0,1],[1,1]])
alpha, c = attention([2.0, 1.0, 3.0], H)
print(alpha) # [0.245 0.090 0.665]
print(c) # [0.910 0.755]
```

Kod $\rightarrow$ formula:

Kod	Formula
exp/sum	$\alpha = \text{softmax}(e)$
alpha @ H	$c = \sum \alpha_i h_i$

P11 da m11 Bahdanau attention'ni shu mantiqda quradi (energiya $\rightarrow$ softmax $\rightarrow$ kontekst).

Katta energiyalar overflow

$\exp(e_i)$ katta e_i da ∞ ga ketishi mumkin (overflow). Yechim (L9 dagi kabi): $e_i - \max(e)$ ni olish — natijaga ta'sir qilmaydi.

Yana: attention $O(n)$ enkoder holatini har dekoder qadamida ko'radi — uzun gapda hisob qimmat (Transformer buni parallel qiladi — L12).

Prezentatsiya rejasi

- 1 Kirish: bir tildan boshqasiga tarjima qilamiz
- 2 Enkoder-Dekoder va bottleneck
- 3 Attention: dekodeer ortga qaraydi
- 4 Attention hisoblash: query, key, value
- 5 Tarjimani BLEU bilan baholash**
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: tarjima etalonga qanchalik mos?

Tarjimani baholash qiyin — bir gapning ko'p to'g'ri tarjimasi bor. **BLEU** oddiy yechim: mashina tarjimasidagi **n-gramlar** etalon (reference) tarjimada qanchalik uchraydi?

Yuqori BLEU $\Rightarrow$ etalonga yaqin.

BLEU — aniqlikka (precision) asoslangan: nechta hypothesis n-grami reference da bor. Qisqa tarjimani jazolash uchun **brevity penalty**.

$$p_n = \frac{\text{mos } n\text{-gramlar}}{\text{hypothesis } n\text{-gramlar}}, \quad \text{BLEU} = \text{BP} \cdot \exp\left(\sum_{n=1}^N w_n \ln p_n\right)$$

bunda: p_n — n -gram aniqligi; w_n — vazn ($1/N$); BP — brevity penalty (qisqa tarjima jazosi); BP = 1 agar hypothesis reference dan kalta bo'lmasa. BLEU-1 — faqat unigram ($N=1$): BLEU-1 = BP · p_1 .

Keltirib chiqarish: nega aniqlik + brevity penalty?

1-qadam. Aniqlik: hypothesis so'zlari reference da bormi? Bu sifatni o'lchaydi.

Keltirib chiqarish: nega aniqlik + brevity penalty?

1-qadam. Aniqlik: hypothesis so'zlari reference da bormi? Bu sifatni o'lchaydi. **2-qadam.** Muammo: juda **qisqa** tarjima yuqori aniqlik olishi mumkin ("the" $\rightarrow p_1=1$). Bu noto'g'ri yuqori ball.

Keltirib chiqarish: nega aniqlik + brevity penalty?

1-qadam. Aniqlik: hypothesis so'zlari reference da bormi? Bu sifatni o'lchaydi. **2-qadam.** Muammo: juda **qisqa** tarjima yuqori aniqlik olishi mumkin ("the" $\rightarrow p_1=1$). Bu noto'g'ri yuqori ball. **3-qadam. Brevity penalty** qisqa tarjimani jazolaydi:

$$\text{BP} = \begin{cases} 1 & |hyp| \geq |ref| \\ e^{1-|ref|/|hyp|} & |hyp| < |ref| \end{cases}$$

Xulosa: BLEU = aniqlik (sifat) $\times$ BP (uzunlik) — ikkisi muvozanatlanadi.

Qo'lda misol: BLEU-1 = 0.667

Reference: men kitobni o'qidim (3 so'z); Hypothesis: men kitobni yozdim (3 so'z).

Unigram aniqligi:

- men — ref da bor ✓
- kitobni — ref da bor ✓
- yozdim — ref da yo'q (×)

$$p_1 = \frac{2}{3}, \quad \text{BP} = 1 \quad (3 \geq 3)$$

$$\text{BLEU-1} = 1 \cdot \frac{2}{3} = \mathbf{0.667}$$

2/3 so'z mos; uzunlik teng (BP= 1).
BLEU-1 = 0.667. To'liq BLEU bi-gram/trigramni ham qo'shadi.

Sizning vazifangiz: boshqa hypothesis uchun BLEU-1

Savol — 90 soniya

Reference: men kitobni o'qidim (3); Hypothesis: men kitobni sotib oldim (4 so'z). Mos unigramlar: men, kitobni (2 ta).

$p_1 = ?$ (BP = 1, **chunki** $4 \geq 3$)

Sizning vazifangiz: boshqa hypothesis uchun BLEU-1

Savol — 90 soniya

Reference: men kitobni o'qidim (3); Hypothesis: men kitobni sotib oldim (4 so'z). Mos unigramlar: men, kitobni (2 ta).

$p_1 = ?$ (BP = 1, **chunki** $4 \geq 3$)

Javob

$$p_1 = \frac{2}{4} = 0.5; \quad \text{BLEU-1} = 1 \cdot 0.5 = \mathbf{0.5}$$

Maxraj — **hypothesis** uzunligi (4). Uzunroq, ammo kam mos $\Rightarrow$ aniqlik tushdi. (BP= 1 chunki hypothesis kalta emas.)

Kod $\leftrightarrow$ formula: BLEU-1

```
def bleu1(ref, hyp):  
    ref_set = set(ref)  
    matches = sum(1 for w in hyp if w in ref_set)  
    p1 = matches / len(hyp)  
    bp = 1.0 if len(hyp) >= len(ref) else \  
        pow(2.718, 1 - len(ref)/len(hyp))  
    return bp * p1  
  
r = "men kitobni o'qidim".split()  
h = "men kitobni yozdim".split()  
print(round(bleu1(r, h), 3))    # 0.667
```

Kod $\rightarrow$ formula:

Kod	Formula
matches/len	p_1
bp	BP
bp*p1	BLEU-1

Bu soddalashtirilgan;
nltk.translate.bleu_score
clipping va bigram/trigramni ham
qo'shadi. P11 da shuni ishlatamiz.

BLEU tuzog'i: yuqori BLEU har doim yaxshi tarjima emas

Cheklovlar

- Sinonim/qayta tartiblashni jazolaydi (n-gram aniq mos kerak).
- Bitta reference kam — ko'p to'g'ri tarjima e'tiborsiz qoladi.
- Ma'noni emas, yuza mosligini o'lchaydi.

Amalda: BLEU — tez, arzon taqqoslash mezon; ammo inson bahosi yoki ma'no-asosli metrikalar (COMET) bilan to'ldiriladi.

Prezentatsiya rejasi

- 1 Kirish: bir tildan boshqasiga tarjima qilamiz
- 2 Enkoder-Dekoder va bottleneck
- 3 Attention: dekodeer ortga qaraydi
- 4 Attention hisoblash: query, key, value
- 5 Tarjimani BLEU bilan baholash
- 6 Xulosa va amaliyotga ko'prik

O'zbek tilida: SOV-SVO konversiya va attention alignment

1. SOV → SVO:

O'zbekcha: *men kitobni o'qidim*
(Ega-Ob'ekt-Kesim). Inglizcha: *I read a book*
(Ega-Kesim-Ob'ekt).

Qiyinchilik

Dekoder kesimni (read) inglizda **oldinroq** chiqarishi kerak — so'z tartibi qayta tuziladi.

2. Attention alignment yordam beradi:

read ni yozayotganda attention o'zbekcha o'qidim ga (oxirgi so'z) qaraydi — garchi u inglizda 2-o'rinda bo'lsa ham.

Attention so'z tartibidan **mustaqil** bog'lanish quradi — o'zbek erkin tartibida ayniqsa qimmatli.

Sintez: bottleneck'dan attention'ga

Jihat	Attention'siz Seq2Seq	Attention bilan
Kontekst	sobit $\mathbf{c} = h_n$	har qadam $\mathbf{c}_t = \sum \alpha_i h_i$
Uzun gap	sifat tushadi (bottleneck)	barqaror
Alignment	yo'q	$\alpha_{t,i}$ (qaysi so'zga)
Hisob	arzon	$O(n)$ har qadam

Asosiy g'oya

Attention sobit kontekst bottleneck'ini yechadi: dekoder har qadamda energiya $\rightarrow$ softmax $\rightarrow$ vaznlangan kontekst orqali manbaning tegishli qismiga qaraydi. BLEU bilan baholaymiz.

Seminal manba: Bahdanau, Cho, Bengio (2015)

Bahdanau, D., Cho, K., Bengio, Y. (2015). **Neural Machine Translation by Jointly Learning to Align and Translate.** *ICLR 2015*.

Ahamiyati:

- NLP'ga attention'ni kiritdi — bottleneck muammosini yechdi.
- Alignment'ni o'rganib, uzun gaplarda tarjima sifatini oshirdi.
- Transformer (L12, "Attention is All You Need") shu g'oyaning rivoji.

Muhokama savoli (P11 gacha o'ylang)

O'zbek tilida so'z tartibi erkin ("kitobni men o'qidim" ham to'g'ri). Attention alignment buni qanday yengillashtiradi? Sobit kontekst nega qiynalardi?

- ① ✓ **Tushuntirdik:** enkoder-dekoder va information bottleneck (sabit $\mathbf{c} = h_n$).
- ② ✓ **Tushuntirdik:** attention — har qadam yangi kontekst $\mathbf{c}_t = \sum \alpha_i h_i$.
- ③ ✓ **Hisobladik:** $\alpha = \text{softmax}([2, 1, 3]) = [0.245, 0.090, 0.665]$, kontekst $[0.910, 0.755]$.
- ④ ✓ **Hisobladik:** BLEU-1 = 0.667 (aniqlik + brevity penalty).

Ertaga P11: attention'li neyro-tarjimon quramiz



P11 da qurasiz:

- m11 Seq2SeqTranslator: enkoder-dekoder + attention
- OPUS-100 uz-en da o'qitish, BLEU baho
- Attention vaznlari α ni tekshirish

Birinchi assert (bu slayd [I3]):

```
assert np.allclose(  
    alpha, [0.245,0.090,0.665],  
    atol=1e-3)
```

*# Ma'ruza L11 [I3]-slayd bilan
solishtiring (attention softmax)*

- ❶ Bahdanau, D., Cho, K., Bengio, Y. (2015). *Neural Machine Translation by Jointly Learning to Align and Translate*. ICLR 2015.
- ❷ Sutskever, I., Vinyals, O., Le, Q. (2014). *Sequence to Sequence Learning with Neural Networks*. NeurIPS 27.
- ❸ Luong, M., Pham, H., Manning, C. (2015). *Effective Approaches to Attention-based NMT*. EMNLP 2015. (Dot-product attention.)
- ❹ Papineni, K., va boshq. (2002). *BLEU: a Method for Automatic Evaluation of MT*. ACL 2002.
- ❺ `nltk.translate.bleu_score` hujjatlari.

Ilova S1: additive vs dot-product attention

Energiya $e_{t,i}$ ni hisoblashning ikki keng tarqalgan usuli:

- **Additive** (Bahdanau): $e_{t,i} = \mathbf{v}_a^\top \tanh(W_a s_{t-1} + U_a h_i)$ — kichik MLP.
- **Dot-product** (Luong): $e_{t,i} = s_{t-1}^\top h_i$ — tezroq, parametrsiz.

bunda: Transformer (L12) masshtablangan dot-product ishlatadi: $e = \frac{q^\top k}{\sqrt{d}}$ — $\sqrt{d}$ gradientni barqarorlashtiradi.

Ilova S2: to'liq BLEU (n-gram va clipping)

To'liq BLEU bir nechta n uchun aniqlikni geometrik o'rtachalaydi:

$$\text{BLEU} = \text{BP} \cdot \exp\left(\frac{1}{N} \sum_{n=1}^N \ln p_n\right), \quad N = 4 \text{ (odatda)}$$

bunda: clipping: bir so'z reference da necha marta bo'lsa, shuncha marta hisoblanadi (takroriy so'z bilan aldashni oldini oladi).

Misol: hypothesis the the the — clippingsiz $p_1=1$; clipping bilan reference da the bir marta bo'lsa, $p_1=1/3$.