

# Transformer arxitekturası va matnni umumlashtirish

## Tabiiy tilni qayta ishlash — 12-ma'ruza

A.A. Abdulali

11:00–12:20 · mavzu №12

3-iyul 2026

# Prezentatsiya rejasi

- 1 Kirish: rekurrentlikdan butunlay voz kechamiz
- 2 Self-attention: har pozitsiya hammaga qaraydi
- 3 Multi-head attention va positional encoding
- 4 Transformer bloki va umumlashtirish
- 5 Umumlashtirishni ROUGE bilan baholash
- 6 Xulosa va amaliyotga ko'prik

# Takrorlash: o'tgan darsdan ikki savol

## 1-savol

L11 da attention dekoderga manbaning kerakli so'ziga "qarash" imkonini berdi. Lekin enkoder va dekodeer hamon nima edi?

## 2-savol

Manba gapni so'zma-so'z ketma-ket o'qiganimiz modelni o'qitishda qanday cheklov tug'diradi?

# Takrorlash: o'tgan darsdan ikki savol

## 1-savol

L11 da attention dekoderga manbaning kerakli so'ziga "qarash" imkonini berdi. Lekin enkoder va dekodeer hamon nima edi?

## 2-savol

Manba gapni so'zma-so'z ketma-ket o'qiganimiz modelni o'qitishda qanday cheklov tug'diradi?

## 1-javob

Ikkalasi ham **LSTM** edi — holatlar ketma-ket,  $h_t$  uchun  $h_{t-1}$  kerak. Attention ustiga qurilgan, ammo asos rekurrent.

## 2-javob

Ketma-ketlik **parallellashmaydi**:  $n$  so'z uchun  $n$  qadam. Bugun rekurrentlikni butunlay olib tashlaymiz — **Transformer**.

## Siz bugungi dars oxirida quyidagilarni bajara olasiz:

- ➊ **Tushuntira olasiz:** nega Transformer rekurrentlikdan voz kechadi — parallellashtirish va uzoq bog'liqlik.
- ➋ **Hisoblay olasiz:** scaled dot-product self-attention vaznlarini —  $\alpha = \text{softmax}([2, 1, 3]) = [0.245, 0.090, 0.665]$ .
- ➌ **Tushuntira olasiz:** multi-head attention, positional encoding va residual + layer norm.
- ➍ **Hisoblay olasiz:** umumlashtirish sifatini ROUGE-1 bilan —  $P = 1.0$ ,  $R = 0.6$ ,  $F_1 = 0.75$ .

L11 dan: attention, energiya  $\rightarrow$  softmax  $\rightarrow$  kontekst. L6/L9 dan: softmax. Matematikadan: skalyar ko'paytma, matritsa ko'paytma, exp, sin / cos.

## Bugungi dars rejasi:

| Tsiki | Mavzu                                | Vaqt   | Hosil natija                     | bo'luvchi |
|-------|--------------------------------------|--------|----------------------------------|-----------|
| 1     | Self-attention va parallellashtirish | 16 daq | $\alpha = [0.245, 0.090, 0.665]$ |           |
| 2     | Multi-head va positional encoding    | 16 daq | $PE(0) = [0, 1, \dots]$          |           |
| 3     | Transformer bloki va umumlashtirish  | 18 daq | residual + Layer-Norm            |           |
| 4     | ROUGE bilan baholash                 | 16 daq | $F_1 = 0.750$                    |           |
|       | Xulosa va 12-amaliyotga ko'rsatmalar | 10 daq | Ertaga nima qurishingiz          |           |

### Bu dars Transformer'ga olib keladi

Self-attention — L11 attention'ning umumlashmasi. Bugungi ROUGE-1  $F_1 = 0.750$  ertangi P12 da assert bo'ladi.

# Bugungi dars uchun muammo: ketma-ketlik o'qitishni sekinlashtiradi

## RNN/LSTM qayerda qiynaladi:

### Ketma-ket hisob

$h_t$  ni hisoblash uchun  $h_{t-1}$  shart.  $n$  so'z  $\Rightarrow n$  qadam, biri tugamay ikkinchisi boshlanmaydi — **parallellashmaydi**.

### Uzoq bog'liqlik sust

Ikki uzoq so'z orasida axborot  $O(n)$  qadamdan o'tadi — gradient yo'lda zaiflashadi (L8 vanishing gradient).

## Bugungi yechim:

- 1 Rekurrentlikni **butunlay** olib tashlaymiz.
- 2 Har so'z **barcha** so'zlarga bir vaqtning o'zida qaraydi (self-attention).
- 3 Har juft orasi — **bitta** qadam ( $O(1)$  yo'l), to'liq parallel.

"Attention is all you need" (Vaswani, 2017): rekurrentlik shart emas — faqat attention yetadi.

# Prezentatsiya rejasi

- 1 Kirish: rekurrentlikdan butunlay voz kechamiz
- 2 Self-attention: har pozitsiya hammaga qaraydi
- 3 Multi-head attention va positional encoding
- 4 Transformer bloki va umumlashtirish
- 5 Umumlashtirishni ROUGE bilan baholash
- 6 Xulosa va amaliyotga ko'prik



# Intuitsiya: gap ichida har soʻz boshqalarga qaraydi

L11 da **dekoder** enkoderga qarardi (kross-attention). Self-attention shuni **gap ichida** qiladi: har soʻz **shu gapdagi** boshqa soʻzlarga qaraydi.

"U *bankka* bordi" — "bankka" ning maʼnosi "pul" yoki "daryo" ekani atrofdagi soʻzlardan aniqlanadi. Har soʻz kontekstni oʻzi yigʻadi.

**Asosiy ark:** self-attention — L11 attentionʼning umumlashmasi. Soʻrov (query) endi dekoder emas, **shu gapning** oʻzidan keladi. Energiya  $\rightarrow$  softmax  $\rightarrow$  kontekst — bir xil.

## Scaled dot-product attention: rasmiy ta'rif

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^{\top}}{\sqrt{d_k}}\right) V$$

**bunda:**  $Q$  — so'rovlar (query) matritsasi;  $K$  — kalitlar (key);  $V$  — qiymatlar (value);  $d_k$  — kalit o'lchami;  $QK^{\top}/\sqrt{d_k}$  — masshtablangan moslik energiyasi; softmax qatorlar bo'yicha olinadi. Self-attention'da  $Q = XW^Q$ ,  $K = XW^K$ ,  $V = XW^V$  — uchchalasi **bitta** kirish  $X$  dan. L11 dagi additive attention'ning matritsali, parallel shakli.

Keltirib chiqarish: nega  $\sqrt{d_k}$  ga bo'lamiz?

**1-qadam.** Moslik — so'rov va kalitning skalyar ko'paytmasi:  $e_{ij} = q_i \cdot k_j$  (L11 energiyasi).

## Keltirib chiqarish: nega $\sqrt{d_k}$ ga bo'lamiz?

**1-qadam.** Moslik — so'rov va kalitning skalyar ko'paytmasi:  $e_{ij} = q_i \cdot k_j$  (L11 energiyasi).

**2-qadam.**  $d_k$  katta bo'lsa,  $q \cdot k$  yig'indisi  $d_k$  ta haddan iborat  $\Rightarrow$  qiymatlar kattalashadi (dispersiya  $\sim d_k$ ).

## Keltirib chiqarish: nega $\sqrt{d_k}$ ga bo'lamiz?

**1-qadam.** Moslik — so'rov va kalitning skalyar ko'paytmasi:  $e_{ij} = q_i \cdot k_j$  (L11 energiyasi).

**2-qadam.**  $d_k$  katta bo'lsa,  $q \cdot k$  yig'indisi  $d_k$  ta haddan iborat  $\Rightarrow$  qiymatlar kattalashadi (dispersiya  $\sim d_k$ ). **3-qadam.** Katta energiyalarda softmax bitta pozitsiyaga "yopishadi"  $\Rightarrow$  gradient kichrayadi (o'qitish sekinlashadi).

## Keltirib chiqarish: nega $\sqrt{d_k}$ ga bo'lamiz?

**1-qadam.** Moslik — so'rov va kalitning skalyar ko'paytmasi:  $e_{ij} = q_i \cdot k_j$  (L11 energiyasi).

**2-qadam.**  $d_k$  katta bo'lsa,  $q \cdot k$  yig'indisi  $d_k$  ta haddan iborat  $\Rightarrow$  qiymatlar kattalashadi (dispersiya  $\sim d_k$ ). **3-qadam.** Katta energiyalarda softmax bitta pozitsiyaga "yopishadi"  $\Rightarrow$  gradient kichrayadi (o'qitish sekinlashadi). **4-qadam.**  $\sqrt{d_k}$  ga bo'lib, dispersiyani  $\approx 1$  ga qaytaramiz — softmax barqaror.

**Xulosa:**  $\sqrt{d_k}$  — gradientni barqarorlashtiruvchi masshtab. Endi softmax'ni qo'lda hisoblaymiz.

Qo'lda misol: self-attention vaznlari  $\alpha = [0.245, 0.090, 0.665]$

$$q \cdot k_1 = 4, \quad q \cdot k_2 = 2, \quad q \cdot k_3 = 6. \quad \text{Masshtab: } / \sqrt{4} = /2 \Rightarrow e = [2, 1, 3].$$

**Softmax:**

$$\sum = 7.389 + 2.718 + 20.086 = 30.193$$

$$\alpha = \frac{[7.389, 2.718, 20.086]}{30.193} \\ = [0.245, 0.090, 0.665]$$

$$(\exp(2) \approx 7.389, \exp(1) \approx 2.718, \exp(3) \approx 20.086)$$

Aynan L11 [I3] dagi softmax! Self-attention — o'sha matematika, ammo so'rov gapning **o'zidan**. 3-pozitsiya eng katta vazn oldi.

# Sizning vazifangiz: boshqa so'rov uchun vaznlar

## Savol — 90 soniya

Ko'paytmalar  $q \cdot k = [2, 2, 4]$ ,  $d_k = 4$  ( $\sqrt{d_k} = 2$ )  $\Rightarrow$  masshtablangan  $e = [1, 1, 2]$ .

$\alpha = \text{softmax}([1, 1, 2]) = ?$  ( $\exp(1) \approx 2.718$ ,  $\exp(2) \approx 7.389$ )



# Sizning vazifangiz: boshqa so'rov uchun vaznlar

## Savol — 90 soniya

Ko'paytmalar  $q \cdot k = [2, 2, 4]$ ,  $d_k = 4$  ( $\sqrt{d_k} = 2$ )  $\Rightarrow$  masshtablangan  $e = [1, 1, 2]$ .

$\alpha = \text{softmax}([1, 1, 2]) = ?$  ( $\exp(1) \approx 2.718$ ,  $\exp(2) \approx 7.389$ )

## Javob

$$\sum = 2.718 + 2.718 + 7.389 = 12.825; \quad \alpha = \frac{[2.718, 2.718, 7.389]}{12.825} = [0.212, 0.212, 0.576]$$

Teng energiyali ikki pozitsiya teng vazn oladi; eng katta energiya (3-pozitsiya) eng katta vazn. Yig'indi = 1.

# Kod ↔ formula: scaled dot-product attention

```
1 import numpy as np
2
3 def self_attention(X, Wq, Wk, Wv):
4     Q, K, V = X @ Wq, X @ Wk, X @ Wv
5     d_k = K.shape[-1]
6     e = Q @ K.T / np.sqrt(d_k)          # energiya
7     e = e - e.max(axis=-1, keepdims=True)
8     alpha = np.exp(e)
9     alpha /= alpha.sum(axis=-1, keepdims=True)
10    return alpha @ V                    # kontekst
```

## Kod → formula:

| Kod        | Formula       |
|------------|---------------|
| Q@K.T      | $QK^T$        |
| /sqrt(d_k) | $/\sqrt{d_k}$ |
| exp/sum    | softmax       |
| alpha@V    | kontekst      |

e - e.max — L9 dagi overflow hi-moyasi. To'liq matritsa — barcha pozitsiya **parallel**.

# Self-attention tuzog'i: masshtabsiz softmax to'yinadi

## $\sqrt{d_k}$ ni unutish

$\sqrt{d_k}$  ga bo'lmasak,  $d_k = 512$  da energiyalar juda katta — softmax bitta pozitsiyaga  $\approx 1$  beradi, qolganlarga  $\approx 0$ . Gradient yo'qoladi, model o'qimaydi.

**Yechim:** har doim  $/\sqrt{d_k}$ . Yana: hisob murakkabligi  $O(n^2)$  — juda uzun gapda qimmat (keyingi tadqiqot mavzusi).

# Prezentatsiya rejasi

- 1 Kirish: rekurrentlikdan butunlay voz kechamiz
- 2 Self-attention: har pozitsiya hammaga qaraydi
- 3 Multi-head attention va positional encoding**
- 4 Transformer bloki va umumlashtirish
- 5 Umumlashtirishni ROUGE bilan baholash
- 6 Xulosa va amaliyotga ko'prik

# Intuitsiya: bir necha "qarash" va so'z tartibini eslab qolish

**Multi-head:** bitta attention — bitta "nuqtai nazar".  
Bir nechta **head** har xil munosabatni ko'radi: biri sintaktik (kim-nima), ikkinchisi semantik (ma'no).

**Positional encoding:** self-attention so'z **tartibini** ko'rmaydi — "men seni" va "seni men" bir xil to'plam. Tartibni qo'shimcha signal bilan kiritamiz.

Head'lar parallel ishlaydi, natijalari bir-lashtiriladi. PE har pozitsiyaga o'ziga xos "barmoq izi" beradi — so'z vektoriga qo'shiladi.

## Multi-head attention va positional encoding: rasmiy ta'rif

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V), \quad \text{MHA} = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O$$

$$PE_{(pos, 2i)} = \sin(pos/10000^{2i/d}), \quad PE_{(pos, 2i+1)} = \cos(pos/10000^{2i/d})$$

**bunda:**  $h$  — head soni;  $W_i^Q, W_i^K, W_i^V$  — har head proyeksiyasi;  $W^O$  — birlashtiruvchi proyeksiya;  $pos$  — pozitsiya;  $i$  — o'lcham indeksi;  $d$  — model o'lchami.

# Keltirib chiqarish: nega bir nechta head va nega sinusoidal PE?

**1-qadam.** Bitta head softmax bilan e'tiborni **o'rtachalashtiradi** — turli munosabatlarni bir vektorga aralashtiradi.

# Keltirib chiqarish: nega bir nechta head va nega sinusoidal PE?

**1-qadam.** Bitta head softmax bilan e'tiborni **o'rtachalashtiradi** — turli munosabatlarni bir vektorga aralashtiradi. **2-qadam.** Kirishni  $h$  ta kichik fazoga proyeksiya qilamiz; har biri alohida attention — turli naqshlar parallel o'rganiladi.



## Keltirib chiqarish: nega bir nechta head va nega sinusoidal PE?

**1-qadam.** Bitta head softmax bilan e'tiborni **o'rtachalashtiradi** — turli munosabatlarni bir vektorga aralashtiradi. **2-qadam.** Kirishni  $h$  ta kichik fazoga proyeksiya qilamiz; har biri alohida attention — turli naqshlar parallel o'rganiladi. **3-qadam.** Self-attention pozitsiyaga befarq (permutatsiyaga invariant)  $\Rightarrow$  tartibni kiritish kerak.

## Keltirib chiqarish: nega bir nechta head va nega sinusoidal PE?

**1-qadam.** Bitta head softmax bilan e'tiborni **o'rtachalashtiradi** — turli munosabatlarni bir vektorga aralashtiradi. **2-qadam.** Kirishni  $h$  ta kichik fazoga proyeksiya qilamiz; har biri alohida attention — turli naqshlar parallel o'rganiladi. **3-qadam.** Self-attention pozitsiyaga befarq (permutatsiyaga invariant)  $\Rightarrow$  tartibni kiritish kerak. **4-qadam.** Sinusoidal PE har pozitsiyaga noyob naqsh beradi va **nisbiy** masofani ( $pos+k$ ) chiziqli ifodalaydi.

**Xulosa:** multi-head — ko'p nuqtai nazar; PE — tartib signali. Endi PE'ni qo'lda hisoblaymiz.

## Qo'lda misol: birinchi pozitsiya uchun PE qiymati

$$PE_{(0,0)} = \sin(0), \quad PE_{(0,1)} = \cos(0), \quad PE_{(0,2)} = \sin(0), \quad PE_{(0,3)} = \cos(0).$$

**Hisoblaymiz:**

$$\sin(0) = 0, \quad \cos(0) = 1$$

$$PE_{(0)} = [0, 1, 0, 1]$$

$pos = 0$  da argument har doim 0 ( $0/10000 = 0$ ).

Juft o'lchamlar — sin, toq o'lchamlar — cos.  $pos = 0$  uchun  $[0, 1, 0, 1]$  — bu vektor so'z embeddingiga **qo'shiladi**.

# Sizning vazifangiz: ikkinchi pozitsiya uchun PE

## Savol — 60 soniya

$pos = 1$ ,  $d = 4$ ,  $i = 0$  uchun dastlabki ikki qiymat:  $PE_{(1,0)} = \sin(1/10000^0)$ ,  $PE_{(1,1)} = \cos(1/10000^0)$ .

$10000^0 = 1$ , demak  $\text{argument} = 1$ .  $[PE_{(1,0)}, PE_{(1,1)}] = ?$   
( $\sin(1) \approx 0.841$ ,  $\cos(1) \approx 0.540$ )

# Sizning vazifangiz: ikkinchi pozitsiya uchun PE

## Savol — 60 soniya

$pos = 1$ ,  $d = 4$ ,  $i = 0$  uchun dastlabki ikki qiymat:  $PE_{(1,0)} = \sin(1/10000^0)$ ,  $PE_{(1,1)} = \cos(1/10000^0)$ .

$10000^0 = 1$ , demak argument = 1.  $[PE_{(1,0)}, PE_{(1,1)}] = ?$   
( $\sin(1) \approx 0.841$ ,  $\cos(1) \approx 0.540$ )

## Javob

$[PE_{(1,0)}, PE_{(1,1)}] = [\sin(1), \cos(1)] = [0.841, 0.540]$

$pos = 0$  dagi  $[0, 1]$  dan farqli — har pozitsiya boshqa naqsh. Shu farq modelga tartibni bildiradi.

## Kod $\leftrightarrow$ formula: positional encoding

```
1 import numpy as np
2
3 def positional_encoding(n_pos, d):
4     pos = np.arange(n_pos)[: , None]
5     i = np.arange(d)[None, :]
6     angle = pos / 10000 ** (2 * (i // 2) / d)
7     pe = np.zeros((n_pos, d))
8     pe[:, 0::2] = np.sin(angle[:, 0::2])
9     pe[:, 1::2] = np.cos(angle[:, 1::2])
10    return pe
11
12 print(positional_encoding(2, 4)[0])    # [0 1 0 1]
```

### Kod $\rightarrow$ formula:

| Kod    | Formula            |
|--------|--------------------|
| angle  | $pos/10000^{2i/d}$ |
| [0::2] | juft: sin          |
| [1::2] | toq: cos           |

PE so'z embeddingiga qo'shiladi:  
 $x = emb + pe$ . Hech qanday  
o'rganiladigan parametr yo'q.

# PE tuzog'i: positional encoding'ni unutsak, tartib yo'qoladi

## Tartibsiz model

PE'siz Transformer so'zlar **to'plamini** ko'radi, ketma-ketlikni emas: "it odamni qopdi" va "odamni it qopdi" bir xil ifodalanadi — ma'no buziladi.

**Yechim:** kirishga PE qo'shish shart.  
Yana: head soni  $h$   $d$  ga bo'linishi kerak ( $d/h$  butun son).

# Prezentatsiya rejasi

- 1 Kirish: rekurrentlikdan butunlay voz kechamiz
- 2 Self-attention: har pozitsiya hammaga qaraydi
- 3 Multi-head attention va positional encoding
- 4 Transformer bloki va umumlashtirish**
- 5 Umumlashtirishni ROUGE bilan baholash
- 6 Xulosa va amaliyotga ko'prik



# Intuitsiya: bloklarni ustma-ust qalaymiz

Bitta Transformer bloki: **attention** (so'zlar gaplashadi) + **FFN** (har so'z alohida qayta ishlanadi), har biri atrofida **residual** va **LayerNorm**.

Bloklarni  $N$  marta qalaymiz. Umumlashtirish uchun: **enkoder** maqolani o'qiydi, **dekoder** xulosani yozadi (L11 seq2seq kabi).

Dekoder ikki attention ishlatadi: **masked self-attention** (kelajakni ko'rmaydi) + **cross-attention** (enkoderga qaraydi — L11 dagi attention!).

# Transformer bloki: rasmiy ta'rif

$$z = \text{LayerNorm}(x + \text{Sublayer}(x)), \quad \text{FFN}(x) = \max(0, xW_1 + b_1) W_2 + b_2$$

**bunda:**  $x$  — blok kirishi; Sublayer — MHA yoki FFN;  $x + \text{Sublayer}(x)$  — residual (qoldiq) ulanish; LayerNorm — qatlam normallash;  $W_1, W_2$  — FFN vaznlari;  $\max(0, \cdot)$  — ReLU. Har blokda ikki sublayer: MHA  $\rightarrow$  FFN, ikkalasi residual + LayerNorm bilan o'raladi.

## Keltirib chiqarish: nega residual, LayerNorm va mask?

**1-qadam.** Chuqur stek gradientni so'ndiradi  $\Rightarrow$  **residual**  $(x + \text{Sublayer}(x))$  gradientga "qisqa yo'l" beradi.

## Keltirib chiqarish: nega residual, LayerNorm va mask?

**1-qadam.** Chuqur stek gradientni so'ndiradi  $\Rightarrow$  **residual**  $(x + \text{Sublayer}(x))$  gradientga "qisqa yo'l" beradi. **2-qadam.** Qatlamlararo masshtab o'zgaradi  $\Rightarrow$  **LayerNorm** har vektorni o'rtacha 0, dispersiya 1 ga keltiradi.

## Keltirib chiqarish: nega residual, LayerNorm va mask?

**1-qadam.** Chuqur stek gradientni so'ndiradi  $\Rightarrow$  **residual** ( $x + \text{Sublayer}(x)$ ) gradientga "qisqa yo'l" beradi. **2-qadam.** Qatlamlararo masshtab o'zgaradi  $\Rightarrow$  **LayerNorm** har vektorni o'rtacha 0, dispersiya 1 ga keltiradi. **3-qadam.** Attention chiziqli-ga yaqin  $\Rightarrow$  **FFN** (ReLU) nochiziqlilik qo'shadi.

# Keltirib chiqarish: nega residual, LayerNorm va mask?

**1-qadam.** Chuqur stek gradientni so'ndiradi  $\Rightarrow$  **residual** ( $x + \text{Sublayer}(x)$ ) gradientga "qisqa yo'l" beradi. **2-qadam.** Qatlamlararo masshtab o'zgaradi  $\Rightarrow$  **LayerNorm** har vektorni o'rtacha 0, dispersiya 1 ga keltiradi. **3-qadam.** Attention chiziqli-ga yaqin  $\Rightarrow$  **FFN** (ReLU) nochiziqlilik qo'shadi. **4-qadam.** Dekoder kelajak so'zni ko'rmasligi kerak  $\Rightarrow$  **causal mask**:  $j > i$  pozitsiyalarga energiya  $-\infty$ .

**Xulosa:** residual + norm — barqaror chuqurlik; FFN — quvvat; mask — halol generatsiya.

## Qo'lda misol: residual va LayerNorm

$$x = [0, 1], \text{Sublayer}(x) = [1, 2] \Rightarrow x + \text{Sublayer}(x) = [1, 3].$$

**LayerNorm ( $\varepsilon$  e'tiborsiz):**

$$\mu = \frac{1+3}{2} = 2, \quad \sigma = \sqrt{\frac{(1-2)^2 + (3-2)^2}{2}} = 1$$
$$\hat{z} = \frac{[1,3]-2}{1} = [-1, 1]$$

Residual axborotni saqlaydi; Layer-Norm uni o'rtacha 0, dispersiya 1 ga keltiradi — keyingi blok barqaror kirish oladi.

# Sizning vazifangiz: uch o'lchamli vektorni normallang

## Savol — 90 soniya

Vektor  $v = [1, 2, 3]$  ni LayerNorm qiling ( $\varepsilon$  e'tiborsiz).

$$\mu = 2; \quad \sigma = \sqrt{\frac{(1-2)^2 + (2-2)^2 + (3-2)^2}{3}} = \sqrt{0.667} \approx 0.816.$$

$$\hat{z} = (v - \mu) / \sigma = ?$$



# Sizning vazifangiz: uch o'lchamli vektorni normallang

## Savol — 90 soniya

Vektor  $v = [1, 2, 3]$  ni LayerNorm qiling ( $\varepsilon$  e'tiborsiz).

$$\mu = 2; \quad \sigma = \sqrt{\frac{(1-2)^2 + (2-2)^2 + (3-2)^2}{3}} = \sqrt{0.667} \approx 0.816.$$

$$\hat{z} = (v - \mu) / \sigma = ?$$

## Javob

$$\hat{z} = \frac{[-1, 0, 1]}{0.816} = [-1.22, 0, 1.22]$$

O'rtacha 0, dispersiya 1. O'rtadagi qiymat ( $2 = \mu$ ) nolga aylandi — normallash markazni siljitadi.

# Kod $\leftrightarrow$ formula: Transformer enkoder bloki

```
1 import torch.nn as nn
2
3 class EncoderBlock(nn.Module):
4     def __init__(self, d, h, ff):
5         super().__init__()
6         self.mha = nn.MultiheadAttention(d, h,
7             batch_first=True)
8         self.ffn = nn.Sequential(
9             nn.Linear(d, ff), nn.ReLU(), nn.
10                Linear(ff, d))
11         self.n1, self.n2 = nn.LayerNorm(d), nn.
12            LayerNorm(d)
13
14     def forward(self, x):
15         a, _ = self.mha(x, x, x)      # self-
16             attention
17         x = self.n1(x + a)             # residual +
18             norm
19         return self.n2(x + self.ffn(x))
```

## Kod $\rightarrow$ formula:

| Kod        | Formula             |
|------------|---------------------|
| mha(x,x,x) | self-attention      |
| n1(x+a)    | residual+norm       |
| ffn        | $\max(0, \cdot)W_2$ |

P12 da m12 shu blokdan enkoder-dekoder umumlashtirgich quradi.

# Transformer tuzog'i: dekodeerda causal mask shart

## Mask'ni unutish

Dekoder o'qitishda mask qo'ymasak, model keyingi so'zni **ko'rib** bashorat qiladi (aldash). O'qitishda loss past, ammo haqiqiy generatsiyada model ishlamaydi.

**Yechim:** causal mask —  $j > i$  pozitsiyalarga  $-\infty$ . Yana: PE'ni qo'shishni unutmang (oldingi tuzoq).

# Prezentatsiya rejasi

- 1 Kirish: rekurrentlikdan butunlay voz kechamiz
- 2 Self-attention: har pozitsiya hammaga qaraydi
- 3 Multi-head attention va positional encoding
- 4 Transformer bloki va umumlashtirish
- 5 Umumlashtirishni ROUGE bilan baholash**
- 6 Xulosa va amaliyotga ko'prik

# Intuitsiya: xulosa etalon mazmunini qanchalik qamradi?

Umumlashtirishda asosiy savol: model etalon xulosadagi **muhim mazmunni** qamradimi? **ROUGE** buni o'lchaydi — etalon va generatsiya orasidagi n-gram ustma-ustligi.

L11 dagi BLEU **aniqlikka** (precision) urg'u berardi (tarjima); ROUGE **to'liqlikka** (recall) — xulosa hech narsani tushirib qoldirmadimi?

ROUGE-1 — unigram ustma-ustligi;  
ROUGE-L — eng uzun umumiy ketma-ketlik (LCS). Recall, precision va  $F_1$  hisoblanadi.

## ROUGE-1: rasmiy ta'rif

$$P = \frac{|\text{mos unigramlar}|}{|\text{hypothesis}|}, \quad R = \frac{|\text{mos unigramlar}|}{|\text{reference}|}, \quad F_1 = \frac{2PR}{P + R}$$

**bunda:**  $P$  — aniqlik (precision): generatsiyaning qancha qismi etalonda bor;  $R$  — to'liqlik (recall): etalonning qancha qismi qamrandi;  $F_1$  — ikkisining garmonik o'rtachasi. BLEU faqat  $P$  ga o'xshash edi; ROUGE  $R$  ni ham hisoblaydi — shuning uchun umumlashtirishga mos.

# Keltirib chiqarish: nega recall, precision va $F_1$ ?

**1-qadam. Recall:** etalon xulosaning qancha so'zi generatsiyada bor? Muhim mazmun tushib qolmadimi — umumlashtirishning asosi.

## Keltirib chiqarish: nega recall, precision va $F_1$ ?

**1-qadam. Recall:** etalon xulosaning qancha so'zi generatsiyada bor? Muhim mazmun tushib qolmadimi — umumlashtirishning asosi. **2-qadam.** Faqat recall'ni ko'paytirish oson: hamma narsani yozsak  $R = 1$ , ammo xulosa uzun va keraksiz  $\Rightarrow$  **precision** kerak.



# Keltirib chiqarish: nega recall, precision va $F_1$ ?

**1-qadam. Recall:** etalon xulosaning qancha so'zi generatsiyada bor? Muhim mazmun tushib qolmadimi — umumlashtirishning asosi. **2-qadam.** Faqat recall'ni ko'paytirish oson: hamma narsani yozsak  $R = 1$ , ammo xulosa uzun va keraksiz  $\Rightarrow$  **precision** kerak. **3-qadam.**  $P$  va  $R$  ni muvozanatlash uchun ularning garmonik o'rtachasi —  $F_1$ . Bittasi past bo'lsa,  $F_1$  ham past.

**Xulosa:**  $F_1$  — qisqalik (precision) va to'liqlik (recall) o'rtasidagi muvozanat. Endi qo'lda hisoblaymiz.

## Qo'lda hisob: ROUGE-1 $F_1 = 0.750$

Reference: nlp juda qiziq va foydali (5 token); Hypothesis: nlp juda foydali (3 token).

**Mos unigramlar:** nlp, juda, foydali — 3 ta (barchasi etalonda bor).

$$P = \frac{3}{3} = \mathbf{1.000}$$

$$R = \frac{3}{5} = \mathbf{0.600}$$

$$F_1 = \frac{2 \cdot 1.0 \cdot 0.6}{1.0 + 0.6} = \frac{1.2}{1.6} = \mathbf{0.750}$$

Barcha hypothesis so'zlari etalonda ( $P = 1$ ); ammo etalonning 2 so'zi (qiziq, va) tushib qoldi ( $R = 0.6$ ).

Ertangi P12 birinchi assert:

```
assert abs(f1 - 0.750)  
< 1e-3  
# Ma'ruza L12 [l4]-slayd
```

# Sizning vazifangiz: boshqa hypothesis uchun ROUGE-1

## Savol — 90 soniya

Reference: nlp juda qiziq va foydali (5); Hypothesis: nlp foydali yaxshi (3 token).  
Mos unigramlar: nlp, foydali (2 ta; yaxshi etalonda yo'q).

$P = ?$ ,  $R = ?$ ,  $F_1 = ?$

# Sizning vazifangiz: boshqa hypothesis uchun ROUGE-1

## Savol — 90 soniya

Reference: nlp juda qiziq va foydali (5); Hypothesis: nlp foydali yaxshi (3 token).  
Mos unigramlar: nlp, foydali (2 ta; yaxshi etalonda yo'q).

$P = ?$ ,  $R = ?$ ,  $F_1 = ?$

## Javob

$$P = \frac{2}{3} \approx 0.667; \quad R = \frac{2}{5} = 0.400; \quad F_1 = \frac{2 \cdot 0.667 \cdot 0.4}{0.667 + 0.4} = \frac{0.533}{1.067} = \mathbf{0.500}$$

yaxshi etalonda yo'q  $\Rightarrow P$  tushdi; bitta mos so'z kam  $\Rightarrow R$  ham past.  $F_1$  ikkisini birlashtiradi.

# Kod ↔ formula: ROUGE-1

```
1 from collections import Counter
2
3 def rouge1(ref, hyp):
4     r, h = ref.split(), hyp.split()
5     overlap = sum((Counter(h) & Counter(r)).
6                   values())
7     p = overlap / len(h)
8     rec = overlap / len(r)
9     f1 = 2 * p * rec / (p + rec) if p + rec else
10         0.0
11     return p, rec, f1
12
13 ref = "nlp juda qiziq va foydali"
14 hyp = "nlp juda foydali"
15 print(rouge1(ref, hyp))    # (1.0, 0.6, 0.75)
```

## Kod → formula:

| Kod       | Formula     |
|-----------|-------------|
| &         | mos unigram |
| /len(h)   | $P$         |
| /len(r)   | $R$         |
| 2pr/(p+r) | $F_1$       |

Counter & — clipping (takroni cheklaydi). P12 da shu mantiqni m12 da ishlatamiz.

# ROUGE tuzog'i: yuqori ROUGE har doim yaxshi xulosa emas

## Cheklovlar

- Yuza ustma-ustlikni o'lchaydi — ravonlik/grammatikani emas.
- Sinonim va qayta ifodani jazolaydi (aniq so'z mosligi kerak).
- Faqat recall'ga qarasak, uzun xulosa "aldab" yuqori ball oladi.

**Amalda:**  $F_1$  (recall + precision) ishlatiladi; ma'no-asosli metrikalar (BERTScore) bilan to'ldiriladi.

# Prezentatsiya rejasi

- 1 Kirish: rekurrentlikdan butunlay voz kechamiz
- 2 Self-attention: har pozitsiya hammaga qaraydi
- 3 Multi-head attention va positional encoding
- 4 Transformer bloki va umumlashtirish
- 5 Umumlashtirishni ROUGE bilan baholash
- 6 Xulosa va amaliyotga ko'prik

# O'zbek tilida: positional encoding va erkin so'z tartibi

## 1. Erkin so'z tartibi:

O'zbekcha "men kitobni o'qidim" va "kitobni men o'qidim" — ikkalasi to'g'ri. Self-attention so'zlar **to'plamini** ko'radi, tartibga befarq.

### Savol

PE tartibni kiritadi — bu erkin tartibga **yordam beradimi** yoki **xalaqit qiladimi**?

## 2. Tahlil:

Self-attention'ning o'zi tartibga befarq — shuning uchun "men kitobni" va "kitobni men" mazmunan yaqin ifodalanadi (o'zbek uchun afzal).

PE tartib ma'lumotini **qo'shadi**, lekin majburlamaydi — model o'zbek erkin tartibini ham o'rgana oladi. SOV/SVO Transformer uchun RNN'dagidan oson.



## Sintez: RNN/LSTM'dan Transformer'ga

| Jihat           | RNN / LSTM             | Transformer          |
|-----------------|------------------------|----------------------|
| Hisob           | ketma-ket ( $n$ qadam) | parallel (1 qadam)   |
| Uzoq bog'liqlik | $O(n)$ yo'l, sust      | $O(1)$ yo'l, kuchli  |
| So'z tartibi    | tabiiy (rekurrent)     | positional encoding  |
| Murakkablik     | $O(n)$                 | $O(n^2)$ (attention) |

### Asosiy g'oya

Transformer rekurrentlikni self-attention bilan almashtiradi: to'liq parallel, uzoq bog'liqlikka kuchli. Narxi —  $O(n^2)$  attention va PE zarurati. Umumlashtirishni ROUGE bilan baholaymiz.

# Seminal manba: Vaswani va boshqalar (2017)

Vaswani, A., Shazeer, N., Parmar, N., va boshq. (2017). **Attention Is All You Need.** *NeurIPS* 30.

## Ahamiyati:

- Rekurrentlik va konvolyutsiyasiz, faqat attention bilan modelni qurdi.
- To'liq parallel o'qitish — katta modellar (BERT, GPT) uchun asos.
- Zamonaviy NLP'ning deyarli barchasi shu arxitektura ustiga qurilgan.


## Muhokama savoli (P12 gacha o'ylang)

Self-attention  $O(n^2)$  — juda uzun hujjat (10000 so'z) uchun bu nima muammo tug'diradi? O'zbek agglutinatsiyasi token sonini oshirsa, bu qanchalik og'irlashadi?

# Bugungi maqsadlar bajarildi

- 1 ✓ **Tushuntirdik:** nega Transformer rekurrentlikdan voz kechadi — parallellashtirish va uzoq bog'liqlik.
- 2 ✓ **Hisobladik:** self-attention vaznlari  $\alpha = \text{softmax}([2, 1, 3]) = [0.245, 0.090, 0.665]$ .
- 3 ✓ **Tushuntirdik:** multi-head attention, positional encoding va residual + layer norm.
- 4 ✓ **Hisobladik:** ROUGE-1  $P = 1.0$ ,  $R = 0.6$ ,  $F_1 = 0.75$ .

# Ertaga P12: Transformer bilan matn umumlashtiramiz



## P12 da qurasiz:

- m12 TransformerSummarizer: self-attention + PE
- Wikipedia uz maqola-xulosa juftlarida o'qitish
- ROUGE-1 bilan baholash

## Birinchi assert (bu slayd [I4]):

```
assert abs(  
    f1 - 0.750) < 1e-3  
  
# Ma'ruza L12 [I4]-slayd bilan  
# solishtiring (ROUGE-1 F1)
```

- ① Vaswani, A., va boshq. (2017). *Attention Is All You Need*. NeurIPS 30.
- ② Lin, C.-Y. (2004). *ROUGE: A Package for Automatic Evaluation of Summaries*. ACL Workshop.
- ③ Devlin, J., va boshq. (2019). *BERT: Pre-training of Deep Bidirectional Transformers*. NAACL-HLT 2019.
- ④ Raffel, C., va boshq. (2020). *Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer (T5)*. JMLR 21.
- ⑤ `torch.nn.Transformer` va `rouge_score` hujjatlari.

# Ilova S1: multi-head attention to'liq matematikasi

$h$  ta head, har biri  $d_k = d/h$  o'lchamli:

$$\text{head}_i = \text{softmax} \left( \frac{(XW_i^Q)(XW_i^K)^\top}{\sqrt{d_k}} \right) (XW_i^V)$$

**bunda:**  $W_i^Q, W_i^K, W_i^V \in \mathbb{R}^{d \times d_k}$  — har head proyeksiyalari; natijalar konkatensatsiya qilinib  $W^O \in \mathbb{R}^{d \times d}$  bilan birlashtiriladi.

Har head turli munosabatni o'rganadi;  $d_k = d/h$  tanlovi umumiy hisobni bitta to'liq o'lchamli attention bilan teng saqlaydi.

## Ilova S2: ROUGE-L (eng uzun umumiy ketma-ketlik)

ROUGE-L unigram emas, **LCS** (longest common subsequence) ga asoslanadi:

$$R_{lcs} = \frac{\text{LCS}(X, Y)}{|Y|}, \quad P_{lcs} = \frac{\text{LCS}(X, Y)}{|X|}, \quad F_{lcs} = \frac{2P_{lcs}R_{lcs}}{P_{lcs} + R_{lcs}}$$

**bunda:**  $X$  — hypothesis,  $Y$  — reference; LCS — tartibni saqlagan eng uzun umumiy ketma-ketlik uzunligi.

Misol:  $X = \text{nlp juda foydali}$ ,  $Y = \text{nlp juda qiziq va foydali} \Rightarrow \text{LCS} = \text{nlp juda foydali}$  (uzunligi 3, tartib saqlangan).