

Transfer Learning va oldindan o'qitilgan modellar (BERT, T5)

Tabiiy tilni qayta ishlash — 13-ma'ruza

A.A. Abdulali

11:00–12:20 · mavzu №13

6-iyul 2026

Prezentatsiya rejasi

- 1 Kirish: noldan o'qitmaymiz, oldindan o'qitilganni olamiz
- 2 Transfer learning: pre-training va fine-tuning
- 3 BERT: ikki tomonlama enkoder
- 4 T5: hamma narsa matndan matnga
- 5 Hugging Face ekotizimi
- 6 Xulosa va amaliyotga ko'prik

Takrorlash: o'tgan darsdan ikki savol

1-savol

L12 da Transformer'ni quridik. Uni o'qitish uchun nima kerak edi — qancha ma'lumot va hisob?

2-savol

O'zbek tili uchun millionlab yorliqlangan namuna yo'q. Unda kuchli Transformer'ni qanday quramiz?

Takrorlash: o'tgan darsdan ikki savol

1-savol

L12 da Transformer'ni quridik. Uni o'qitish uchun nima kerak edi — qancha ma'lumot va hisob?

2-savol

O'zbek tili uchun millionlab yorliqlangan namuna yo'q. Unda kuchli Transformer'ni qanday quramiz?

1-javob

Juda ko'p: katta korpus, ko'p GPU, kunlab o'qitish. Noldan har safar bu — isrof.

2-javob

Oldindan o'qitilgan modelni olamiz va kichik datada **sozlaymiz** (fine-tuning) — bugungi mavzu: transfer learning.

Siz bugungi dars oxirida quyidagilarni bajara olasiz:

- ➊ **Tushuntira olasiz:** transfer learning — pre-training va fine-tuning farqi va nega kam-resursli til uchun zarur.
- ➋ **Hisoblay olasiz:** fine-tuning BCE yo'qotishini — $\sigma(2.0) \approx 0.880$, $\text{BCE} \approx 0.128$.
- ➌ **Tushuntira olasiz:** BERT (ikki tomonlama enkoder, MLM) va T5 (matn→matn) farqini.
- ➍ **Tushuntira olasiz:** Hugging Face ekotizimi bilan fine-tuning oqimini.

L12 dan: Transformer, self-attention. L2 dan: logistik regressiya, sigmoid. L6/L9 dan: softmax. Matematikadan: exp, ln, ehtimol.

Bugungi dars rejasi:

Tsiki	Mavzu	Vaqt	Hosil natija	bo'luvchi
1	Transfer learning va fine-tuning	16 daq	BCE = 0.128	
2	BERT: ikki tomonlama enkoder	16 daq	MLM bashorati	
3	T5: matndan matnga	16 daq	yagona format	
4	Hugging Face ekotizimi	16 daq	fine-tuning oqimi	
	Xulosa va 13-amaliyotga ko'rsatmalar	10 daq	Ertaga nima qurishingiz	

Bu dars fine-tuning'ga olib keladi

Oldindan o'qitilgan modelni kichik datada sozlaymiz. Bugungi BCE = 0.128 ertangi P13 da assert bo'ladi.

Bugungi dars uchun muammo: noldan o'qitish kam-resursli til uchun imkonsiz

Noldan o'qitish qayerda qiynaladi:

Ulkan ma'lumot talabi

Kuchli Transformer milliardlab so'z va minglab GPU-soat talab qiladi. O'zbek uchun bunday yorliqlangan korpus yo'q.

Har vazifaga qaytadan

Sentiment, NER, tarjima — har biri uchun noldan o'qitish ulkan isrof.

Bugungi yechim:

- 1 Katta korpusda **bir marta** oldindan o'qitilgan model (umumiy til bilimi).
- 2 Uni **kichik** yorliqlangan datada **sozlaymiz** (fine-tuning).
- 3 Bilim **ko'chiriladi** (transfer) — kam data, kam hisob.

BERT, T5 — L12 dagi Transformer ustiga qurilgan, oldindan o'qitilgan modellar. Biz ularni olamiz.

Prezentatsiya rejasi

- 1 Kirish: noldan o'qitmaymiz, oldindan o'qitilganni olamiz
- 2 Transfer learning: pre-training va fine-tuning
- 3 BERT: ikki tomonlama enkoder
- 4 T5: hamma narsa matndan matnga
- 5 Hugging Face ekotizimi
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: avval umumiy o'rgan, keyin vazifaga moslan

Inson ham tilni avval umumiy o'rganadi, keyin aniq kasbga moslashtiradi. Model ham:

- **Pre-training:** katta yorliqsiz korpusda umumiy til bilimi (o'z-o'zini nazorat).
- **Fine-tuning:** kichik yorliqlangan datada aniq vazifaga sozlash (nazorat ostida).

Oldindan o'qitilgan vaznlar — yaxshi **boshlang'ich nuqta**. Fine-tuning ularni biroz suradi, noldan boshlamaydi.

Fine-tuning yo'qotishi: rasmiy ta'rif

$$p = \sigma(z) = \frac{1}{1 + e^{-z}}, \quad \text{BCE} = -[y \ln p + (1 - y) \ln(1 - p)]$$

bunda: z — model logiti (oxirgi qatlam chiqishi); p — ijobiy sinf ehtimoli; $y \in \{0, 1\}$ — haqiqiy yorliq (ijobiy = 1, salbiy = 0); BCE — ikkilik kross-entropiya yo'qotishi. Fine-tuning bu yo'qotishni kichik yorliqlangan datada minimallashtiradi — oldindan o'qitilgan vaznlardan boshlab.

Keltirib chiqarish: nega avval pre-train, keyin fine-tune?

1-qadam. Tasodifiy boshlang'ich vaznlar juda ko'p yorliqlangan ma'lumot talab qiladi — o'zbek uchun yo'q.

Keltirib chiqarish: nega avval pre-train, keyin fine-tune?

1-qadam. Tasodifiy boshlang'ich vaznlar juda ko'p yorliqlangan ma'lumot talab qiladi — o'zbek uchun yo'q. **2-qadam.** Yorliqsiz katta korpusda o'z-o'zini nazorat (masalan, niqoblangan so'zni bashorat) — bu ma'lumot **ko'p va arzon**.

Keltirib chiqarish: nega avval pre-train, keyin fine-tune?

1-qadam. Tasodifiy boshlang'ich vaznlar juda ko'p yorliqlangan ma'lumot talab qiladi — o'zbek uchun yo'q. **2-qadam.** Yorliqsiz katta korpusda o'z-o'zini nazorat (masalan, niqoblangan so'zni bashorat) — bu ma'lumot **ko'p va arzon**. **3-qadam.** Model umumiy til naqshlarini o'rganadi — yaxshi boshlang'ich vaznlar.

Keltirib chiqarish: nega avval pre-train, keyin fine-tune?

1-qadam. Tasodifiy boshlang'ich vaznlar juda ko'p yorliqlangan ma'lumot talab qiladi — o'zbek uchun yo'q. **2-qadam.** Yorliqsiz katta korpusda o'z-o'zini nazorat (masalan, niqoblangan so'zni bashorat) — bu ma'lumot **ko'p va arzon**. **3-qadam.** Model umumiy til naqshlarini o'rganadi — yaxshi boshlang'ich vaznlar. **4-qadam.** Kichik yorliqlangan datada faqat **sozlaymiz** — BCE ni minimallashtiramiz, kam qadamda.

Xulosa: pre-training bilimni beradi, fine-tuning uni vazifaga buradi. Endi BCE'ni qo'lda hisoblaymiz.

Qo'lda hisob: sigmoid va BCE yo'qotishi = 0.128

$$e^{-2.0} \approx 0.135.$$

Sigmoid va BCE:

$$p = \sigma(2.0) = \frac{1}{1+0.135} = \frac{1}{1.135} \approx \mathbf{0.880}$$

$$\text{BCE} = -\ln(0.880) \approx \mathbf{0.128}$$

Model ijobiy sinfga 0.880 ishonch berdi;
yorliq ham ijobiy $\Rightarrow$ **past** yo'qotish
(0.128).

Ertangi P13 birinchi assert:

```
assert abs(loss - 0.128)  
< 1e-2
```

Ma'ruza L13 [l1]-slayd

Sizning vazifangiz: nol logit uchun BCE

Savol — 60 soniya

Model ishonchsiz: logit $z = 0.0$, yorliq $y = 1$ (ijobiy). $\sigma(0) = 0.5$.

BCE = $-\ln(0.5) = ?$ ($\ln 2 \approx 0.693$)

Sizning vazifangiz: nol logit uchun BCE

Savol — 60 soniya

Model ishonchsiz: logit $z = 0.0$, yorliq $y = 1$ (ijobiy). $\sigma(0) = 0.5$.

$BCE = -\ln(0.5) = ?$ ($\ln 2 \approx 0.693$)

Javob

$BCE = -\ln(0.5) = \ln 2 \approx \mathbf{0.693}$

Ishonchsiz bashorat (50/50) yo'qotishi 0.693 — ishonchli to'g'ri (0.128) dan ancha yuqori. Fine-tuning buni pasaytiradi.

Kod ↔ formula: BCE yo'qotishi

```
1 import torch
2 import torch.nn as nn
3
4 logit = torch.tensor([2.0])      # model
   chiqishi
5 target = torch.tensor([1.0])    # ijobiy
   yorliq
6 loss_fn = nn.BCEWithLogitsLoss()
7 loss = loss_fn(logit, target)
8
9 print(float(torch.sigmoid(logit))) # 0.880
10 print(float(loss))                # 0.128
```

Kod → formula:

Kod	Formula
sigmoid	$\sigma(z)$
BCEWith...	$-\ln p(y=1)$

BCEWithLogitsLoss sigmoid'ni ichida bajaradi (barqaror). P13 da m13 fine-tuning shu loss'ni ishlatadi.

Fine-tuning tuzog'i: katta o'rganish tezligi bilimni "unuttiradi"

Catastrophic forgetting

Fine-tuning'da η (learning rate) katta bo'lsa, oldindan o'qitilgan bilim **buziladi** — model umumiy tilni unutadi.

Yechim: kichik η (masalan 2×10^{-5}), kam epoch (2–3), warmup. Kichik datada overfitting'dan ham ehtiyot bo'ling.

Prezentatsiya rejasi

- 1 Kirish: noldan o'qitmaymiz, oldindan o'qitilganni olamiz
- 2 Transfer learning: pre-training va fine-tuning
- 3 BERT: ikki tomonlama enkoder**
- 4 T5: hamma narsa matndan matnga
- 5 Hugging Face ekotizimi
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: so'zni ikkala tomondan tushunamiz

BERT — Transformer **enkoder** stegi (L12). U gapni o'qiydi va har so'zni **chap va o'ng** kontekst bilan birga tushunadi (ikki tomonlama).

"U *bankka* bordi" — "bankka" ma'nosi (pul/daryo) ikkala tomondagi so'zlardan aniqlanadi. [CLS] maxsus tokeni butun gap vakili bo'ladi.

BERT **generatsiya qilmaydi** (dekoder yo'q) — u tushunish (klassifikatsiya, NER) uchun. Fine-tuning'da [CLS] vektoriga klassifikator qo'shamiz.

BERT pre-training: masked language modeling

$$\mathcal{L}_{\text{MLM}} = -\sum_{i \in M} \ln p(x_i \mid x_{\setminus M}), \quad p(x_i \mid \cdot) = \text{softmax}(Wh_i)$$

bunda: M — niqoblangan pozitsiyalar (taxminan 15%); $x_{\setminus M}$ — niqoblanmagan kontekst (ikkala tomon); h_i — i -pozitsiya enkoder holati; $p(x_i \mid \cdot)$ — lug'at ustidan softmax. Model niqoblangan so'zni **ikki tomonlama** kontekstdan bashorat qiladi — shu tariqa chuqur til bilimi o'rganiladi.

Keltirib chiqarish: nega niqoblash kerak?

1-qadam. Oddiy til modeli (L7/L9) faqat **chapdan** bashorat qiladi — o'ng kontekstni ko'rmaydi.

Keltirib chiqarish: nega niqoblash kerak?

1-qadam. Oddiy til modeli (L7/L9) faqat **chapdan** bashorat qiladi — o'ng kontekstni ko'rmaydi. **2-qadam.** Ikki tomonlama qilsak, so'z **o'zini** ko'rib qo'yadi (aldash) — bashorat ma'nosiz bo'ladi.

Keltirib chiqarish: nega niqoblash kerak?

1-qadam. Oddiy til modeli (L7/L9) faqat **chapdan** bashorat qiladi — o'ng kontekstni ko'rmaydi. **2-qadam.** Ikki tomonlama qilsak, so'z **o'zini** ko'rib qo'yadi (aldash) — bashorat ma'nosiz bo'ladi. **3-qadam.** Yechim: ba'zi so'zlarni [MASK] bilan **niqoblaymiz**, qolganini ko'rsatamiz — model niqoblanganini topishi kerak.

Keltirib chiqarish: nega niqoblash kerak?

1-qadam. Oddiy til modeli (L7/L9) faqat **chapdan** bashorat qiladi — o'ng kontekstni ko'rmaydi. **2-qadam.** Ikki tomonlama qilsak, so'z **o'zini** ko'rib qo'yadi (aldash) — bashorat ma'nosiz bo'ladi. **3-qadam.** Yechim: ba'zi so'zlarni [MASK] bilan **niqoblaymiz**, qolganini ko'rsatamiz — model niqoblanganini topishi kerak. **4-qadam.** Endi ikkala tomon ham ishlatiladi, aldash yo'q — chuqur ikki tomonlama bilim.

Xulosa: MLM ikki tomonlamalik va halol bashoratni birlashtiradi. Endi bitta niqobni qo'lda bashorat qilamiz.

Qo'lda misol: niqoblangan so'zni bashorat

"Men bozordan [MASK] oldim." Logitlar: kitob= 1, olma= 3, non= 2.

Softmax:

$$\sum = e^1 + e^3 + e^2 = 2.718 + 20.086 + 7.389 = 30.193$$

$$p = \frac{[2.718, 20.086, 7.389]}{30.193}$$
$$= [0.090, \mathbf{0.665}, 0.245]$$

Eng katta ehtimol **olma** (0.665) — model niqob o'rniga "olma" ni bashorat qiladi. Softmax L6/L9 dagi kabi.

Savol — 60 soniya

Logitlar: $a = 1$, $b = 1$, $c = 2$. $p = \text{softmax}([1, 1, 2]) = ?$
($e^1 \approx 2.718$, $e^2 \approx 7.389$)

Sizning vazifangiz: boshqa logitlar uchun bashorat

Savol — 60 soniya

Logitlar: $a = 1$, $b = 1$, $c = 2$. $p = \text{softmax}([1, 1, 2]) = ?$
($e^1 \approx 2.718$, $e^2 \approx 7.389$)

Javob

$\sum = 2.718 + 2.718 + 7.389 = 12.825$; $p = \frac{[2.718, 2.718, 7.389]}{12.825} = [0.212, 0.212, \mathbf{0.576}]$
 c eng ehtimolli (0.576). Teng logitli a, b teng ehtimol oldi.

Kod ↔ formula: BERT [CLS] vektori

```
1 from transformers import AutoTokenizer, AutoModel
2
3 name = "bert-base-multilingual-cased"
4 tok = AutoTokenizer.from_pretrained(name)
5 model = AutoModel.from_pretrained(name)
6
7 inp = tok("Bu film juda zo'r", return_tensors="pt")
8
9 out = model(**inp)
10 cls = out.last_hidden_state[:, 0]    # [CLS]
    vektori
11 print(cls.shape)                    # (1, 768)
```

Kod → formula:

Kod	Formula
from_pretr.	oldindan o'qitilgan
[:, 0]	[CLS] h_0

[CLS] vektori gap vakili — ustiga klassifikator qo'yib fine-tune qilamiz (P13).

BERT tuzog'i: u matn yarata olmaydi

Faqat enkoder

BERT — enkoder; dekoder yo'q. Undan tarjima yoki xulosa **generatsiya** qilib bo'lmaydi. U tushunish vazifalari uchun (klassifikatsiya, NER).

Yechim: generatsiya kerak bo'lsa — T5 yoki GPT (dekoderli). Klassifikatsiya kerak bo'lsa — BERT ideal.

Prezentatsiya rejasi

- 1 Kirish: noldan o'qitmaymiz, oldindan o'qitilganni olamiz
- 2 Transfer learning: pre-training va fine-tuning
- 3 BERT: ikki tomonlama enkoder
- 4 T5: hamma narsa matndan matnga**
- 5 Hugging Face ekotizimi
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: har vazifani bitta formatga keltiramiz

T5 — Transformer **enkoder-dekoder** (L12). Asosiy g'oya: **har** vazifa "matn kiritish → matn chiqarish" sifatida ifodalanadi.

"translate uz-en: men keldim" → "i came";

"sentiment: bu film zo'r" → "ijobiy".

Vazifa **prefiks** bilan bildiriladi.

Bitta model, bitta format — klassifikatsiya, tarjima, xulosa hammasi matn→matn. Alohida "head" shart emas.

T5: matn-dan-matnga yo'qotish

$$\mathcal{L} = - \sum_{t=1}^T \ln p(y_t \mid y_{<t}, x), \quad \text{vazifa} = \text{prefiks}(x)$$

bunda: x — prefiksli kiritish matni; y_t — chiqish ketma-ketligining t -tokeni; $y_{<t}$ — oldingi tokenlar (dekoder, L11/L12); prefiks vazifani bildiradi ("summarize:", "sentiment:"). Pre-training:

span-corruption (bir necha so'zli bo'lakni niqoblab, tiklash). Hamma vazifa bitta loss bilan o'qitiladi.

Keltirib chiqarish: nega yagona matn-matn format?

1-qadam. Klassik yondashuvda har vazifa boshqa chiqish qatlami ("head") va boshqa loss talab qiladi.

Keltirib chiqarish: nega yagona matn-matn format?

1-qadam. Klassik yondashuvda har vazifa boshqa chiqish qatlami ("head") va boshqa loss talab qiladi. **2-qadam.** Agar chiqishni ham **matn** desak, hamma vazifa bir xil ko'rinadi — bitta model yetadi.

Keltirib chiqarish: nega yagona matn-matn format?

1-qadam. Klassik yondashuvda har vazifa boshqa chiqish qatlami ("head") va boshqa loss talab qiladi. **2-qadam.** Agar chiqishni ham **matn** desak, hamma vazifa bir xil ko'rinadi — bitta model yetadi. **3-qadam.** Vazifani ajratish uchun kiritishga **prefiks** qo'shamiz ("summarize:", "translate:").

Keltirib chiqarish: nega yagona matn-matn format?

1-qadam. Klassik yondashuvda har vazifa boshqa chiqish qatlami ("head") va boshqa loss talab qiladi. **2-qadam.** Agar chiqishni ham **matn** desak, hamma vazifa bir xil ko'rinadi — bitta model yetadi. **3-qadam.** Vazifani ajratish uchun kiritishga **prefiks** qo'shamiz ("summarize:", "translate:"). **4-qadam.** O'qitish — bitta ketma-ketlik kross-entropiyasi (L9/L12 dagi kabi). Yangi vazifa = yangi prefiks.

Xulosa: matn→matn — universal interfeys. Endi bitta chiqish tokeni yo'qotishini hisoblaymiz.

Qo'lda misol: chiqish tokeni yo'qotishi

Kiritish: "sentiment: bu film zo'r"; kutilgan chiqish: "ijobiy". Model $p(\text{ijobiy}) = 0.665$ bergan.

Kross-entropiya (bir token):

$$\begin{aligned}\mathcal{L} &= -\ln p(\text{ijobiy}) \\ &= -\ln(0.665) \approx \mathbf{0.408}\end{aligned}$$

Chiqish ham token — yo'qotish o'sha softmax kross-entropiyasi. Ehtimol oshsa, yo'qotish pasayadi.

Sizning vazifangiz: past ehtimol uchun yo'qotish

Savol — 60 soniya

Model to'g'ri tokeniga atigi $p = 0.245$ ishonch bergan.

$$\mathcal{L} = -\ln(0.245) = ? \quad (\ln(0.245) \approx -1.406)$$

Sizning vazifangiz: past ehtimol uchun yo'qotish

Savol — 60 soniya

Model to'g'ri tokeniga atigi $p = 0.245$ ishonch bergan.

$$\mathcal{L} = -\ln(0.245) = ? \quad (\ln(0.245) \approx -1.406)$$

Javob

$$\mathcal{L} = -\ln(0.245) \approx \mathbf{1.406}$$

Past ehtimol $\Rightarrow$ yuqori yo'qotish ($1.406 \gg 0.408$). Fine-tuning bu yo'qotishni pasaytirib, to'g'ri tokeniga ishonchni oshiradi.

Kod ↔ formula: T5 matn-dan-matnga

```
1 from transformers import T5Tokenizer
2 from transformers import
   T5ForConditionalGeneration
3
4 name = "t5-small"
5 tok = T5Tokenizer.from_pretrained(name)
6 model = T5ForConditionalGeneration.
   from_pretrained(name)
7
8 inp = tok("summarize: ...", return_tensors="pt")
9 ids = model.generate(**inp, max_length=20)
0 print(tok.decode(ids[0]))
```

Kod → formula:

Kod	Formula
"summarize:"	prefiks(x)
generate	$y_t \sim p(\cdot)$

Prefiks vazifani tanlaydi; dekoder chiqishni token-token generatsiya qiladi (L11/L12).

T5 tuzog'i: noto'g'ri prefiks — noto'g'ri xatti-harakat

Prefiksni unutish

T5 vazifani **prefiks**dan biladi. Prefiks noto'g'ri yoki yo'q bo'lsa, model boshqa vazifani bajaradi (masalan, xulosa o'rniga tarjima).

Yechim: har vazifaga aniq, izchil prefiks. O'zbek uchun prefikslar inglizcha qoladi (model shunday o'qitilgan).

Prezentatsiya rejasi

- 1 Kirish: noldan o'qitmaymiz, oldindan o'qitilganni olamiz
- 2 Transfer learning: pre-training va fine-tuning
- 3 BERT: ikki tomonlama enkoder
- 4 T5: hamma narsa matndan matnga
- 5 Hugging Face ekotizimi**
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: tayyor modellar ombori va bir necha qatorlik fine-tuning

Hugging Face — oldindan o'qitilgan minglab modellar ombori va ularni ishlatish kutubxonalari:

- `transformers` — modellar va tokenizatorlar.
- `datasets` — ma'lumotlar.
- `Trainer` — o'qitish siklini avtomatlashtiradi.

`from_pretrained` bilan modelni bir qatorda yuklab, kichik datada bir necha qatorda fine-tune qilamiz — noldan kod yozmaymiz.

Fine-tuning yangilanishi: rasmiy ta'rif

$$\theta \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L}, \quad \eta_t = \eta_{\max} \cdot \min\left(1, \frac{t}{t_{\text{warmup}}}\right)$$

bunda: θ — model vaznlari (oldindan o'qitilgan init); η — o'rganish tezligi (kichik, masalan 2×10^{-5}); $\mathcal{L}$ — vazifa yo'qotishi (BCE/CE); t_{warmup} — warmup qadamlari soni. Trainer shu yangilanishni avtomatik bajaradi — biz faqat giperparametrlarni beramiz.

Keltirib chiqarish: nega Hugging Face ekotizimi?

1-qadam. Modellar turli joyda, turli formatda — yuklab ishlatish qiyin.

Keltirib chiqarish: nega Hugging Face ekotizimi?

1-qadam. Modellar turli joyda, turli formatda — yuklab ishlatish qiyin. **2-qadam.** `from_pretrained` har modelni **bir xil** interfeys bilan yuklaydi (tokenizator + vaznlar).

Keltirib chiqarish: nega Hugging Face ekotizimi?

1-qadam. Modellar turli joyda, turli formatda — yuklab ishlatish qiyin. **2-qadam.** `from_pretrained` har modelni **bir xil** interfeys bilan yuklaydi (tokenizator + vaznlar).
3-qadam. O'qitish sikli (loop, optimizer, logging) takrorlanadi — Trainer uni **abstraktlaydi**.

Keltirib chiqarish: nega Hugging Face ekotizimi?

1-qadam. Modellar turli joyda, turli formatda — yuklab ishlatish qiyin. **2-qadam.**

`from_pretrained` har modelni **bir xil** interfeys bilan yuklaydi (tokenizator + vaznlar).

3-qadam. O'qitish sikli (loop, optimizer, logging) takrorlanadi — Trainer uni **abstraktlaydi**.

4-qadam. datasets ma'lumotni standart ko'rinishda beradi — fine-tuning bir necha qatorga tushadi.

Xulosa: ekotizim takrorlanuvchi ishni standartlashtiradi. Endi o'qitish qadamlari sonini hisoblaymiz.

Qo'lda misol: fine-tuning qadamlari soni

5000 namuna, batch = 16, epoch = 3.

Qadamlar:

$$\text{qadam/epoch} = \lceil 5000/16 \rceil = 313$$

$$\text{jami} = 313 \times 3 = \mathbf{939}$$

≈ 939 qadam — kichik datada fine-tuning tez (bir necha daqiqa GPU'da). Noldan o'qitish million qadam talab qilardi.

Sizning vazifangiz: boshqa konfiguratsiya uchun qadamlar

Savol — 60 soniya

8000 namuna, batch = 32, epoch = 2.

jami qadamlar =? ($\lceil 8000/32 \rceil = 250$)

Sizning vazifangiz: boshqa konfiguratsiya uchun qadamlar

Savol — 60 soniya

8000 namuna, batch = 32, epoch = 2.

jami qadamlar =? ($\lceil 8000/32 \rceil = 250$)

Javob

qadam/epoch = 250; jami = $250 \times 2 = 500$

Kattaroq batch $\Rightarrow$ kamroq qadam; lekin har qadam og'irroq. Kam epoch fine-tuning uchun yetarli (oldindan o'qitilgan).

Kod ↔ formula: Hugging Face Trainer

```
from transformers import (
    AutoModelForSequenceClassification,
    TrainingArguments, Trainer)

model = AutoModelForSequenceClassification.
    from_pretrained(
        "distilbert-base-multilingual-cased", num_labels=2)
args = TrainingArguments(output_dir="out",
    learning_rate=2e-5, per_device_train_batch_size=16,
    num_train_epochs=3, warmup_steps=100)
Trainer(model=model, args=args, train_dataset=ds).train
()
```

Kod → formula:

Kod	Formula
learning_rate	η
warmup_steps	t_{warmup}
num_labels	2 sinf

P13 da m13 aynan shu oqim bilan o'zbek sentimentini fine-tune qiladi.

Hugging Face tuzog'i: model va tokenizator mos kelishi shart

Nomuvofiq tokenizator

Tokenizator va model bir xil name dan yuklanishi kerak. Boshqa tokenizator $\Rightarrow$ noto'g'ri token ID lar $\Rightarrow$ model ma'nosiz chiqish beradi.

Yechim: har doim bir name dan AutoTokenizer va AutoModel.num_labels ni vazifaga moslang.

Prezentatsiya rejasi

- 1 Kirish: noldan o'qitmaymiz, oldindan o'qitilganni olamiz
- 2 Transfer learning: pre-training va fine-tuning
- 3 BERT: ikki tomonlama enkoder
- 4 T5: hamma narsa matndan matnga
- 5 Hugging Face ekotizimi
- 6 Xulosa va amaliyotga ko'prik

O'zbek tilida: WordPiece tokenizatsiya va qo'shimchalar

1. mBERT WordPiece:

mBERT o'zbekni kam ko'rgan — 'o'rganaman' kabi so'zni mayda bo'laklarga kesadi: o'rga ##na ##man (taxminan 5 token).

Muammo

Qo'shimchalar parchalanadi $\Rightarrow$ ketma-ketlik uzayadi, ma'no tarqaladi, fine-tuning sifatiga ta'sir qiladi.

2. XLM-RoBERTa:

XLM-RoBERTa SentencePiece bilan ko'p tilda (o'zbek ham) o'qitilgan — o'zbek so'zlarini ko'proq butun saqlaydi.

O'zbek vazifalari uchun XLM-RoBERTa ko'pincha mBERT'dan yaxshiroq. Tokenizatorni tanlash — muhim qaror.

Sintez: noldan o'qitish va fine-tuning; BERT va T5

Jihat	Noldan o'qitish	Fine-tuning (transfer)
Ma'lumot	millionlab yorliq	minglab yorliq yetadi
Hisob	kunlab, ko'p GPU	daqiqalar, 1 GPU
O'zbek uchun	imkonsiz	amaliy
Model turi	—	BERT (enkoder) / T5 (enk-dek)

Asosiy g'oya

Transfer learning bilimni katta korpusdan kichik vazifaga ko'chiradi. BERT tushunish (klassifikatsiya), T5 generatsiya (xulosa/tarjima) uchun. Hugging Face buni bir necha qatorga keltiradi.

Devlin, J., Chang, M., Lee, K., Toutanova, K. (2019). **BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding**. *NAACL-HLT 2019*.

Ahamiyati:


- Ikki tomonlama pre-training (MLM) ni ommalashtirdi.
- "Pre-train + fine-tune" ni NLP standartiga aylantirdi.
- Ko'p tilli mBERT kam-resursli tillarga (o'zbek) yo'l ochdi.

Muhokama savoli (P13 gacha o'ylang)

mBERT o'zbek qo'shimchalarini mayda kesadi. Bu sentiment klassifikatsiyasiga qanday ta'sir qiladi? XLM-RoBERTa nega yordam berishi mumkin?

- ① ✓ **Tushuntirdik:** transfer learning — pre-training va fine-tuning; kam-resursli til uchun zarurati.
- ② ✓ **Hisobladik:** fine-tuning BCE yo'qotishi — $\sigma(2.0) \approx 0.880$, $\text{BCE} \approx 0.128$.
- ③ ✓ **Tushuntirdik:** BERT (ikki tomonlama enkoder, MLM) va T5 (matn→matn) farqi.
- ④ ✓ **Tushuntirdik:** Hugging Face ekotizimi bilan fine-tuning oqimi.

Ertaga P13: BERT'ni o'zbek sentimentiga fine-tune qilamiz



P13 da qurasiz:

- m13 FineTunedClassifier: BERT + Trainer
- Uzum sentimentida fine-tuning (ijobiy/salbiy)
- BCE yo'qotish va baholash

Birinchi assert (bu slayd [I1]):

```
assert abs(  
    loss - 0.128) < 1e-2  
# Ma'ruza L13 [I1]-slayd bilan  
# solishtiring (sigma(2.0), BCE)
```

- ① Devlin, J., va boshq. (2019). *BERT: Pre-training of Deep Bidirectional Transformers*. NAACL-HLT 2019.
- ② Raffel, C., va boshq. (2020). *Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer (T5)*. JMLR 21.
- ③ Howard, J., Ruder, S. (2018). *Universal Language Model Fine-tuning (ULMFiT)*. ACL 2018.
- ④ Conneau, A., va boshq. (2020). *Unsupervised Cross-lingual Representation Learning at Scale (XLM-RoBERTa)*. ACL 2020.
- ⑤ huggingface.co/docs/transformers hujjatlari.

Ilova S1: MLM niqoblash strategiyasi (80/10/10)

BERT niqoblangan 15% tokenni quyidagicha qayta ishlaydi:

- 80% — [MASK] bilan almashtiriladi.
- 10% — tasodifiy boshqa so'z bilan almashtiriladi.
- 10% — o'zgarishsiz qoldiriladi.

bunda: Bu strategiya model fine-tuning paytida [MASK] ko'rmasligiga (train/test nomuvofiqligiga) qarshi turadi — model har doim kontekstga tayanadi.

Ilova S2: T5 span-corruption pre-training

T5 alohida tokenlar emas, **bo'laklar** (span) ni niqoblaydi:

kirish: "NLP <X> qiziq <Y> fan" → chiqish: "<X> juda <Y> foydali"

bunda: $\langle X \rangle, \langle Y \rangle$ — maxsus sentinel tokenlar; model niqoblangan bo'laklarni ketma-ketlik sifatida tiklaydi — bu enkoder-dekoder formatga tabiiy mos keladi.

Shu tariqa T5 pre-training ham, fine-tuning ham bir xil matn→matn shaklida bo'ladi.